Liora
ex DataScientest

R

amazon

Trustpilot

Amazon Reviews

Sentiment Analysis & Topic Modelling

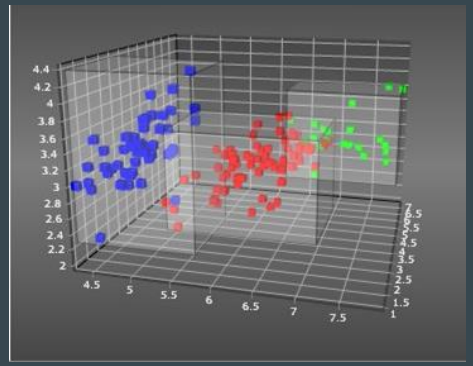

Agenda

- → Introduction
- → Présentation des données
- → Preprocessing
- → Classification du sentiment
- → Topic modelling
- → Démo Streamlit
- → Exploitation métier
- → Conclusion

Introduction - contexte

- Trustpilot collecte des millions d'avis clients
- Analyse manuelle impossible pour les grandes entreprises
- Besoin : permettre une analyse à grande échelle des Avis clients

Client pilote : Responsable marketing Amazon (produits Culture Loisirs)

- ➢ Analyser rapidement les ressentis des clients Amazon
- ➢ Identifier les causes d'insatisfaction et les produits concernés

Objectif : ***Offrir une lecture claire, rapide et synthétique des avis collectés***

Introduction - objectifs

Solution technique cible : modèles NLP

Prédiction du SENTIMENT

Définir la polarité (Positif / Négatif) d'un avis

→ Classification binaire

→ Métrique clé : Recall classe négative

Prédiction du THEME

Extraire les grands thèmes récurrents des avis

→ Clustering & Topic Modeling

→ 6 thèmes à identifier

→ Métrique clé : coefficient de Silhouette

Livrable : Pipeline de pré processing + module d'analyse des avis

Présentation des données

- Avis Trustpilot des clients Amazon
- Produits de divertissement et de loisirs
- Corpus volumineux (3.6 M) et hétérogène
- Classes équilibrées : 50% positifs / 50% négatifs

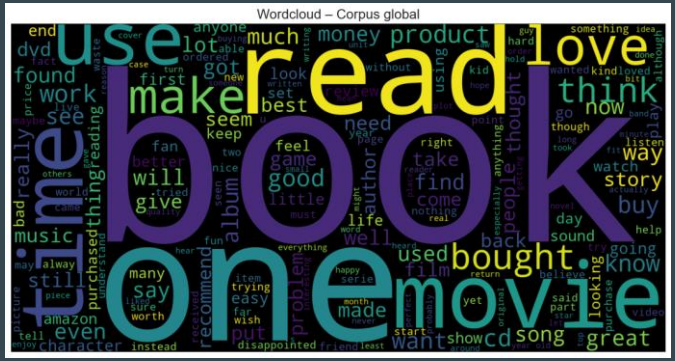
Wordcloud – Corpus global
book
read
one
movie
use
love
make
think
time
bought
money
product
music
story
way
buy
know
great
song
cd
want
used
find
take
good
feel
will
give
seem
need
keep
best
look
set
first
found
work
see
dvd
end
much
lot
got
now
though
listen
watch
sound
day
back
life
well
author
album
thing
reading
purchased
recommend
problem
amazon
even
still
character
many
say
made
easy
put
trying
wish
worth
disappointed
friend
least
instead
show
yet
said
part
looking
going
help
bad
really
others
world
fan
better
tried
nice
two
right
anything
people
thought
using
kind
hard
gay
something
idea
although
play
kid
without
case
cover
fact
price
waste
receive
sure
tell
piece
enjoy
may
always
picture
hear
turn
start
month
series
happy
item
fun
far
sure
worth
yet
return
film
everything
must
nothing
real
especially
original
receive

Preprocessing

Langues présentes :

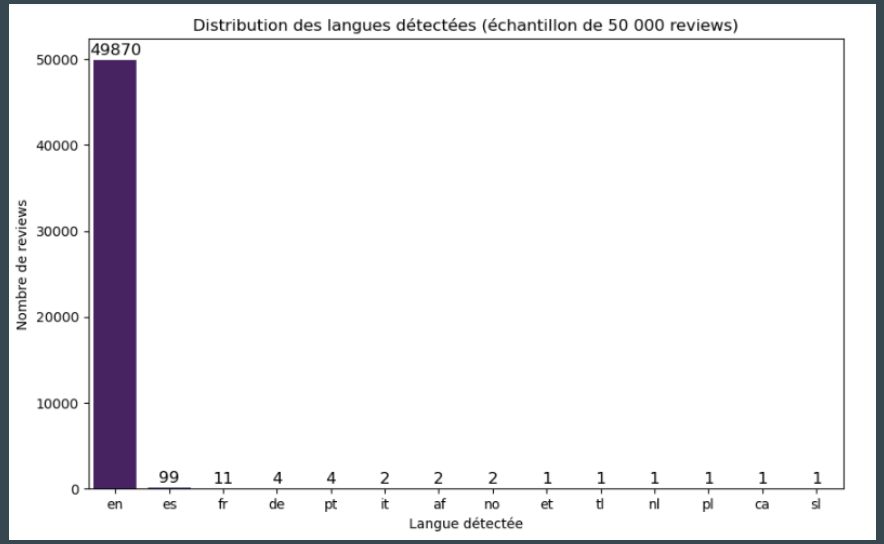

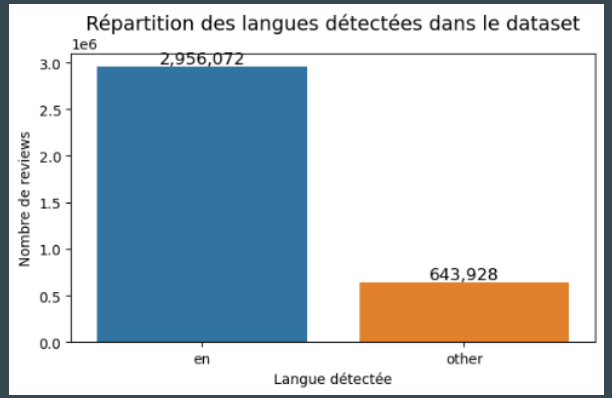

Fonction
“looks_english”

Preprocessing

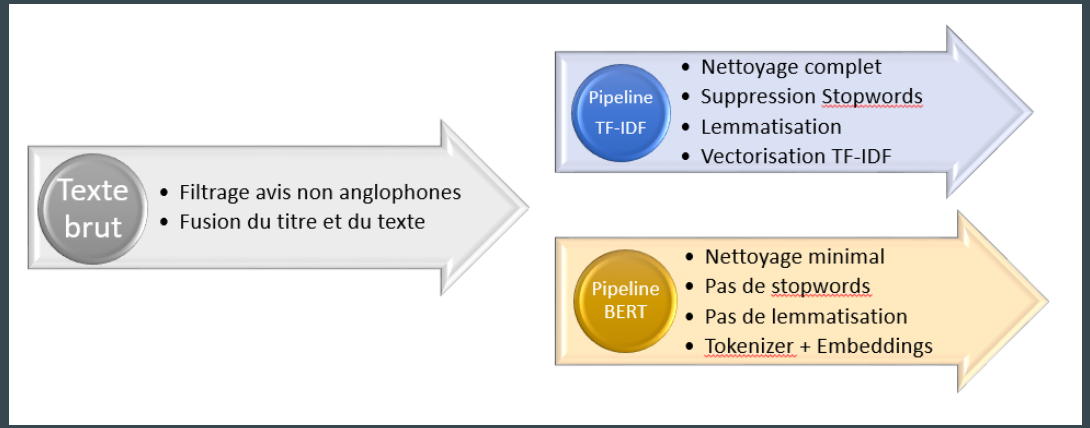

Vectorisation TF-IDF

	token	tfidf
45	music back	0.210705
13	vid	0.208586
24	fresher	0.205658
46	anyone care	0.204698
39	people hate	0.196929
34	even non	0.196399
38	even people	0.194822
14	game	0.190103
40	music played	0.188885

Embeddings

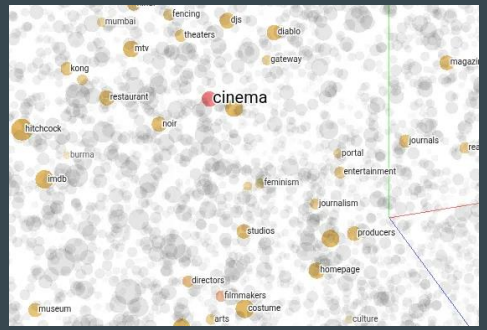

Classification du sentiment - modèles entraînés

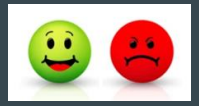

Prédire le sentiment (positif ou négatif) de l'avis : <u>Classification supervisée</u>

Modèles Baseline

- **Naïve Bayes**
  → probabiliste simple, rapide, basé sur la fréquence des mots
- **Régression Logistique**
  → Classificateur linéaire robuste, bonne interprétabilité
- **SVM Linéaire**
  → Performant sur données textuelles de grande dimension

📌 Rôle : établir une base de comparaison solide et interprétable

Modèles Avancés

- **Random Forest**
  → Modèle d'ensemble: capte les interactions non linéaires
- **XGBoost**
  → Gradient Boosting: performant mais sensible au bruit

📌 Rôle : exploiter la compréhension sémantique profonde du texte

Classification du sentiment - performances

	Modèle	Taille du train set	Accuracy	F1 Score	Recall classe négative	Interprétation
✅	SVM optimisé	3.6M	0.9198	0.9188	0.9159	Modèle linéaire très performant, tire profit du volume massif
✅	LogReg optimisé	3.6M	0.9197	0.9187	0.916	Excellent baseline, stable
❌	Naive Bayes	3.6M	0.880	0.879	0.875	Baseline rapide, mais limité
❌	Random Forest	80k	0.867	0.866	0.854	Arbres → surfit sur petit échantillon, pas adapté au texte
❌	XGBoost	120k	0.858	0.859	0.849	Puissant, mais trop peu de données pour exploiter TF-IDF

Classification du sentiment - performances

DistilBERT

- Modèle Transformer, issu de la distillation de BERT (apprentissage à partir d'un modèle plus complexe)

- Fine tuning complet :

  - Entraînement de la tête de classification (DistilBertForSequenceClassification)

  - Ajustement de tous les poids de DistilBERT

- Performances proches de BERT mais coût de calcul réduit (meilleur compromis performance / efficacité)

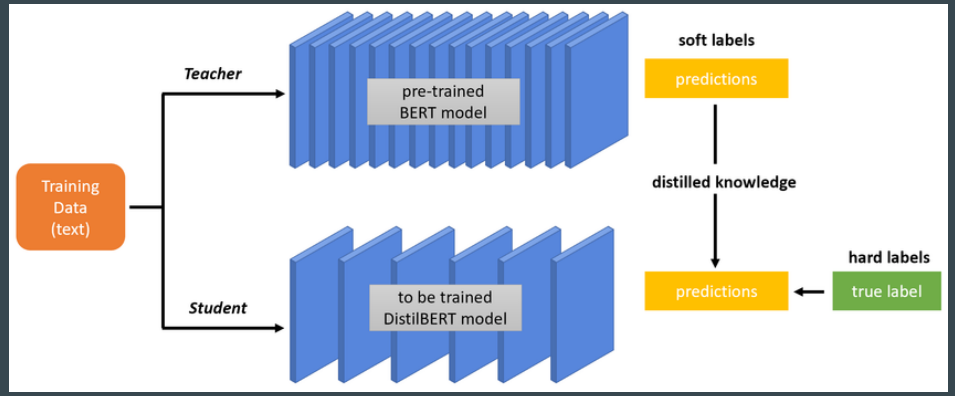


```
Accuracy : 0.9255
F1-score : 0.926
Recall classe négative : 0.93
```

Modèle retenu pour le déploiement

Topic modelling - modèles entraînés

Objectif : Identifier le thème principal de l'avis : Clustering non supervisé

Modèle Baseline

TF-IDF + KMeans

Méthode

- Vectorisation TF-IDF
- 25k reviews échantillonnées
- Basé sur la fréquence des mots

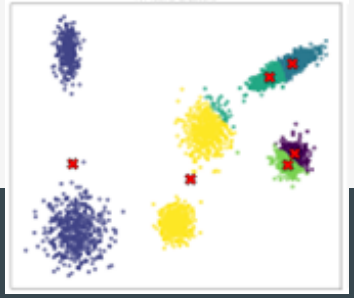

Modèle Avancé

Sentence-BERT + KMeans

Méthode

- Embeddings sémantiques denses
- 20k reviews échantillonnées
- Basé sur le sens global du texte

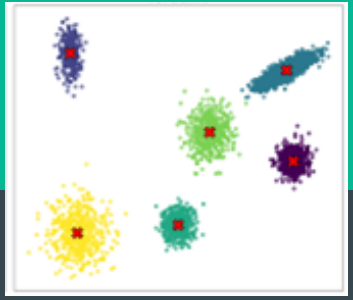

Démonstration - Streamlit

Lien vers la Démo

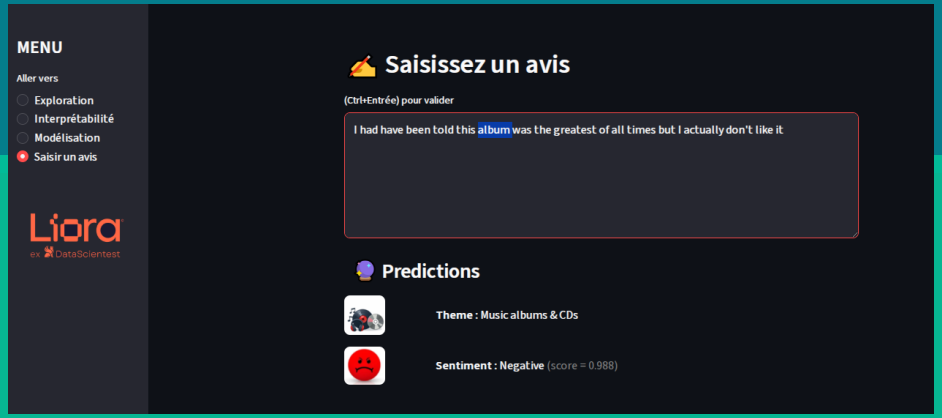

Exploitation métier

💬 ⇨ ✅ Transformer les avis clients en décision concrètes.

▯ 💬 Analyse automatique des sentiments + thèmes.

● **Détection rapide des insatisfactions**
→ Identifier les produits et causes critiques (prix, qualité, fiabilité)

⚡ **Priorisation intelligente du support client**
→ Traitement accéléré des avis très négatifs

📈 **Optimiser la stratégie marketing**
Identifier ce que les clients valorisent
Adapter l'offre et la communication

Conclusion – Bilan

🎯 **Objectifs atteints**

Sentiment + extraction de thèmes

⚙️ **Modèles performants**

Classification précise + analyse complémentaire

📊 **Résultats exploitables métier**

Outil d'aide à la décision concret

🌍 **Cas réel validé**

Aligné avec un besoin type Trustpilot

Conclusion - perspectives

Perspectives sur les modèles

- Entraîner DistilBERT avec GPU
- Tester des Transformers plus avancés (BERT, RoBERTa)
- Passer à une classification multi-niveaux (5 sentiments)
- Utiliser BERTopic pour un topic modeling plus performant

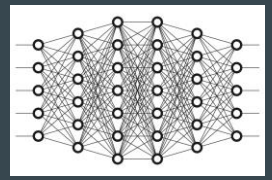

Perspectives sur les données

- Ajout de métadonnées (date, catégorie, note)
- Analyse de l'évolution du sentiment dans le temps
- Extension multilingue
- Détection de faux avis / spam

Perspectives métier / produit

- Dashboard décisionnel pour les équipes métier
- Alertes automatiques en cas de pic d'avis négatifs
- Priorisation des problèmes clients
- Intégration dans un pipeline temps réel

Merci pour votre attention

```
import pandas as pd
import matplolib.pyplot as plt

from skleern.model_selection import train_test_split

data = pd.read_csv("data.csv")

df.head()

X = data[['feature1,]

sns.heatmap(corr, an

sns.heatmap(corr,

model.fit(X_ti

y_pred = model.predict(X_test)

accuracy = accuracy_score(y_test, y_pred).

plt.xlabel("Feature 1")
plt.ylabel("Feature 2")
plt.title("Nuage de points")
plt.show()
```

Annexes

Outil Trustpilot

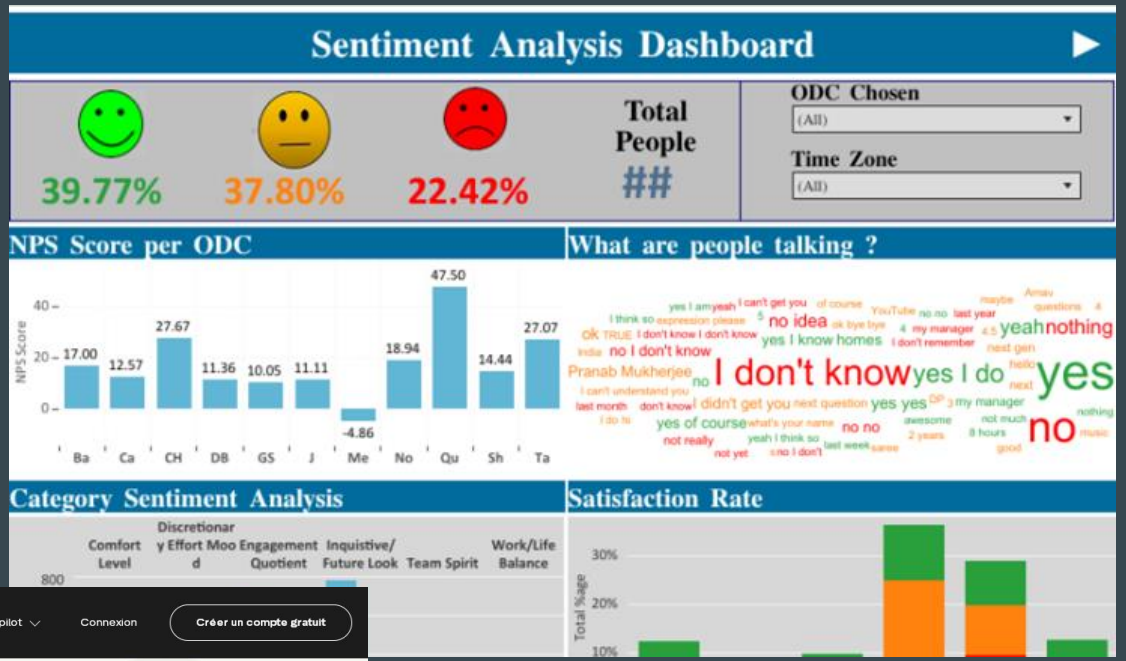

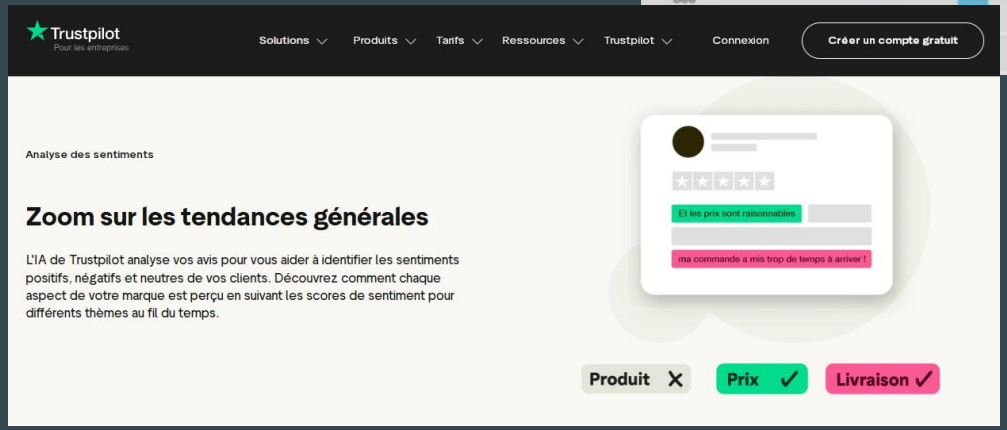

Term Frequency -Inverse Document Frequency

$$\text{TF-IDF} = \frac{\text{term frequency}}{\text{total words}} \times \log\left(\frac{\text{corpus size}}{1 + \text{documents with term}}\right)$$

	a	best	great	in	indeed	is	our	place	the	this	world
D1	0	0.34262	0	0.34262	0	0.243777	0	0.243777	0.68524	0.34262	0.243777
D2	0.425677	0	0.425677	0	0.425677	0.302873	0.425677	0.302873	0	0	0.302873

D1	[0, 0.34262, 0, 0.34262, 0, 0.243777, 0, 0.243777, 0.68524, 0.34262, 0.24377]
D2	[0.425677, 0, 0.425677, 0, 0.425677, 0.302873, 0.425677, 0.302873, 0, 0, 0.302873]

Topic modelling - performances

Comparaison des approches

Critère	TF-IDF + KMeans	SBERT + KMeans
Silhouette Score	0.0037	**0.0479 (13x supérieur)**
Cohérence des thématiques	Moyenne	**Excellente**
Séparation clusters	Recouvrement	**Nette séparation**

6 thèmes principaux extraits avec Sentence-BERT