Amazon Reviews
Sentiment Analysis & Topic Modelling

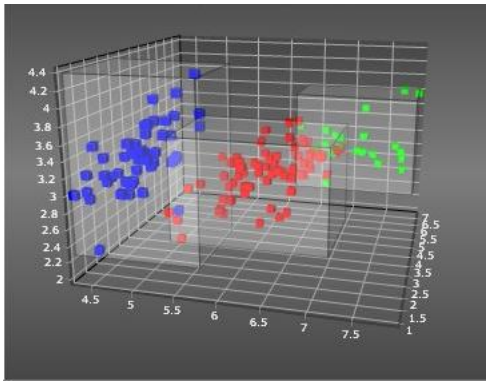

DataScientest

2025-2026

1 Contexte du projet **5**
2 Description du dataset **5**
3 Chargement et aperçu des données **7**
3.1 Inspection initiale du dataset 7
3.1 Qualité des données 8
4 Analyse univariée **9**
4.1 Répartition des classes 9
4.2 Longueur des avis 10
5 Analyse qualité du texte **13**
5.1 Détection de contenu HTML 13
5.2 Détection des caractères non ASCII 13
5.3 Détection automatique de la langue 14
5.4 Ponctuation suspecte 15
5.5 Reviews trop courtes 16
5.6 Répétitions suspectes 16
5.7 Synthèse de la qualité du corpus 17
6 Analyse textuelle exploratoire **18**
6.1 Nettoyage minimal (exploration) 18
6.2 Wordclouds 18
6.3 Fréquence des mots (sans stopwords) 20
6.4 N-grams 22
6.5 Analyse des stopwords 27
7 Pré-processing envisagé pour la modélisation **29**
7.1 Concaténation du titre avec la review 29
7.2 Normalisation du texte 30
7.3 Tokenisation 30
7.4 Stopwords 30
7.5 Lemmatisation (optionnel) 30
7.6 Construction des features 31
8 Pré-processing (implémentation réelle) **32**
8.1 Filtrage des reviews non anglaises 32
8.2 Concaténation du titre et la review 33
8.3 Nettoyage du texte 33
8.3.1 Passage en minuscules 33
8.3.2 Suppression de la ponctuation 33
8.3.3 Normalisation des espaces et nettoyage général 34
8.3.4 Suppression des caractères non ASCII 34
8.4 Suppression des stopwords 34

8.5 Lemmatisation 35
8.6 Tokenisation 36
8.7 Construction des représentations vectorielles 37
Interprétation des vecteurs TF-IDF 37
8.8 Pipeline final 39
8.9 Conclusion de l'exploration et du pré traitement 40
9 Modélisation du Sentiment (supervisée) 41
9.1 Préparation des données 41
9.2 Analyse métier des métriques 41
9.3 Modèles baselines 41
9.3.1 Régression logistique 42
9.3.2 Naive Bayes 42
9.3.3 SVM linéaire 43
9.3.4 Synthèse des modèles baseline 43
9.4 Modèles Optimisés 44
9.4.1 Méthode 44
9.4.2 Régression Logistique optimisée 44
9.4.3 SVM Linéaire optimisé 46
9.4.4 Comparaison globale après optimisation 47
9.4.5 Interprétation métier 47
9.4.6 Conclusion Step 2 47
9.5 Modèles avancés 48
9.5.1 Random Forest 48
9.5.2 XGBoost 49
9.6 Bilan des modèles 51
9.7 Interprétabilité des modèles 51
9.7.1 Régression Logistique optimisée 52
9.7.2 SVM linéaire optimisé 52
9.7.3 Random Forest 53
9.7.4 XGBoost 54
9.7.5 Synthèse de l'interprétabilité 55
9.8 Modèle Fine-tuning DistilBERT 55
9.8.1 Architecture et justification 56
9.8.2 Préparation du dataset 56
9.8.3 Hyperparamètres retenus : 56
9.8.4 Fine tuning de DistilBERT 56
9.8.5 Résultats obtenus 57
9.8.6 Analyse 57
9.9 Interprétabilité du modèle DistilBERT 58
9.9.1 Interprétabilité locale avec des reviews du dataset 58
9.9.2 Rédaction d'avis ambigus pour challenger le modèle 59
9.9.3 Synthèse 60
9.10 Conclusion métier 60
Apport métier : 60

9.11 Conclusion de la prédiction du sentiment 60
10 Modélisation – Thématisation 61
10.1 Préprocessing spécifique au Topic Modeling 61
10.2 Baseline : TF-IDF + KMeans 61
10.2.1 Méthodologie 61
10.2.2 Résultats : 61
10.2.3 Thèmes identifiés et interprétabilité 62
10.3 Approche avancée : Sentence-BERT + KMeans 64
10.3.1 Pourquoi SBERT ? 64
10.3.2 Méthodologie 64
10.3.3 Résultats SBERT 64
10.3.4 Exemples qualitatifs par cluster + interprétabilité 64
10.4 Comparaison TF-IDF vs SBERT 67
10.5 Synthèse des Thématiques identifiées 67
10.6 Test des 2 modèles DistilBert et SentenceBert sur des avis personnalisés 68
10.7 Conclusion de la section 70
11 Synthèse générale 71
11.1 Analyse de sentiment 71
11.2 Analyse thématique (Topic Modeling) 71
a) Baseline TF-IDF + KMeans 71
b) Sentence-BERT + KMeans 72
11.3 Recommandations métier 72
11.4 Limites du projet & Pistes d'amélioration 73
12 Conclusion finale 74

1 Contexte du projet

Les entreprises s'appuient de plus en plus sur Trustpilot pour comprendre la voix de leurs clients, suivre la satisfaction et repérer les axes d'amélioration de leurs produits ou services. Toutefois, la masse d'avis collectés rend l'analyse manuelle complexe : trop de commentaires à lire, difficulté à identifier les thèmes récurrents et manque d'outils simples pour exploiter efficacement cette donnée textuelle.

Face à ces limites, la direction de Trustpilot nous a confié la conception d'un module d'analyse automatique destiné aux entreprises clientes. L'objectif est de leur offrir une lecture claire, rapide et synthétique des avis collectés, en regroupant les commentaires par thématique et par sentiment, et en les restituant dans un tableau de bord orienté décision.

Pour guider notre réflexion, nous avons choisi de nous placer dans le cas d'un client réel : Paul, Responsable Marketing Produits Loisirs chez Amazon, entreprise fortement utilisatrice de Trustpilot et disposant d'un volume d'avis très élevé. Son périmètre illustre parfaitement les problématiques rencontrées par les équipes marketing et customer experience : comprendre les ressentis exprimés, identifier les sources d'insatisfaction et suivre l'évolution des tendances de satisfaction.

Dans ce contexte, le projet poursuit deux objectifs complémentaires :

- **Analyse supervisée** : prédire automatiquement la polarité d'un avis (positif / négatif)

- **Analyse non supervisée** : extraire les grands thèmes récurrents évoqués par les utilisateurs (clustering, topic modeling).

Ce travail d'exploration constitue la première étape de la construction d'un produit Data destiné à des équipes opérationnelles — marketing, qualité, service client — cherchant à exploiter leurs données d'avis de manière structurée et actionnable.

2 Description du dataset

Dans le cadre de ce projet, nous avons besoin d'un corpus suffisamment large et représentatif pour simuler un volume important d'avis similaires à ceux que reçoit un client Trustpilot disposant d'une forte activité, comme **Amazon** dans sa catégorie *Produits Loisirs*.
Le dataset retenu est **Amazon Reviews Polarity**, une référence bien connue en NLP, disponible sur Kaggle.

Ce corpus contient des millions d'avis publiés par des utilisateurs Amazon, chacun annoté selon une polarité binaire :

- 1 = avis négatif
- 2 = avis positif

Il est structuré en deux fichiers principaux :

- 3,6 millions d'avis pour l'entraînement (*train.csv*)
- 400 000 avis pour le jeu de test (*test.csv*)

Chaque avis comporte trois champs :

- title : résumé court, souvent une synthèse de l'opinion
- text : contenu textuel complet, support principal pour l'analyse
- label : polarité du sentiment, utilisée comme variable cible

Plusieurs caractéristiques font de ce dataset un support pertinent pour notre cas d'usage Trustpilot :

✓ **Un volume très important**
Il permet de simuler la situation réelle d'un client Trustpilot recevant des milliers d'avis par jour et nécessitant une automatisation de leur analyse.

✓ **Un dataset équilibré**
Les classes positif et négatif sont de même taille, facilitant l'entraînement de modèles supervisés fiables.

✓ **Un corpus textuel riche**
Les avis sont majoritairement longs et expressifs, ce qui est idéal pour :

- la classification de sentiments,
- l'extraction thématique ou le clustering,
- les modèles avancés comme les transformers.

Surreprésentation des produits culturels

Il est essentiel de noter que ce dataset n'est pas un échantillon généraliste de toute la marketplace Amazon.
Il est fortement dominé par des produits culturels :

- livres,
- films,
- musique,
- jeux vidéo,
- produits de divertissement familiaux.

Ce biais provient du processus de sélection original du dataset, orienté vers des catégories générant des textes plus denses et plus polarisés.

Dans notre projet, cette caractéristique est cohérente avec notre persona défini en tant que Data Product Manager : Paul, Responsable Marketing Produits Loisirs chez Amazon, dont l'activité couvre précisément ce type de produits

3 Chargement et aperçu des données

Afin de préparer l'analyse exploratoire, nous commençons par charger les deux fichiers fournis par le dataset *Amazon Reviews Polarity* : **train.csv** et **test.csv**. Le premier contient 3,6 millions d'avis et constitue notre base d'apprentissage principale ; le second, composé de 400 000 avis, servira ultérieurement à l'évaluation des modèles.

Ces fichiers ne possèdent pas d'en-tête dans la version Kaggle : les colonnes sont donc ajoutées manuellement pour faciliter leur lecture :

- **label** : polarité du sentiment (1 = négatif, 2 = positif),
- **title** : titre court de l'avis,
- **text** : texte complet rédigé par l'utilisateur.

Une première utilisation de `head()`, `shape`, et `info()` confirme que les données sont structurées conformément à la documentation du dataset Kaggle.

3.1 Inspection initiale du dataset

	label	title	text
0	2	Stuning even for the non-gamer	This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^
1	2	The best soundtrack ever to anything.	I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.
2	2	Amazing!	This soundtrack is my favorite music of all time, hands down. The intense sadness of "Prisoners of Fate" (which means all the more if you've played the game) and the hope in "A Distant Promise" and "Girl who Stole the Star" have been an important inspiration to me personally throughout my teen years. The higher energy tracks like "Chrono Cross ~ Time's Scar~", "Time of the Dreamwatch", and "Chronomantique" (indefinably remeniscent of Chrono Trigger) are all absolutely superb as well.This soundtrack is amazing music, probably the best of this composer's work (I haven't heard the Xenogears soundtrack, so I can't say for sure), and even if you've never played the game, it would be worth twice the price to buy it.I wish I could give it 6 stars.
3	2	Excellent Soundtrack	I truly like this soundtrack and I enjoy video game music. I have played this game and most of the music on here I enjoy and it's truly relaxing and peaceful.On disk one. my favorites are Scars Of Time, Between Life and Death, Forest Of Illusion, Fortress of Ancient Dragons, Lost Fragment, and Drowned Valley.Disk Two: The Draggons, Galdorb - Home, Chronomantique, Prisoners of Fate, Gale, and my girlfriend likes ZelbessDisk Three: The best of the three. Garden Of God, Chronopolis, Fates, Jellyfish sea, Burning Orphange, Dragon's Prayer, Tower Of Stars, Dragon God, and Radical Dreamers - Unstealable Jewel.Overall, this is a excellent soundtrack and should be brought by those that like video game music.Xander Cross
4	2	Remember, Pull Your Jaw Off The Floor After Hearing it	If you've played the game, you know how divine the music is! Every single song tells a story of the game, it's that good! The greatest songs are without a doubt, Chrono Cross: Time's Scar, Magical Dreamers: The Wind, The Stars, and the Sea and Radical Dreamers: Unstolen Jewel. (Translation varies) This music is perfect if you ask me, the best it can be. Yasunori Mitsuda just poured his heart on and wrote it down on paper.

Une première inspection via `head()` puis `info()` permet de confirmer :

L'aperçu des premières lignes montre que :

- les avis sont rédigés en anglais,
- le contenu textuel est souvent long, détaillé et argumenté — caractéristique typique des catégories produits dominantes du dataset (livres, films, musique, jeux vidéo),
- La variable "**label"** est correctement encodée (1 ou 2), ce qui facilitera la tâche de classification supervisée.

Il faut noter que l'encodage (1,2) deviendra parfois (0,1) car les modèles sklearn convertissent automatiquement les labels en valeurs numériques encodées de 0 à n-classes−1.

Nous observons également que certains champs peuvent contenir des caractères spéciaux, de la ponctuation expressive ou des formats inhabituels (par exemple : majuscules, répétitions, ponctuation excessive). Ces éléments feront l'objet d'une analyse spécifique dans la section dédiée à la qualité du texte.

3.1 Qualité des données

Plusieurs éléments sont examinés avant de poursuivre l'exploration :

✓Présence de valeurs manquantes

```
# Valeurs manquantes
train.isna().sum()
✓ 0.6s

label      0
title    207
text       0
dtype: int64
```

- **text** : aucune valeur manquante
- **label** : aucune valeur manquante
  title : 207 valeurs vides (≈ 0,005 %), un taux négligeable qui ne perturbera pas l'analyse

Il y a quasiment systématiquement un titre qui accompagne la review. or le titre est potentiellement représentatif du sentiment, voire de la thématique. On donc aura intérêt dans le pré processing à concaténer le titre avec la review pour récupérer l'information qu'il contient.

✓Doublons

On observe 5217 doublons de review présents dans le dataset. Sur 3 600 000 reviews, cela ne représente que 0,14% mais on les supprimera lors du pré- processing.

✓Première évaluation de la qualité textuelle

L'examen préliminaire révèle la présence ponctuelle de :

- ponctuation expressive,
- caractères spéciaux,
- variantes d'écriture (majuscules, abréviations),
- avis très courts.

Ces éléments feront l'objet d'analyses plus détaillées dans la section **5 — Analyse qualité du texte**, afin d'anticiper les choix de pré-processing nécessaires.

4 Analyse univariée

L'analyse univariée permet d'examiner séparément les caractéristiques essentielles du dataset avant d'étudier des relations plus complexes entre les variables textuelles et les sentiments. Dans ce projet, deux aspects sont particulièrement importants :

- la répartition des classes de sentiment,
- et la longueur des avis, qui peut avoir un impact sur la qualité des modèles NLP.

4.1 Répartition des classes

L'examen de la variable *label* montre que les avis positifs et négatifs sont répartis de manière parfaitement équilibrée :

- **1,8 million d'avis négatifs** (label = 1)
- **1,8 million d'avis positifs** (label = 2)

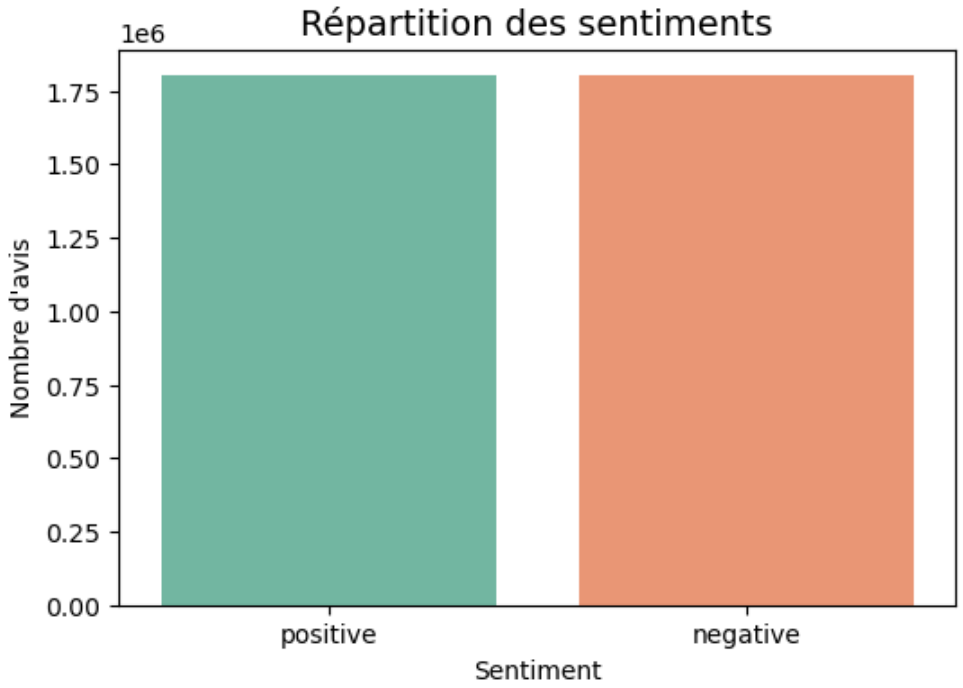

Cette symétrie constitue un avantage important pour l'apprentissage supervisé, car elle évite les problèmes classiques de déséquilibre de classes, tels que la sur-représentation d'un sentiment ou la nécessité d'utiliser des techniques de rééchantillonnage.

Elle reflète également la structure originale du dataset Amazon Polarity, construit intentionnellement pour fournir un corpus équilibré afin de tester les performances des modèles de classification sentimentale.

Dans notre cas d'usage, cela nous permet d'entraîner un modèle robuste sans ajustement particulier dès la phase exploratoire.

4.2 Longueur des avis

Etude statistique

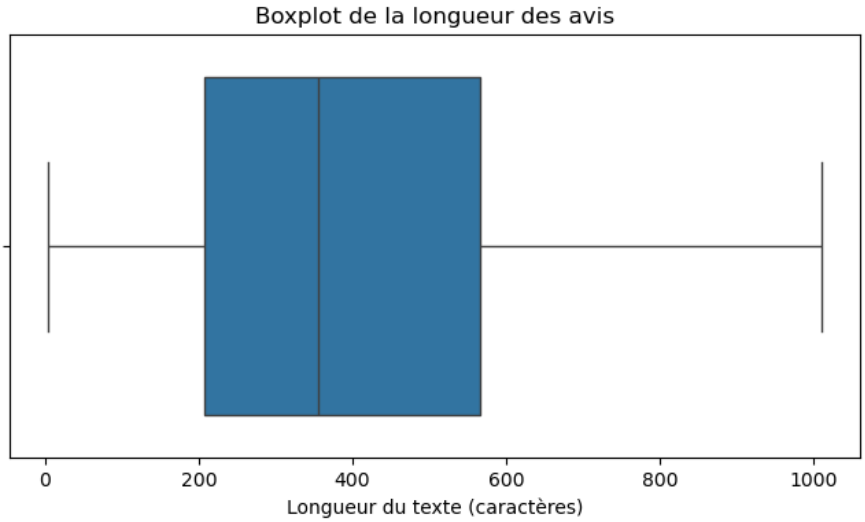

- count = 3 600 000 reviews
- mean ≈ 405 caractères
- std ≈ 234
- min = 4
- 25% = 207
- 50% (médiane) = 356
- 75% = 566
- max ≈ 1000

Distribution des longueurs des avis

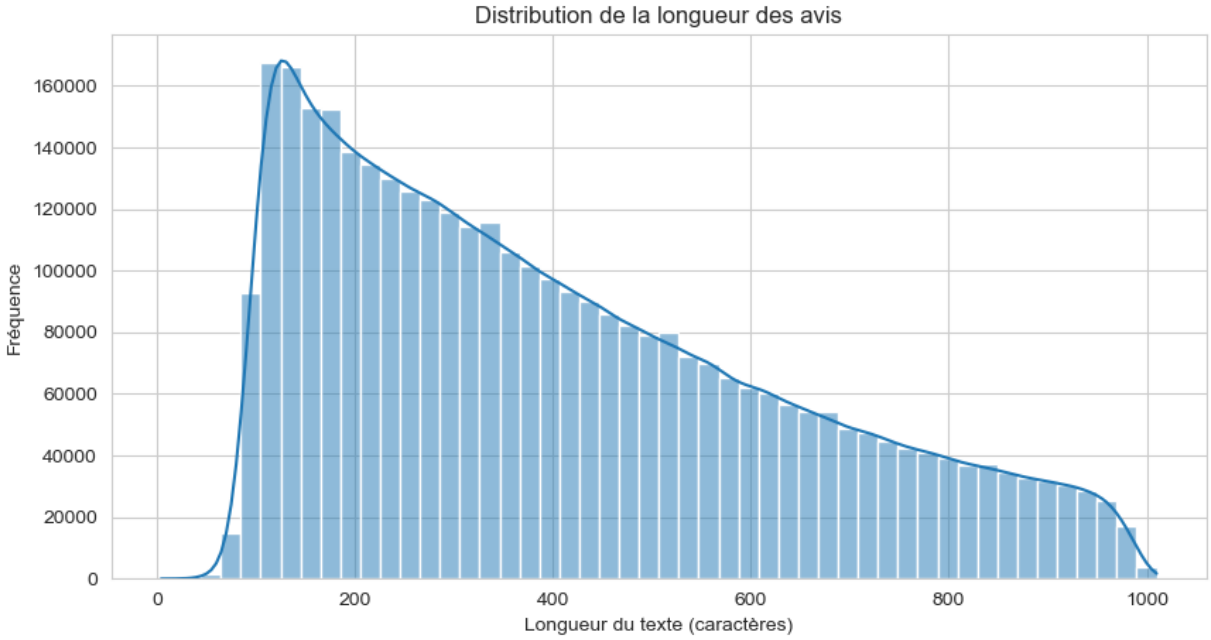

L'analyse de la distribution des longueurs d'avis (en nombre de caractères) met en évidence plusieurs tendances :

- Les avis sont globalement riches et détaillés, avec une longueur médiane de 356 caractères.
- La majorité des avis se concentrent entre 200 et 600 caractères.
- Une longue "queue" de distribution existe vers les avis très longs (jusqu'à 1000 caractères), typique des catégories produits culturels (livres, films, musique

Longueur des avis selon le sentiment

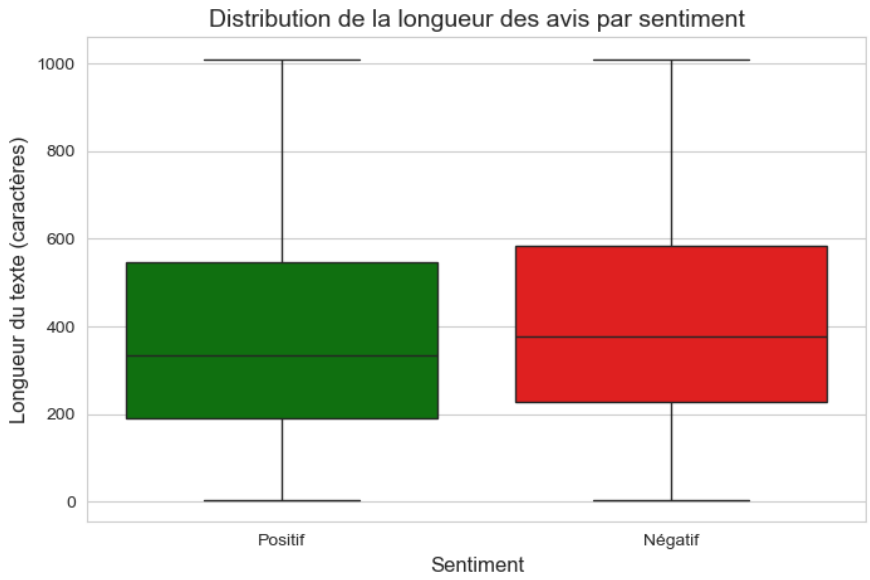

Lorsque la distribution est segmentée par sentiment (positif vs négatif), on observe des distributions très proches. Toutefois le boxplot montre que la médiane des avis négatifs est légèrement supérieure à celle des avis positifs, indiquant que les avis négatifs ont tendance à être un peu plus longs dans ce corpus. Cette tendance peut s'expliquer par le fait que certains utilisateurs insatisfaits détaillent davantage leur expérience ou justifient leur frustration. Inversement, les avis positifs restent souvent synthétiques et orientés vers la recommandation rapide.

Si on regarde la distribution des longueurs d'avis via des violin plot , on s'aperçoit que le profil diffère selon le sentiment : les avis négatifs très courts et très longs sont plus nombreux que les avis positifs, signe que beaucoup de commentaires positifs sont aussi très courts parce qu'ils expriment brièvement une colère ou très long parce qu'ils détaillent les raisons de leur mécontentement. A l'inverse, les longueurs des avis positifs sont légèrement plus homogènes.

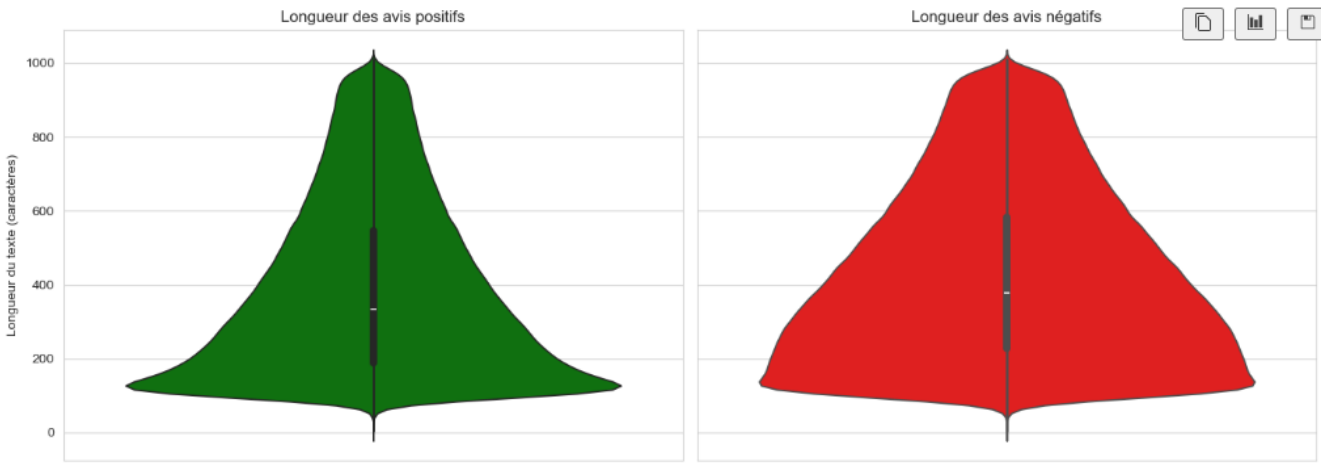

Toutefois, comme on peut le constater sur les histogrammes ci après, les distributions des longueurs par sentiment sont très proches, confirmant que la longueur d'un avis n'est pas discriminante en elle-même pour prédire le sentiment.

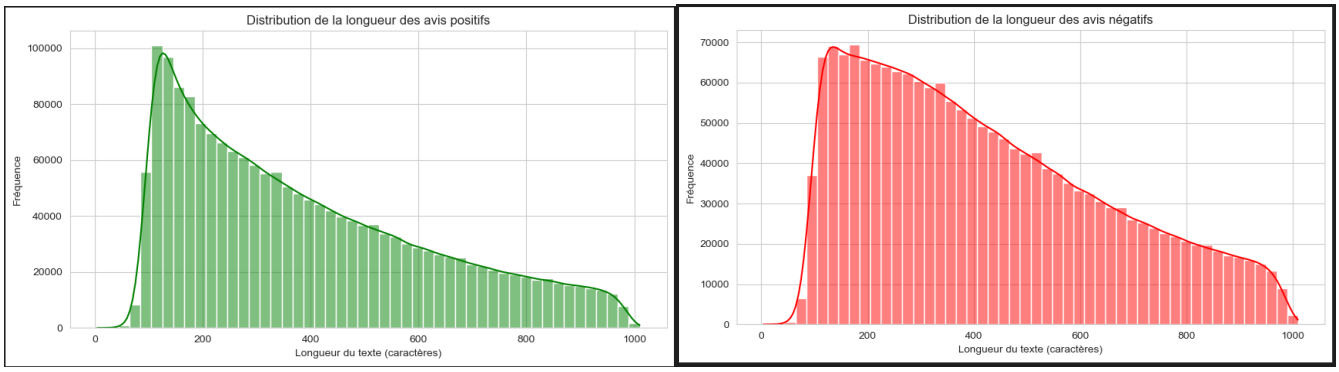

5 Analyse qualité du texte

L'objectif de cette section est d'évaluer l'état brut du corpus avant tout nettoyage, afin d'identifier d'éventuels éléments problématiques (balises, caractères spéciaux, répétitions anormales…) et de déterminer les traitements nécessaires au preprocessing.

Sur les 3,6 millions d'avis, plusieurs tests ont été menés pour mesurer la qualité linguistique globale.

5.1 Détection de contenu HTML

Certains avis peuvent contenir des fragments ressemblant à des balises HTML, introduits soit par le copier-coller de contenu web, soit par des formats automatiques utilisés par certaines plateformes d'avis. Pour vérifier ce point, une expression régulière a été appliquée sur l'ensemble du corpus afin d'identifier la présence de motifs du type `<tag>` ou `</tag>`.

L'analyse révèle que **moins de 0,05 %** des avis contiennent des motifs assimilables à du HTML. Toutefois, la majorité de ces occurrences correspondent en réalité à des symboles ou annotations entre chevrons (ex. : `<over 13>`) plutôt qu'à de véritables balises HTML structurées. Il ne s'agit donc pas d'un bruit systématique nécessitant un nettoyage spécifique.

```
Nombre de reviews contenant de vraies balises HTML : 395

I started to read just the introduction and I started to sense that something was wrong, very wrong. Besides the assumption of
eco-feminism as compatible with Orthodoxy, he discusses the occult he was deeply involved with in terms that made me more than
uncomfortable: admiration, an ambassador's tone in describing occult matters, almost reminiscent of patriotism. This is the sort
of thing one should speak of out of deep humility spurred by repentance from serious sin.This is the first time I have purchased a
book that I thought was Orthodox theology and didn't get past the introduction before regretting I'd made the purchase.If you
wonder, "Does this critic have anything better to say?" then <a href="http://www.amazon.com/author/cjshayward">I invite you to
visit my own author's section.</a>
```

Les rares cas identifiés correspondent probablement :

- à des copier-coller depuis des pages web,
- à des descriptions mal formatées,
- ou à des versions anciennes des avis.

Conséquence pour le preprocessing :

Un simple nettoyage avec une expression régulière suffit pour retirer ces balises. Aucune exclusion d'avis n'est nécessaire.

5.2 Détection des caractères non ASCII

Afin d'évaluer la qualité générale du texte et d'identifier d'éventuels problèmes d'encodage, nous avons recherché la présence de caractères non ASCII dans l'ensemble du corpus (lettres accentuées, symboles spéciaux, caractères typographiques inhabituels, etc.).
Une analyse de la présence de caractères hors ASCII (emojis, guillemets typographiques, symboles spéciaux, caractères internationaux…) montre que **11 728** avis contiennent au moins un caractère non conforme.

```
Nombre de reviews avec des caractères non ASCII visibles : 11728
LO QUE PENSE QUE NO ME INTERESABA SABER SOBRE EL BOX Y SUS CAMPEONES...PERO ME CAUTIVO Y LO LEI HASTA EL FINAL !AHORA SI PUEDO
DISCUTIR DE BOX CON MI ESPOSO Y MIS CUÑADOS...¡Y HASTA CON MI SUEGRO, QUE ES EX BOXEADOR !
```

Interprétation :

- Cela représente environ **0,32 %** du corpus.
- Les caractères concernés proviennent principalement :
  - d'emojis ponctuels,
  - de caractères typographiques spécifiquement anglais (guillemets courbes),
  - ou d'accents issus d'autres langues que l'anglais comme 'ñ' ou le point d'exclamation inversé '¡' en espagnol

Conséquence pour le preprocessing :

Comme ces caractères peuvent perturber la tokenisation et la vectorisation (TF-IDF), ils peuvent être soit normalisés, soit supprimés selon la stratégie choisie.

Mais l'impact global reste très faible dans le cadre de notre dataset et la présence de ces symboles peut être considérée comme non problématique et ne pas justifier d'intervention particulière.

5.3 Détection automatique de la langue

On vient de s'apercevoir que certaines reviews sont écrites en espagnol. Afin de vérifier que l'ensemble du corpus est bien exploitable en anglais, une détection automatique des langues présentes a donc été réalisée sur un échantillon de 50 000 reviews.

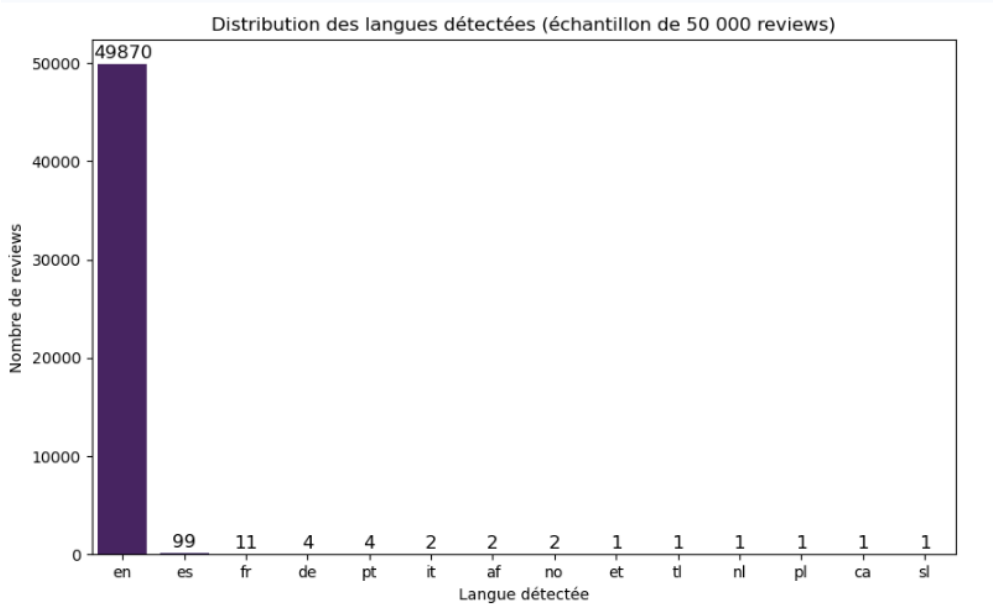

Le dataset Amazon Reviews Polarity est donc probablement presque entièrement anglophone : plus de 49 870 avis sont détectés en anglais, soit plus de 99 % de l'échantillon. Les autres langues (espagnol, français, allemand, portugais, italien, etc.) sont très minoritaires.

Bien que rien ne garantit que notre échantillon de 50 000 reviews soit représentatif, on sait que cette proportion sera très faible à l'échelle du dataset entier et qu'elle n'aurait donc qu'un impact limité sur la modélisation. Mais nous choisirons par cohérence d'éliminer les avis non anglophones lors du pré-

processing final. Cela garantit que les modèles supervisés comme les modèles transformer seront entraînés sur un corpus homogène et linguistiquement pertinent.

5.4 Ponctuation suspecte

Une détection basée sur une expression régulière identifiant les répétitions de ponctuation (trois occurrences ou plus) a permis de recenser ce phénomène dans le corpus. L'analyse révèle plus de 560 000 avis contenant une ponctuation répétée ou exagérée, du type "!!!", "???", "..." ou toute autre répétitions de symboles

```
Nombre de reviews avec ponctuations suspectes : 562550
```

	text
124	This cereal is so sweet....yet so good for you! One taste=ADDICTION!!!! I just tried this cereal out of curiousity and I was hooked! It is an excellent breakfast choice, or just any time to eat! Especially as breakfast because you will crave more honey taste and you won't be hungry later {probably because of how much you'd eat} and it is actually sweeter and better than Honey Bunches of Oats. Cap'n Crunch Berries is an option, but this splendid cereal is SO FILLED WITH A HONEY-FILLED TASTE! I have not tried much better tasting cereal than this! Oh!
125	This cereal is great because it tastes so good. You just crave it. But a word of warning: read the label. Last time my husband and I looked, it had saturated fat! All the other cereals in our cabinet did not... hmmmm. Another reviewer noticed this problem too!Also, Amazon's price of $23 is outrageous. It is between $1.99 to $2.50 in our stores.

Ce type de motif peut indiquer :

- ➔ une écriture très émotionnelle,
- ➔ un avis spam ou automatisé,
- ➔ une qualité rédactionnelle plus faible.

Ce phénomène est très courant dans les avis clients : les utilisateurs amplifient leur émotion via la ponctuation répétée. Ce n'est pas un signal de spam automatisé mais plutôt un signal émotionnel fort, fréquemment présent soit dans les avis très négatifs ("worst ever!!!"), soit dans les avis très enthousiastes ("amazing product!!!").

Les résultats montrent qu'environ 15 % des avis présentent une ponctuation amplifiée, un taux relativement élevé mais cohérent avec la nature du dataset : les avis Amazon Polarity sont souvent expressifs et rédigés dans un contexte émotionnel fort, ce qui favorise l'usage accru de "!" ou "?".

Ce comportement ne constitue donc pas un signal de spam, mais plutôt une caractéristique naturelle du langage utilisateur. Une normalisation de la ponctuation pourra toutefois être envisagée lors du pré-processing afin d'homogénéiser le texte avant vectorisation.

Conséquence pour le preprocessing :

Selon le modèle utilisé :

- pour TF-IDF : ponctuation supprimée car elle ne porte pas d'information textuelle utile
- pour des modèles avancés (Transformers), l'impact est minime mais une normalisation reste bénéfique.

5.5 Reviews trop courtes

Pour identifier les avis peu informatifs ou potentiellement bruités, nous avons calculé le nombre de mots de chaque review. Les avis contenant 3 mots ou moins ont été considérés comme trop courts pour apporter une information utile à la modélisation. Le résultat montre que ce cas est extrêmement rare : seulement 34 avis sur 3,6 millions (≈ 0,001 %) entrent dans cette catégorie.

L'examen manuel confirme que ces avis courts sont généralement :

- ➔ des expressions très brèves ("Good product", "Not worth it"),
- ➔ des réponses minimalistes,
- ➔ ou des textes longs mais sans espaces et sans aucun sens.

```
--- Exemple de review très courte ---

Great Purchase CKVKLJ;JNVKZ;KCVJJVK'ZJXC'VKLZXVMK'ZLXMCV'ZLKCV'LKZMX'LKVCCVCVCVCVCVCVCVCVC
```

Leur nombre étant négligeable, ces avis n'ont pas d'impact significatif sur la distribution générale du corpus. Ils seront toutefois supprimés lors du pré-processing, car leur faible contenu lexical limite leur intérêt pour l'apprentissage d'un modèle NLP.

5.6 Répétitions suspectes

Une autre source possible de bruit dans les avis provient de la répétition excessive d'un même mot, un phénomène parfois observé dans des messages peu soignés, automatisés ou fortement émotionnels. Pour détecter ce comportement, nous avons recherché les occurrences où un mot apparaît trois fois consécutivement ou plus (ex. : "good good good", "buy buy buy").

```
Nombre de reviews avec répétitions suspectes : 9979
```

	text
93	2 stars of 5 for this slow dull "classical" 1980's style movie. This movie has a young Jason Bateman in the lead. Very very very slow and dull with a few moments of bad 1980's style music. To our relief the background music (which is very annoying) is kept to a minimum. Though it attempts to be an action/suspense movie, it achieves neither. I'd suggest skipping this movie.
855	typically, I will force myself to read even the worst books (for class, for "fun", because I think I should), but when I read this book for a [...] English course, I quickly realized it was one of the worst books ever (not to be taken lightly, seriously), certainly not worthy of a classic, boring, endless details that no one cares about... blah blah blah. Terrible. I was bored. It might have been too difficult for a 9th grader, but I wouldn't read it now either.on the other hand, my brother loved it.
878	Yes, I am a 17 yr old high school kid. But I can tell good books from the bad ones. "The Scarlet Letter" is a "classical" tale of 2 lovers. To be concise, this novel is too wordy to be enjoyable. People can say it's a classic romantic novel, it has good character developments, it has good themes and ironies, blah blah blah. I, like most people, don't judge a book by checking out its trap metaphors; all in all leave this book to a "Doctor of Puritanical Philosophy". If youre looking for a more entertaining classic, read "Huck Finn" by Twain.
1070	A Charlie Brown Christmas. Does this REALLY need a review. Who doesn't love CB?? Whaa whaa whaa whhhaaaaaa. So glad I finally purchased this.
1312	I wanted to read this book because the simple life of the Amish people intrigued me.I wish this lady would have talked more about the Amish.Instead,all you read about is "Me,me,me"."What am I doing in my life?"Why do I do this/that?" blah blah blah.By the end of the book the reader really doesn't care anymore!It was scarey for me to find out that this woman is a therapist-YIKES!The reason I gave it 2 stars is that (1) When she does talk about the Amish it is interesting (2) It is a short book and a quick read.

L'analyse révèle qu' environ 9979 avis contiennent ce type de répétitions, soit un volume faible au regard des 3,6 millions d'avis du corpus. L'examen manuel montre que ces répétitions ne relèvent pas d'un comportement automatisé ou suspect, mais plutôt :

- d'un style emphatique fréquent dans les avis en ligne,
- de formulations orales transposées à l'écrit
- ou de tentatives d'insister sur un sentiment ("very very very good").

Ces occurrences ne constituent donc pas un bruit problématique. Elles pourront être conservées si l'objectif est de capturer l'intensité ou l'émotion du langage, ou normalisées (réduction à un seul mot) dans le pré-processing pour homogénéiser le texte avant vectorisation.

Dans le cadre de l'exploration, ces répétitions sont considérées comme tolérables et ne nécessitent pas d'intervention immédiate.

5.7 Synthèse de la qualité du corpus

L'ensemble des analyses montre que :

Le dataset est propre, avec très peu d'erreurs ou de formats anormaux. De plus, les rares anomalies (HTML, non ASCII, ponctuation) sont faciles à corriger. Enfin, les patterns émotionnels (ponctuation, répétitions) reflètent un comportement réel des utilisateurs.

Le corpus ne présente aucun biais structurel nécessitant un filtrage massif. La richesse linguistique observée garantit de très bonnes performances pour les modèles de NLP.

En conclusion :

La qualité générale du texte est excellente et permet d'aborder le preprocessing et la modélisation dans de très bonnes conditions.

6 Analyse textuelle exploratoire

L'objectif de cette section est de comprendre la structure lexicale des avis et d'identifier les éléments clés du corpus avant d'aller vers une modélisation plus poussée.
Nous allons procéder à plusieurs analyses : nettoyage minimal, wordclouds, fréquences lexicales, n-grams et étude des stopwords. Les analyses sont réalisées sur un échantillon représentatif du dataset pour des raisons de performance, tout en garantissant la fidélité des tendances observées.

Cette étape permet de confirmer la richesse sémantique du dataset et d'anticiper les choix de preprocessing pour la modélisation.

6.1 Nettoyage minimal (exploration)

Un pré-nettoyage léger est appliqué pour faciliter l'analyse exploratoire. Les opérations effectuées sont volontairement simples afin de ne pas altérer le contenu linguistique :

- ➔ passage du texte en minuscules,
- ➔ suppression des caractères non alphabétiques les plus courants,
- ➔ normalisation des espaces,
- ➔ maintien des mots tels quels (pas de lemmatisation ni suppression des stopwords à ce stade).

Ce nettoyage minimal permet d'obtenir une représentation plus lisible du corpus pour les analyses statistiques et visuelles sans engager encore le pipeline de pré-processing final.

Aperçu du résultat sur quelques lignes :

	text	clean_text
0	This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^	this sound track was beautiful it paints the senery in your mind so well i would recomend it even to people who hate vid game music i have played the game chrono cross but out of all of the games i have ever played it has the best music it backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras it would impress anyone who cares to listen
1	I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.	i'm reading a lot of reviews saying that this is the best 'game soundtrack' and i figured that i'd write a review to disagree a bit this in my opinino is yasunori mitsuda's ultimate masterpiece the music is timeless and i'm been listening to it for years now and its beauty simply refuses to fade the price tag on this is pretty staggering i must say but if you are going to buy any cd for this much money this is the only one that i feel would be worth every penny

6.2 Wordclouds

Les wordclouds offrent une première lecture intuitive de la tonalité générale du corpus et de ses thématiques dominantes. Trois worclouds ont été générés sur 3 périmètres de données différents :

- un échantillon aléatoire global de 1 million de lignes du corpus,
- un échantillon aléatoire de 1 million de lignes d'avis positifs,
- un échantillon aléatoire de 1 million de lignes d'avis négatifs.

Tous les avis au global

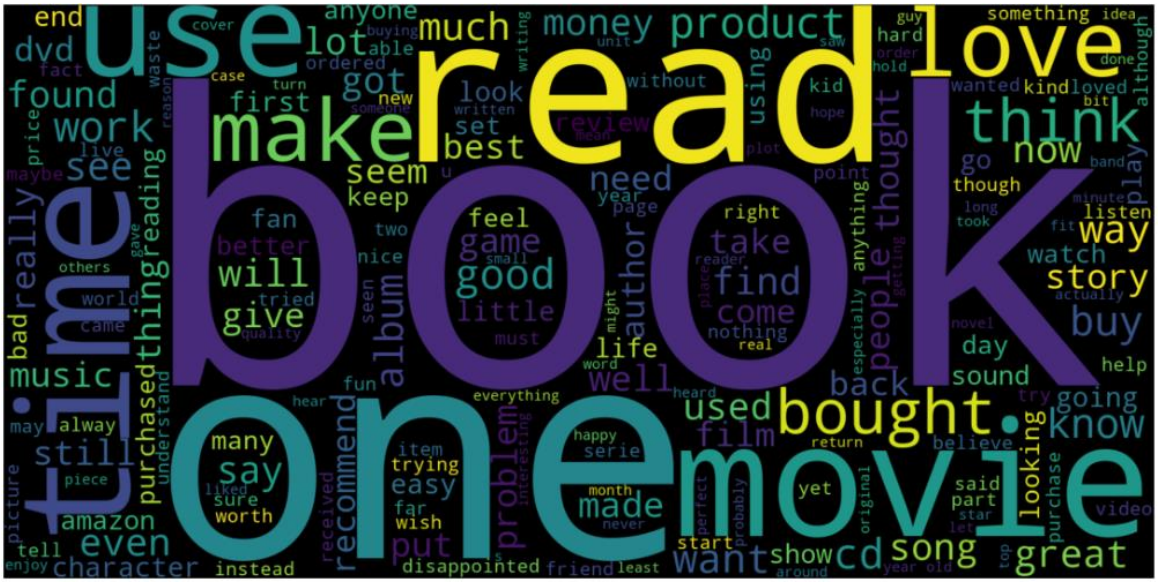

Le wordcloud global montre une dominance très nette des produits culturels ("book", "movie", "album", "dvd"). Le vocabulaire général reste simple et lié soit à la description du produit, soit à l'expérience d'usage ("read", "use", "buy", "time"). Cela confirme que le dataset, bien que étiqueté "reviews Amazon générales", est fortement orienté vers les catégories livres/films/musique.

Avis positifs seuls

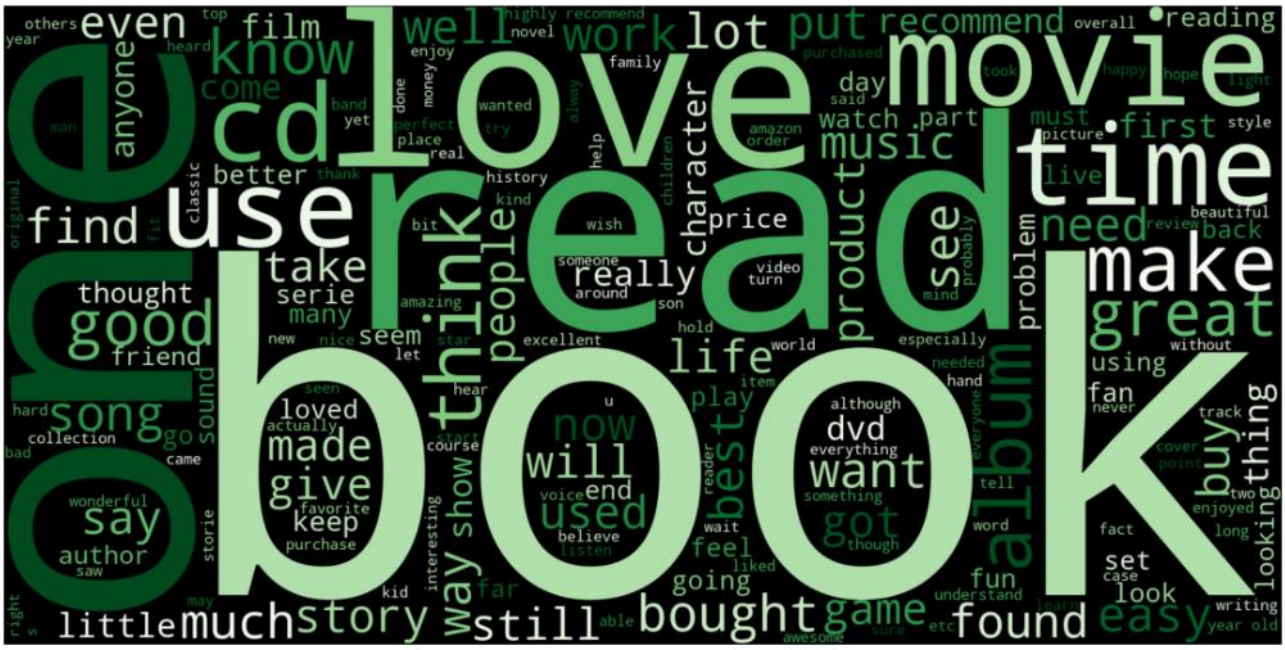

Dans les avis positifs, les termes qui ressortent le plus sont associés à l'appréciation ("love", "great", "good"), à la facilité d'usage ("easy"), et à une expérience utilisateur fluide ("well", "works"). On retrouve

aussi la dimension culturelle déjà observée (“book”, “read”, “movie”, “album”), mais sous un angle valorisant. Globalement, les avis positifs décrivent une satisfaction liée à la qualité, au confort d’utilisation et au plaisir ressenti.

Avis négatifs seuls

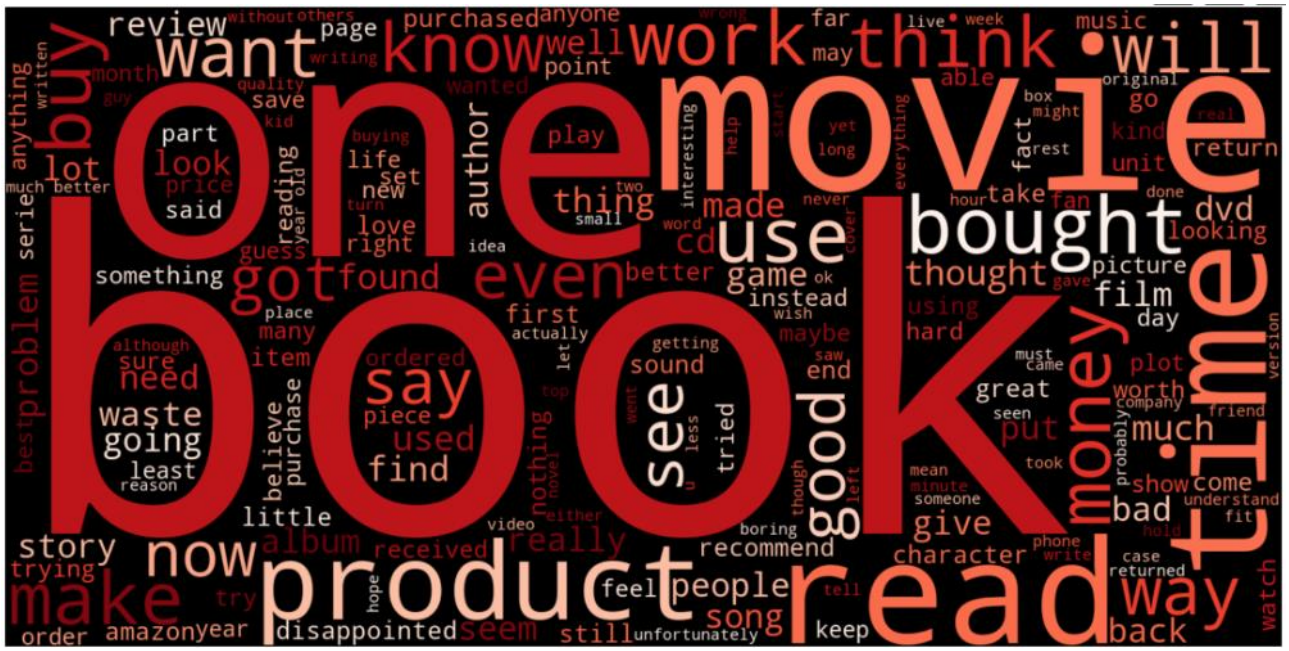

Les avis négatifs mettent davantage l’accent sur le regret ou la déception (“money”, “use”, “buy”, “work”, “time”). Les termes renvoient souvent à une valeur perçue insuffisante (“worth”, “waste”), à un produit qui fonctionne mal (“use”, “work”), ou à une expérience insatisfaisante (“bad”, “disappointed”). Le même univers culturel apparaît, mais accompagné d’un lexique plus critique.

Une structure thématique déjà observable

Dans l’ensemble, les trois word clouds révèlent une structure thématique déjà très marquée : forte présence de produits culturels, importance de l’usage réel du produit, et contraste très clair entre le registre valorisant des avis positifs et le registre critique des avis négatifs. Ces tendances guideront naturellement les futures étapes de classification sentimentale et d’extraction automatique de thèmes.

6.3 Fréquence des mots (sans stopwords)

L’analyse des fréquences montre une forte cohérence avec les observations des word clouds. Les mots book, one, like, good et read dominent largement le corpus global, confirmant la prépondérance des produits culturels dans le dataset.

Les trois barplots permettent de visualiser clairement ces différences lexicales entre sentiment global, positif et négatif.

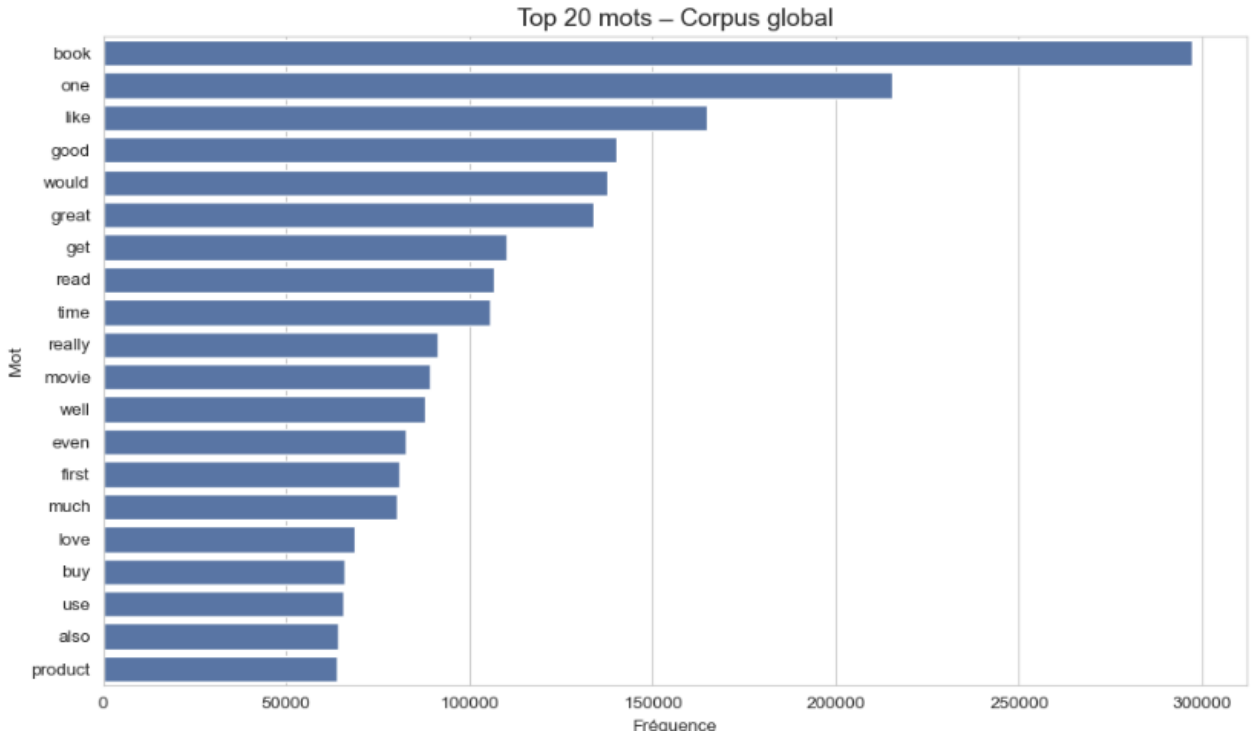
Top 20 mots – Corpus global
book
one
like
good
would
great
get
read
time
really
movie
well
even
first
much
love
buy
use
also
product
Mot
0
50000
100000
150000
200000
250000
300000
Fréquence

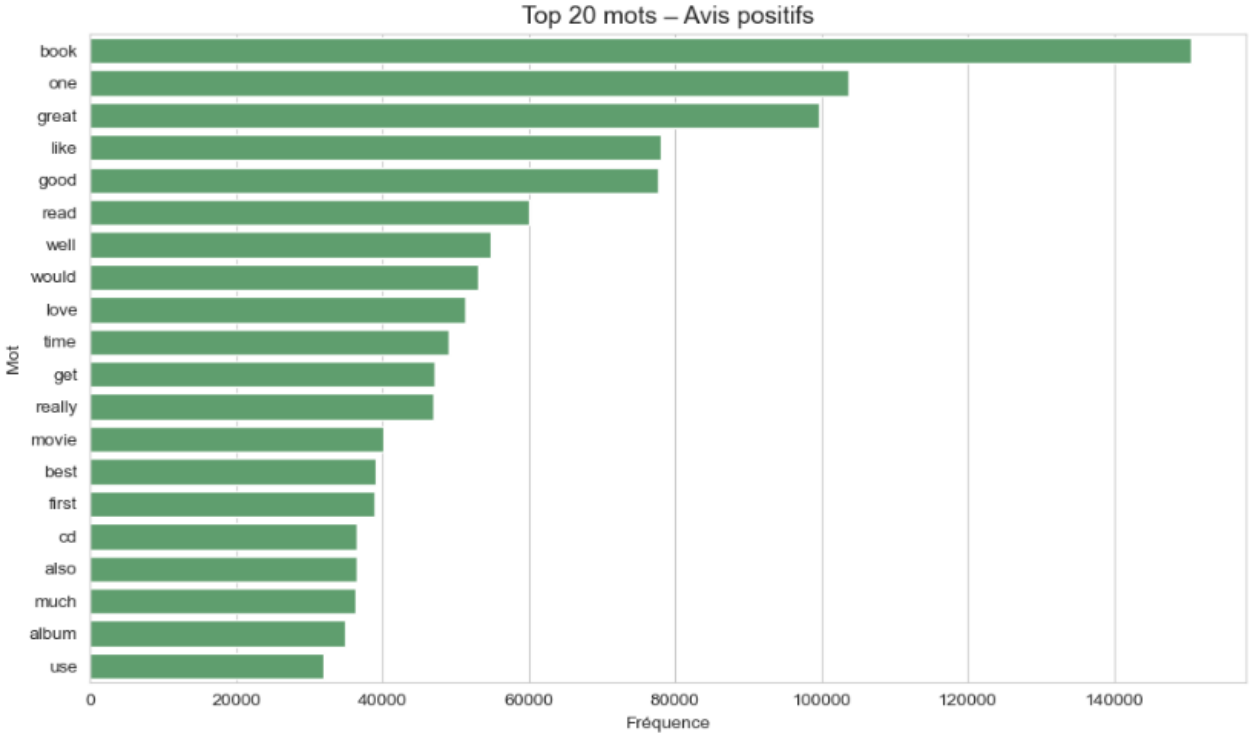
Top 20 mots – Avis positifs
book
one
great
like
good
read
well
would
love
time
get
really
movie
best
first
cd
also
much
album
use
Mot
0
20000
40000
60000
80000
100000
120000
140000
Fréquence

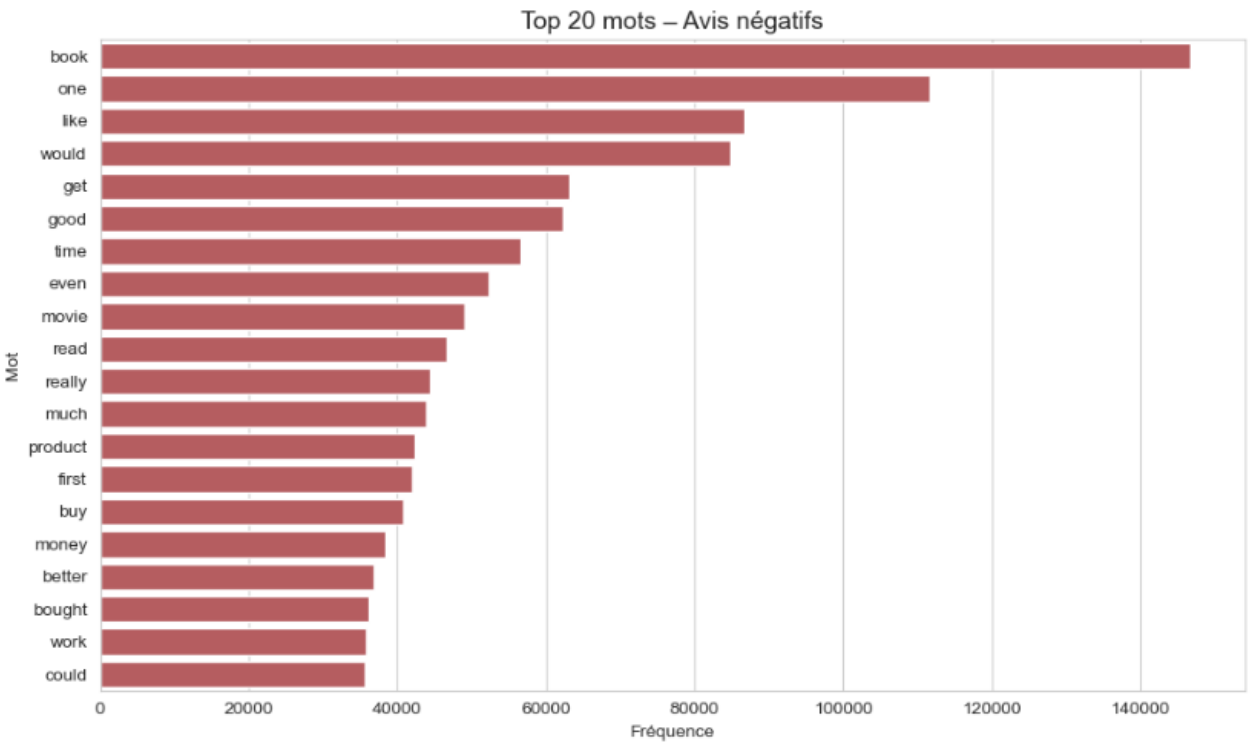

L'analyse des mots les plus fréquents, après suppression des stopwords anglais, met en évidence plusieurs éléments structurants :

- Le corpus est dominé par le vocabulaire lié aux produits culturels : *book*, *movie*, *read*, *album*.
- Certains verbes ou adjectifs fréquents (*like*, *good*, *great*, *really*) apparaissent dans les deux sentiments, mais avec des fréquences différentes.
- Les avis positifs contiennent davantage de termes valorisants (*great*, *best*, *love*).
- Les avis négatifs contiennent des termes plus critiques (*waste*, *poor*, *bad*, *return*, *didn't*).

6.4 N-grams

Pour mieux comprendre les expressions typiques des avis, des *n-grams* (séquences de mots) ont été extraits :

Bigrams (2 mots) les plus fréquents

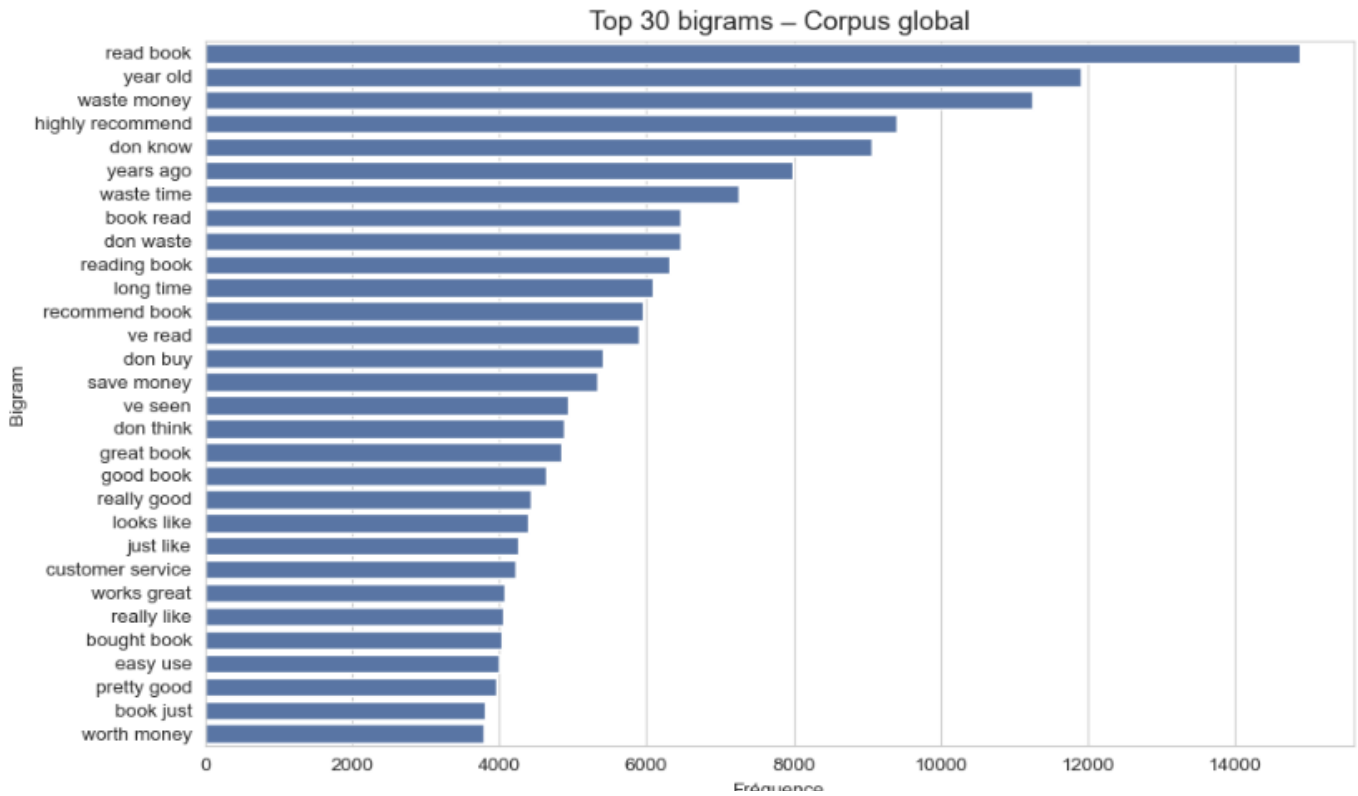

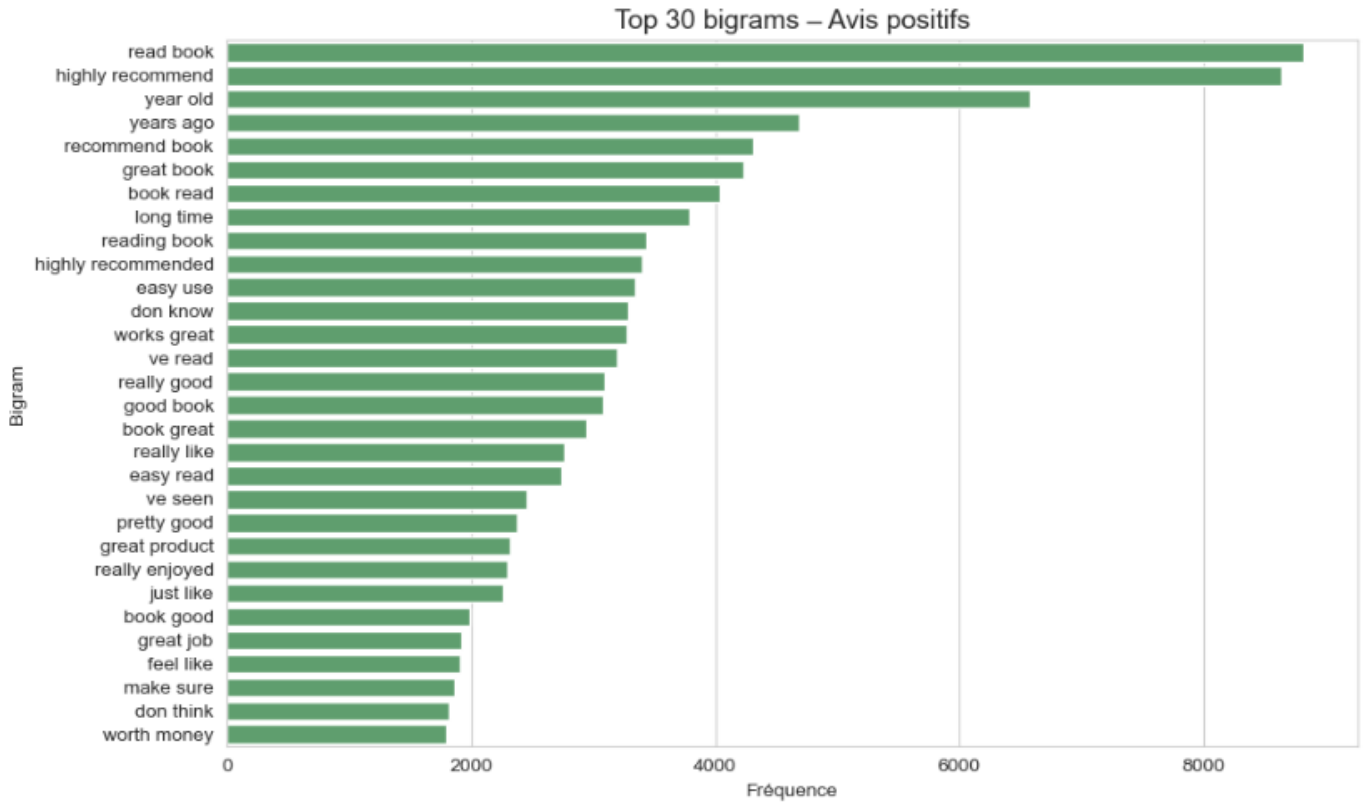

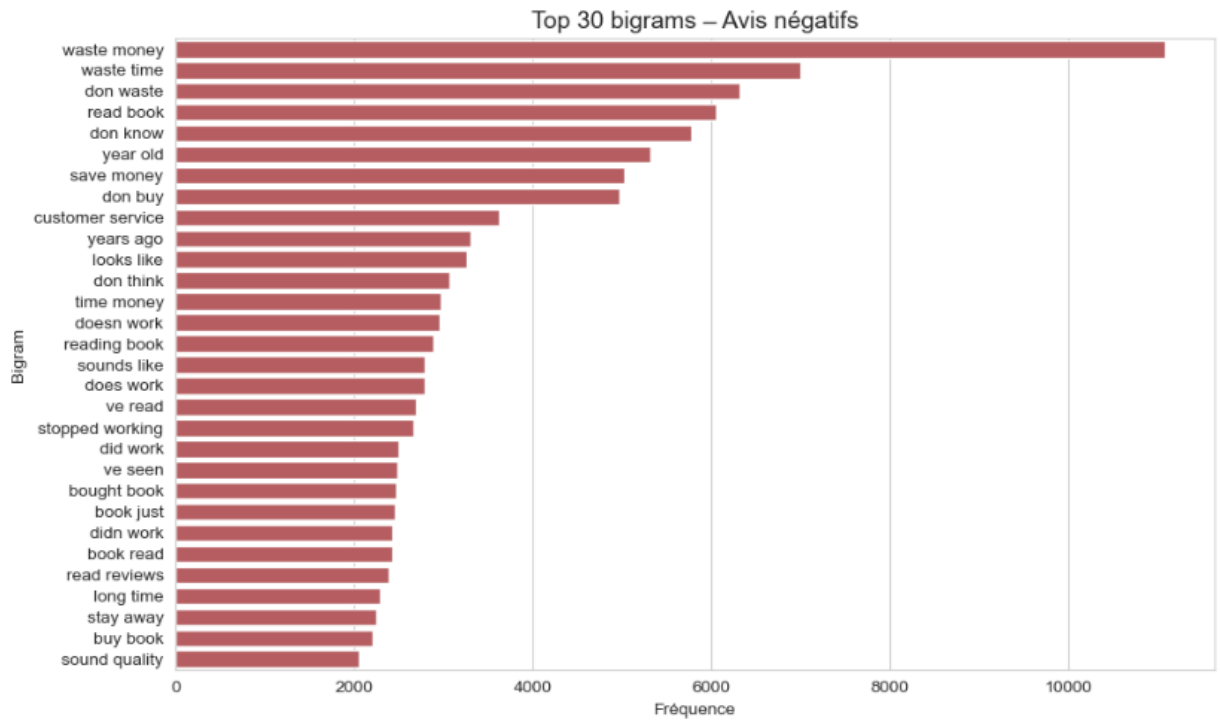

L'analyse des bigrams met en évidence des structures lexicales cohérentes avec celles observées dans les fréquences de mots simples :

Dans le corpus global, les associations les plus fréquentes — *read book*, *year old*, *waste money*, *highly recommend* — confirment la présence dominante des produits culturels, des avis liés aux usages familiaux et de thématiques autour du prix ou de la recommandation.

Dans les **avis positifs**, les bigrams reflètent clairement la satisfaction utilisateur : *highly recommend*, *great book*, *really good*, *works great*. Ils traduisent des retours enthousiastes sur la qualité perçue et la facilité d'usage.

À l'inverse, les **avis négatifs** sont structurés par des expressions marquant la frustration ou l'insatisfaction : *waste money*, *waste time*, *don't buy*, *doesn't work*, *customer service*. Ces formulations mettent en avant des problèmes de qualité, de fonctionnement ou de valeur perçue du produit.

De manière générale, les bigrams permettent déjà de distinguer clairement les registres lexicaux des avis positifs et négatifs, ce qui sera utile pour la modélisation du sentiment et l'analyse thématique.

Trigrams (3 mots) les plus fréquents

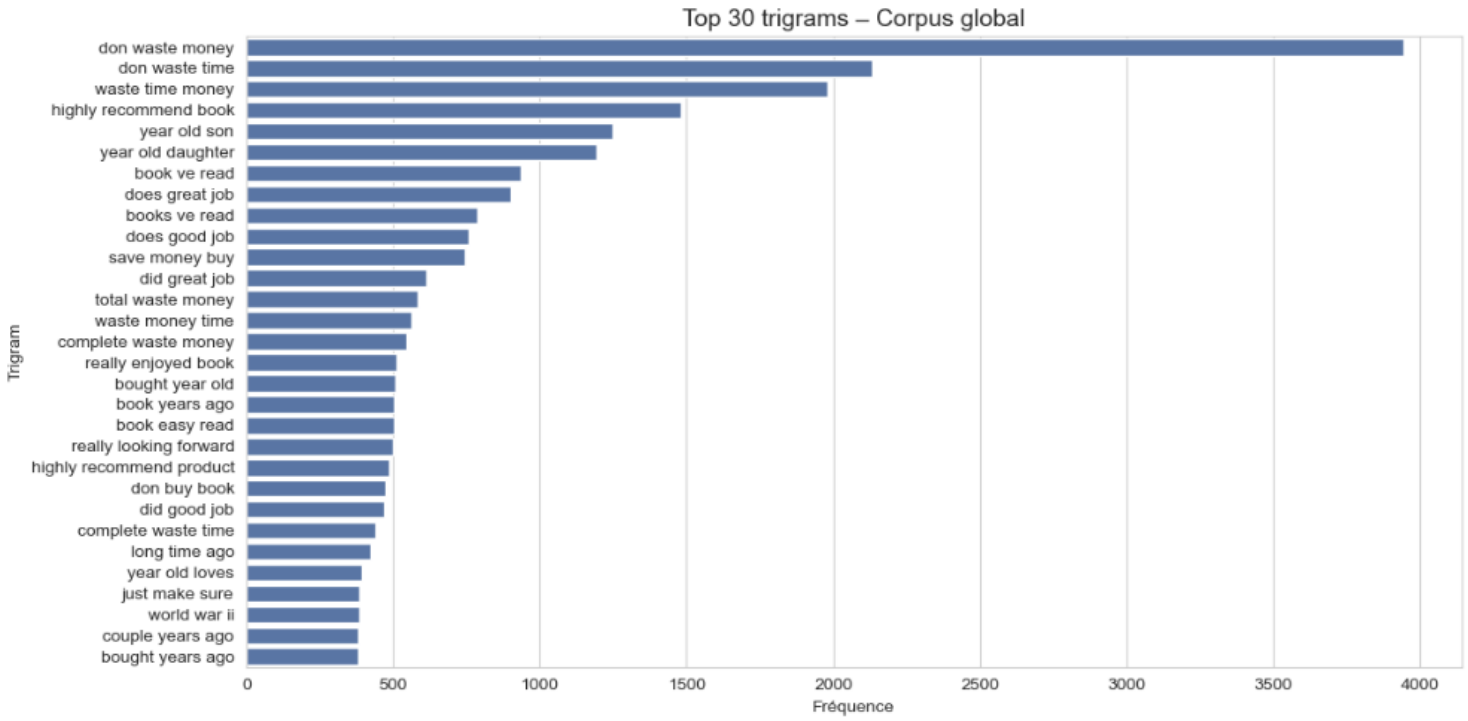

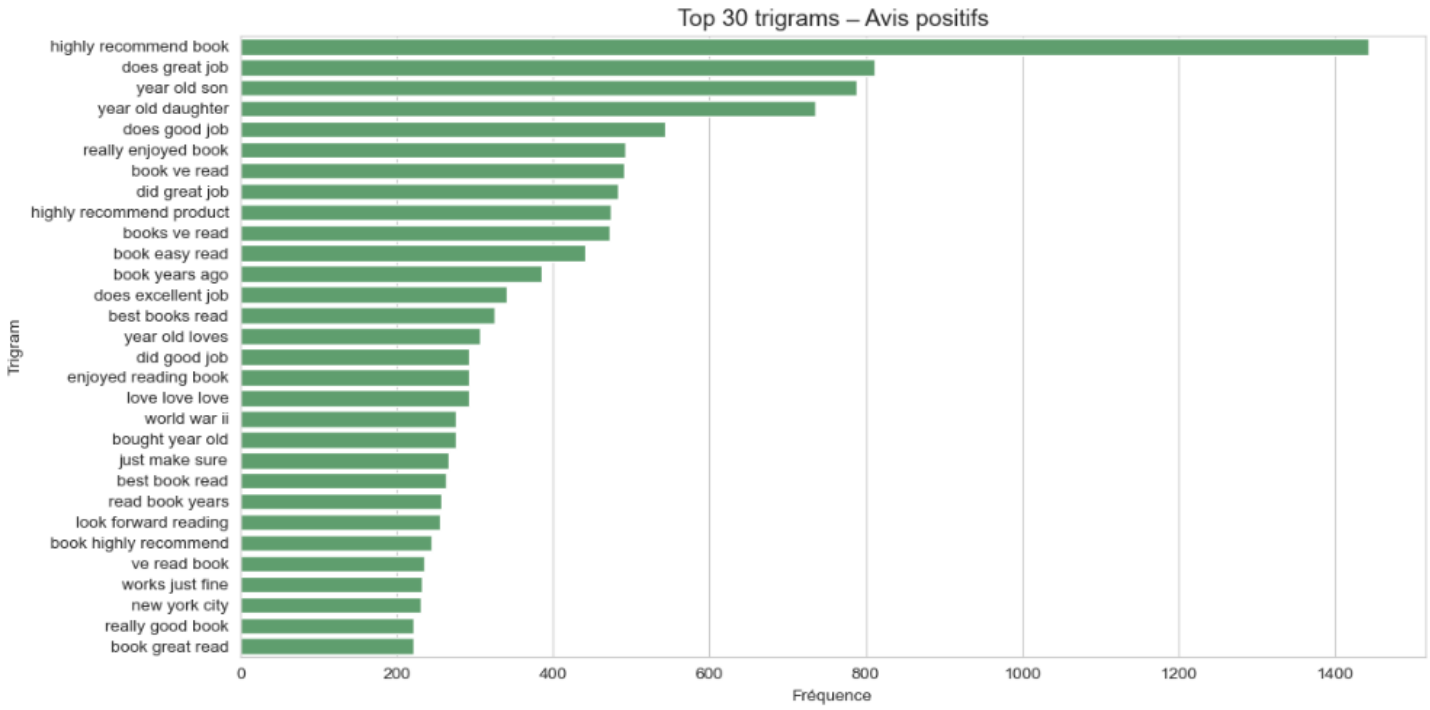

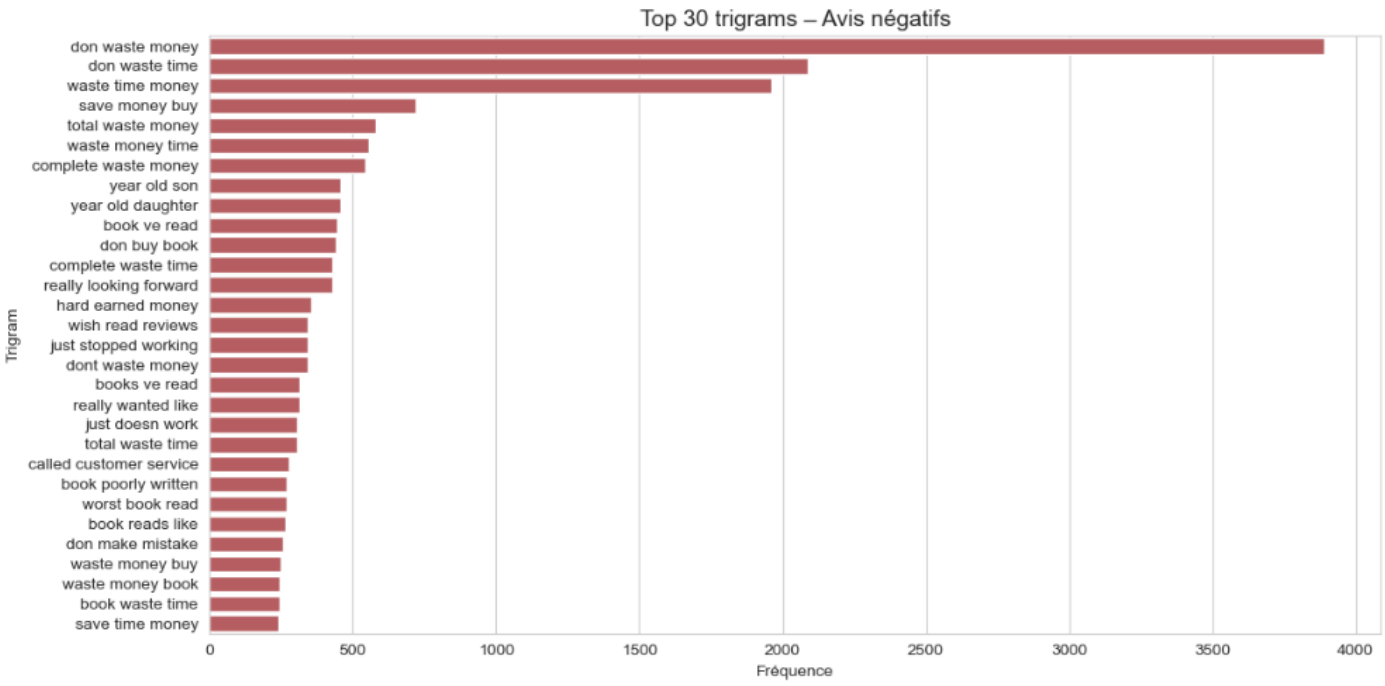

Les trigrams confirment très nettement les tendances observées avec les bigrams.

Dans le **corpus globa**l, plusieurs expressions récurrentes se démarquent : don't waste money, don't waste time, year old son/daughter, ainsi que des formulations de recommandation comme highly recommend book. Cela reflète à la fois la présence de retours d'expérience familiaux et l'importance du rapport qualité/prix.

Les **avis positifs** sont caractérisés par des trigrams à forte connotation qualitative : highly recommend book, does great job, really enjoyed book. Ces expressions traduisent explicitement la satisfaction des utilisateurs, notamment pour les produits culturels (livres, films, albums).

À l'inverse, les **avis négatifs** sont dominés par des expressions marquant la perte de valeur ou des dysfonctionnements, telles que don't waste money, complete waste time, just doesn't work ou encore called customer service. Ces formulations révèlent des motifs fréquents d'insatisfaction : mauvaise qualité perçue, défauts techniques, ou déception lors de l'achat.
Dans l'ensemble, les trigrams mettent en évidence des patterns lexicaux très structurés et cohérents selon la polarité, ce qui confirmera leur utilité dans la modélisation du sentiment et dans la future extraction des thématiques.

6.5 Analyse des stopwords

Les stopwords (mots très fréquents tels que *the*, *and*, *is*, *to*) représentent une grande partie des tokens du corpus, mais apportent peu d'information sémantique pour l'analyse de sujet ou la classification.

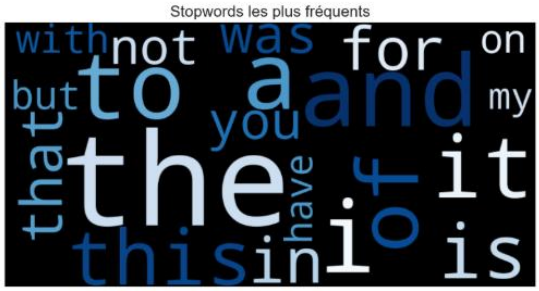

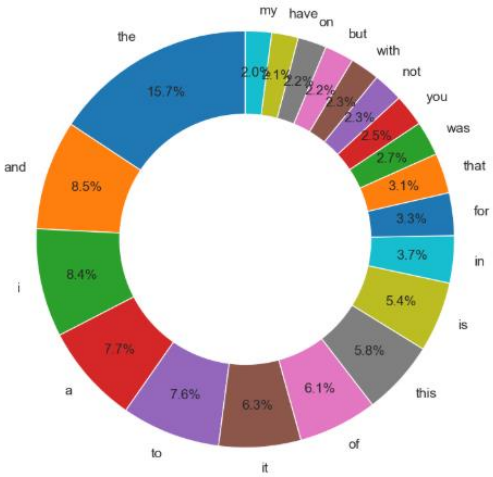

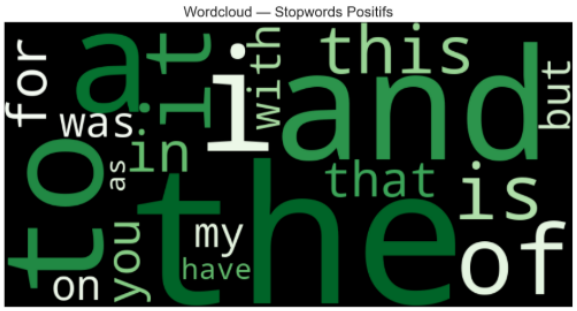

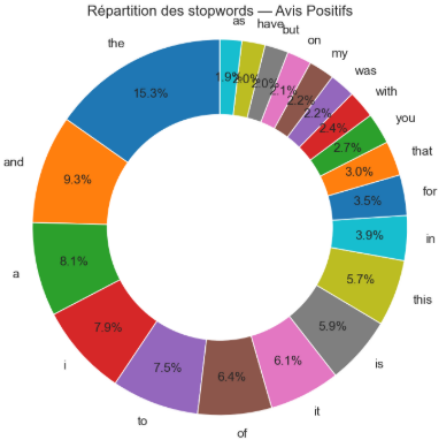

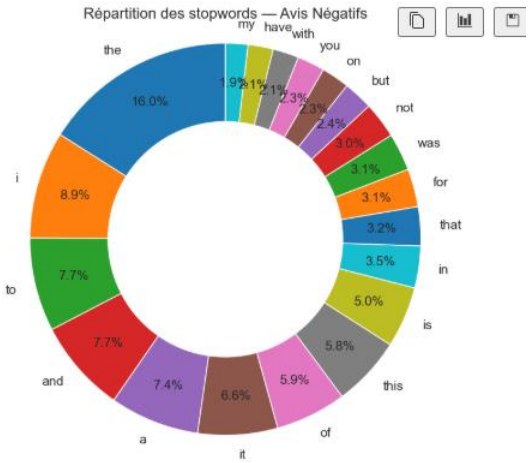

L’analyse montre que :

- les stopwords sont extrêmement fréquents (ce qui est normal en anglais),
- leur répartition est similaire entre avis positifs et négatifs,
- ils n’aident pas à discriminer les sentiments.

Ils seront donc supprimés lors du pré-processing final afin de réduire la dimensionnalité, de renforcer l’importance des mots porteurs de sens et d’améliorer la qualité des représentations vectorielles (TF-IDF ou embeddings).

7 Pré-processing envisagé pour la modélisation

L'objectif du pré-processing est d'obtenir une représentation textuelle propre, cohérente et exploitable par les modèles de Machine Learning. Contrairement au nettoyage minimal utilisé pour l'exploration, cette étape vise à standardiser les avis, éliminer le bruit et préparer la création de features robustes (TF-IDF, embeddings).

Les opérations décrites ci-dessous ne sont pas encore implémentées : elles constituent la feuille de route de préparation des données qui sera appliquée dans la partie Modélisation. L'objectif du pré-processing est de préparer les avis pour les modèles de Machine Learning.

Deux familles de modèles seront explorées dans la phase de modélisation :

1. Modèles classiques basés sur TF-IDF (Logistic Régression, SVM, Random Forest)

Ces modèles nécessitent un pré-processing structurant, incluant :

- normalisation des textes,
- suppression de la ponctuation et des stopwords,
- tokenisation classique,
- lemmatisation,
- construction d'un vocabulaire optimisé.

2. Modèles de type Transformer (DistilBERT, BERT-base)

Ces modèles pré-entraînés possèdent leur propre tokenizer (WordPiece) et requièrent au contraire un pré-processing léger, qui conserve presque toute la structure linguistique du texte. Les sous-sections 7.1 à 7.5 décrivent le pipeline conçu pour les modèles traditionnels (TF-IDF), tandis que la section 8 présente les implémentations effectives, dont une variante adaptée à BERT.

7.1 Concaténation du titre avec la review

Dans de nombreux avis clients, on remarque que le titre constitue un résumé explicite du ressenti de l'utilisateur. Il condense souvent l'opinion générale en quelques mots (« Excellent product », « Very disappointing », « Not worth it »), alors que le texte complet développe les arguments. Ignorer le titre reviendrait donc à se priver d'un signal informatif court, direct et souvent fortement corrélé au sentiment exprimé.

Pour enrichir le contenu analysé par les modèles NLP, le titre peut être concaténé avec le texte de la review. Cette fusion permet de renforcer le signal utile pour la classification, de capturer des mots-clés présents dans le titre mais aussi de mieux gérer les reviews très courtes dont le sentiment peut parfois être exprimé uniquement dans le titre. Enfin, cela stabilise les représentations TF-IDF, qui bénéficient de cette information additionnelle.

7.2 Normalisation du texte

La première étape consiste à uniformiser le format des avis afin de réduire la variabilité inutile :

- passage en minuscules,
- suppression des caractères non pertinents (ponctuation excessive, symboles isolés),
- normalisation des espaces.

Ces transformations permettent d'éviter que des variantes superficielles ("Good", "good", "good!") soient traitées comme des mots différents.

7.3 Tokenisation

Les textes seront découpés en unités linguistiques ("tokens"), généralement des mots. La tokenisation est une étape clé car elle conditionne :

- la création du vocabulaire,
- la fréquence des termes,
- la qualité de la future vectorisation.

Nous utiliserons une tokenisation simple au début (méthode du *WordTokenizer* ou split standard), puis une tokenisation plus avancée si nous testons un modèle transformer (tokenizer type BERT/CamemBERT).

7.4 Stopwords

Les stopwords anglais (the, and, is, etc.) représentent une grande partie du corpus mais n'apportent pas d'information utile pour analyser le sentiment ou les thématiques.

Leur suppression permet :

- de réduire la dimensionnalité,
- d'augmenter le poids relatif des mots informatifs,
- d'améliorer la lisibilité des n-grams et des représentations vectorielles.

Comme observé dans la section 6.5, les stopwords dominent largement le texte, ce qui rend cette étape indispensable.

7.5 Lemmatisation (optionnel)

La lemmatisation consiste à ramener un mot à sa forme canonique (ex. : "running" → "run").
Elle permet :

- de regrouper différentes formes d'un même mot,
- de réduire la taille du vocabulaire,
- de stabiliser les features.

Cette étape sera évaluée au moment de la modélisation.
Elle est utile pour TF-IDF ou Bag-of-Words, mais moins essentiell**e** pour les modèles transformer, qui gèrent intrinsèquement les variations morphologiques.

7.6 Construction des features

Le texte ne peut pas être utilisé directement par les modèles : il doit être transformé en représentations numériques. Plusieurs approches seront testées :

• TF-IDF (baseline solide)

Adapté aux modèles classiques (LogReg, SVM, RandomForest).
Il offre une bonne balance entre performance et interprétabilité.

• Embeddings pré-entraînés (Word2Vec, GloVe)

Utile pour capter la sémantique, mais nécessite un entraînement supplémentaire pour atteindre de bonnes performances sur un corpus spécifique.

• Transformers (BERT / DistilBERT)

Modèles modernes offrant un niveau d'expressivité beaucoup plus élevé.
Ils permettent d'atteindre de meilleures performances sur la classification et seront envisagés en phase avancée du projet.

Ces représentations vectorielles serviront à la fois à la classification de sentiment et à l'extraction thématique via clustering.

8 Pré-processing (implémentation réelle)

L'objectif est d'appliquer au corpus les transformations prévues en vue de la modélisation.

8.1 Filtrage des reviews non anglaises

Lors de la phase d'exploration, une détection automatique de la langue a été réalisée sur un échantillon de 50 000 avis à l'aide de la bibliothèque langdetect. Cette analyse a confirmé que le dataset est très largement anglophone.

Cependant, langdetect est beaucoup trop coûteux pour être appliqué sur l'intégralité des 3,6 millions de reviews. Pour le pré-processing final, une méthode bien plus rapide a donc été adoptée : une heuristique inspirée de looks_english.

Le principe repose sur une idée simple : un texte réellement anglais présente une forte proportion de lettres ASCII (a–z) et contient un noyau de mots fréquents de la langue anglaise. En combinant ces deux signaux (ratio de lettres et ratio de mots anglais), on obtient une détection suffisamment fiable tout en restant extrêmement rapide, ce qui permet de traiter plusieurs millions d'avis en quelques minutes.

Cette approche se rapproche du comportement de langdetect sans en avoir le coût en temps de calcul. Elle permet d'éliminer les avis réellement non anglophones tout en conservant les textes exploitables pour l'apprentissage.

Répartition des reviews non anglaises / non anglaises :

Avant filtrage

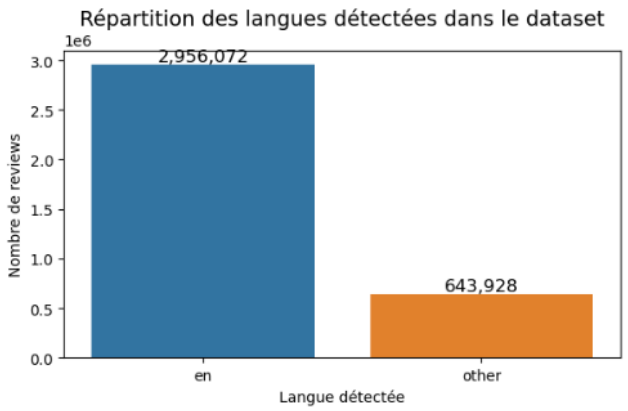

Après Filtrage

17% du corpus a été ainsi supprimé, ce qui est une proportion bien supérieure à celle qui avait été détectée par langdetect sur l'échantillon. On s'y attendait car "looks_english" étant une méthode plus grossière que langdetect, elle supprime inévitablement des avis anglophones. Mais c'était le prix à payer pour être certain d'avoir 100% d'avis en anglais et comme on a une grosse volumétrie dans notre dataset, on a estimé qu'on pouvait se le permettre.

Le résultat, c'est que le filtrage ainsi obtenu produit un corpus final homogène et cohérent pour l'entraînement de modèles NLP en anglais.

8.2 Concaténation du titre et la review

Comme déjà évoqué lors de l'exploration, avant d'appliquer les transformations de nettoyage, la première étape du pré-processing consiste à enrichir le contenu textuel en fusionnant le titre et la review au sein de la colonne text. Cette opération est visible sur les premières lignes du dataset : la colonne 'text' contient désormais le titre suivi du contenu complet de l'avis.
L'intérêt de cette concaténation apparaît immédiatement dans l'inspection du head : certains titres expriment clairement le sentiment ou introduisent des mots-clés importants qui auraient été absents du texte seul. Leur intégration renforce donc la qualité du signal linguistique transmis au modèle.

Voici le dataset une fois la concaténation effectuée :

sentiment	title	text
2	Stuning even for the non-gamer	Stuning even for the non-gamer This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^
2	The best soundtrack ever to anything.	The best soundtrack ever to anything. I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.
2	Amazing!	Amazing! This soundtrack is my favorite music of all time, hands down. The intense sadness of "Prisoners of Fate" (which means all the more if you've played the game) and the hope in "A Distant Promise" and "Girl who Stole the Star" have been an important inspiration to me personally throughout my teen years. The higher energy tracks like "Chrono Cross ~ Time's Scar~", "Time of the Dreamwatch", and "Chronomantique" (indefinably remeniscent of Chrono Trigger) are all absolutely superb as well.This soundtrack is amazing music, probably the best of this composer's work (I haven't heard the Xenogears soundtrack, so I can't say for sure), and even if you've never played the game, it would be worth twice the price to buy it.I wish I could give it 6 stars.
2	Excellent Soundtrack	Excellent Soundtrack I truly like this soundtrack and I enjoy video game music. I have played this game and most of the music on here I enjoy and it's truly relaxing and peaceful.On disk one. my favorites are Scars Of Time, Between Life and Death, Forest Of Illusion, Fortress of Ancient Dragons, Lost Fragment, and Drowned Valley.Disk Two: The Draggons, Galdorb - Home, Chronomantique, Prisoners of Fate, Gale, and my girlfriend likes ZelbessDisk Three: The best of the three. Garden Of God, Chronopolis, Fates, Jellyfish sea, Burning Orphange, Dragon's Prayer, Tower Of Stars, Dragon God, and Radical Dreamers - Unstealable Jewel.Overall, this is a excellent soundtrack and should be brought by those that like video game music.Xander Cross
2	Remember, Pull Your Jaw Off The Floor After Hearing it	Remember, Pull Your Jaw Off The Floor After Hearing it If you've played the game, you know how divine the music is! Every single song tells a story of the game, it's that good! The greatest songs are without a doubt, Chrono Cross: Time's Scar, Magical Dreamers: The Wind, The Stars, and the Sea and Radical Dreamers: Unstolen Jewel. (Translation varies) This music is perfect if you ask me, the best it can be. Yasunori Mitsuda just poured his heart on and wrote it down on paper.

8.3 Nettoyage du texte

On peut commencer à procéder au nettoyage de la variable 'text' qui contient maintenant toute l'information utile.

8.3.1 Passage en minuscules

L'ensemble du texte a été converti en minuscules. Cette étape permet :

- d'harmoniser les formes,
- d'éviter que TF-IDF considère "Good" et "good" comme deux tokens différents,
- de réduire légèrement la dimensionnalité.

8.3.2 Suppression de la ponctuation

Toute la ponctuation non informative a été supprimée, notamment : , . ! ? : ; ( ) [ ]
L'objectif est d'éliminer les artefacts sans modifier les mots significatifs.
Certains caractères (comme l'apostrophe dans don't) ont été préservés au besoin pour éviter de couper des mots importants pour l'analyse de sentiment.

8.3.3 Normalisation des espaces et nettoyage général

Plusieurs opérations ont été réalisées :

- ➔ suppression des doublons d'espaces
- ➔ suppression des espaces en début/fin
- ➔ remplacement des caractères spéciaux par des espaces
- ➔ suppression des caractères non alphabétiques

8.3.4 Suppression des caractères non ASCII

Les emojis, symboles typographiques ou caractères incompatibles ont été supprimés ou remplacés par des espaces. Cette étape limite les erreurs de tokenisation et facilite la vectorisation (TF-IDF ou modèles classiques).

On peut voir la transformation des reviews après cette étape de nettoyage en regardant le contenu des avis avant (colonne text) et après traitement (colonne clean_text) :

sentiment	title	text	clean_text
2	Stuning even for the non-gamer	Stuning even for the non-gamer This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^	stuning even for the non gamer this sound track was beautiful it paints the senery in your mind so well i would recomend it even to people who hate vid game music i have played the game chrono cross but out of all of the games i have ever played it has the best music it backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras it would impress anyone who cares to listen
2	The best soundtrack ever to anything.	The best soundtrack ever to anything. I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.	the best soundtrack ever to anything i'm reading a lot of reviews saying that this is the best 'game soundtrack' and i figured that i'd write a review to disagree a bit this in my opinino is yasunori mitsuda's ultimate masterpiece the music is timeless and i'm been listening to it for years now and its beauty simply refuses to fade the price tag on this is pretty staggering i must say but if you are going to buy any cd for this much money this is the only one that i feel would be worth every penny
2	Amazing!	Amazing! This soundtrack is my favorite music of all time, hands down. The intense sadness of "Prisoners of Fate" (which means all the more if you've played the game) and the hope in "A Distant Promise" and "Girl who Stole the Star" have been an important inspiration to me personally throughout my teen years. The higher energy tracks like "Chrono Cross ~ Time's Scar~", "Time of the Dreamwatch", and "Chronomantique" (indefinably remeniscent of Chrono Trigger) are all absolutely superb as well.This soundtrack is amazing music, probably the best of this composer's work (I haven't heard the Xenogears soundtrack, so I can't say for sure), and even if you've never played the game, it would be worth twice the price to buy it.I wish I could give it 6 stars.	amazing this soundtrack is my favorite music of all time hands down the intense sadness of prisoners of fate which means all the more if you've played the game and the hope in a distant promise and girl who stole the star have been an important inspiration to me personally throughout my teen years the higher energy tracks like chrono cross time's scar time of the dreamwatch and chronomantique indefinably remeniscent of chrono trigger are all absolutely superb as well this soundtrack is amazing music probably the best of this composer's work i haven't heard the xenogears soundtrack so i can't say for sure and even if you've never played the game it would be worth twice the price to buy it i wish i could give it stars

8.4 Suppression des stopwords

Les stopwords anglais (ex : the, and, to, it, this, you…) ont été filtrés car ils n'apportent aucune information utile, ni pour la classification du sentiment, ni pour le clustering thématique,

Leur suppression permet de réduire la dimensionnalité et d'augmenter le signal discriminant dans les modèles supervisés.

sentiment	title	text	clean_text
2	Stuning even for the non-gamer	Stuning even for the non-gamer This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^	stuning even non gamer sound track beautiful paints senery mind well would recomend even people hate vid game music played game chrono cross games ever played best music backs away crude keyboarding takes fresher step grate guitars soulful orchestras would impress anyone cares listen
2	The best soundtrack ever to anything.	The best soundtrack ever to anything. I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.	best soundtrack ever anything reading lot reviews saying best 'game soundtrack' figured write review disagree bit opinino yasunori mitsuda's ultimate masterpiece music timeless listening years beauty simply refuses fade price tag pretty staggering must say going buy cd much money one feel would worth every penny
2	Amazing!	Amazing! This soundtrack is my favorite music of all time, hands down. The intense sadness of "Prisoners of Fate" (which means all the more if you've played the game) and the hope in "A Distant Promise" and "Girl who Stole the Star" have been an important inspiration to me personally throughout my teen years. The higher energy tracks like "Chrono Cross ~ Time's Scar~", "Time of the Dreamwatch", and "Chronomantique" (indefinably remeniscent of Chrono Trigger) are all absolutely superb as well.This soundtrack is amazing music, probably the best of this composer's work (I haven't heard the Xenogears soundtrack, so I can't say for sure), and even if you've never played the game, it would be worth twice the price to buy it.I wish I could give it 6 stars.	amazing soundtrack favorite music time hands intense sadness prisoners fate means played game hope distant promise girl stole star important inspiration personally throughout teen years higher energy tracks like chrono cross time's scar time dreamwatch chronomantique indefinably remeniscent chrono trigger absolutely superb well soundtrack amazing music probably best composer's work heard xenogears soundtrack can't say sure even never played game would worth twice price buy wish could give stars

8.5 Lemmatisation

Une lemmatisation a été appliquée dans les pipelines utilisant TF-IDF.
Elle permet de ramener les mots à leur forme canonique (ex : *reading* → *read*). Cela limite l'explosion du vocabulaire et améliore la généralisation du classifieur en réduisant le bruit syntaxique.

La lemmatisation n'est pas utilisée pour les modèles Transformers, qui embarquent une compréhension morphologique intrinsèque.

	sentiment	title	text	clean_text
0	2	Stuning even for the non-gamer	Stuning even for the non-gamer This sound track was beautiful! It paints the senery in your mind so well I would recomend it even to people who hate vid. game music! I have played the game Chrono Cross but out of all of the games I have ever played it has the best music! It backs away from crude keyboarding and takes a fresher step with grate guitars and soulful orchestras. It would impress anyone who cares to listen! ^_^	stuning even non gamer sound track beautiful paint senery mind well would recomend even people hate vid game music played game chrono cross game ever played best music back away crude keyboarding take fresher step grate guitar soulful orchestra would impress anyone care listen
1	2	The best soundtrack ever to anything.	The best soundtrack ever to anything. I'm reading a lot of reviews saying that this is the best 'game soundtrack' and I figured that I'd write a review to disagree a bit. This in my opinino is Yasunori Mitsuda's ultimate masterpiece. The music is timeless and I'm been listening to it for years now and its beauty simply refuses to fade.The price tag on this is pretty staggering I must say, but if you are going to buy any cd for this much money, this is the only one that I feel would be worth every penny.	best soundtrack ever anything reading lot review saying best 'game soundtrack' figured write review disagree bit opinino yasunori mitsuda's ultimate masterpiece music timeless listening year beauty simply refuse fade price tag pretty staggering must say going buy cd much money one feel would worth every penny
2	2	Amazing!	Amazing! This soundtrack is my favorite music of all time, hands down. The intense sadness of "Prisoners of Fate" (which means all the more if you've played the game) and the hope in "A Distant Promise" and "Girl who Stole the Star" have been an important inspiration to me personally throughout my teen years. The higher energy tracks like "Chrono Cross ~ Time's Scar~", "Time of the Dreamwatch", and "Chronomantique" (indefinably remeniscent of Chrono Trigger) are all absolutely superb as well.This soundtrack is amazing music, probably the best of this composer's work (I haven't heard the Xenogears soundtrack, so I can't say for sure), and even if you've never played the game, it would be worth twice the price to buy it.I wish I could give it 6 stars.	amazing soundtrack favorite music time hand intense sadness prisoner fate mean played game hope distant promise girl stole star important inspiration personally throughout teen year higher energy track like chrono cross time's scar time dreamwatch chronomantique indefinably remeniscent chrono trigger absolutely superb well soundtrack amazing music probably best composer's work heard xenogears soundtrack can't say sure even never played game would worth twice price buy wish could give star

8.6 Tokenisation

Cette étape prépare les données aux différentes représentations vectorielles.

Les textes sont découpés en tokens selon la stratégie suivante :

- ➔ tokenisation simple (split + regex) pour les modèles TF-IDF,
- ➔ tokenisation WordPiece uniquement lors de l'utilisation de Transformers (DistilBERT ou équivalent).

Visualisons les tokens générés pour les premières reviews du dataset :

```
================================================================================
Review 0

Texte nettoyé :
stuning even non gamer sound track beautiful paint senery mind well would recomend even people hate vid game music played game chrono cross game ever
played best music back away crude keyboarding take fresher step grate guitar soulful orchestra would impress anyone care listen

Tokens générés :
['stuning', 'even', 'non', 'gamer', 'sound', 'track', 'beautiful', 'paint', 'senery', 'mind', 'well', 'would', 'recomend', 'even', 'people', 'hate',
'vid', 'game', 'music', 'played', 'game', 'chrono', 'cross', 'game', 'ever', 'played', 'best', 'music', 'back', 'away', 'crude', 'keyboarding', 'take',
'fresher', 'step', 'grate', 'guitar', 'soulful', 'orchestra', 'would', 'impress', 'anyone', 'care', 'listen']
================================================================================
================================================================================
Review 1

Texte nettoyé :
best soundtrack ever anything reading lot review saying best 'game soundtrack' figured write review disagree bit opinino yasunori mitsuda's ultimate
masterpiece music timeless listening year beauty simply refuse fade price tag pretty staggering must say going buy cd much money one feel would worth
every penny

Tokens générés :
['best', 'soundtrack', 'ever', 'anything', 'reading', 'lot', 'review', 'saying', 'best', 'game', 'soundtrack', 'figured', 'write', 'review', 'disagree',
'bit', 'opinino', 'yasunori', 'mitsuda', 'ultimate', 'masterpiece', 'music', 'timeless', 'listening', 'year', 'beauty', 'simply', 'refuse', 'fade',
'price', 'tag', 'pretty', 'staggering', 'must', 'say', 'going', 'buy', 'cd', 'much', 'money', 'one', 'feel', 'would', 'worth', 'every', 'penny']
================================================================================
================================================================================
Review 2

Texte nettoyé :
amazing soundtrack favorite music time hand intense sadness prisoner fate mean played game hope distant promise girl stole star important inspiration
personally throughout teen year higher energy track like chrono cross time's scar time dreamwatch chronomantique indefinably remeniscent chrono trigger
absolutely superb well soundtrack amazing music probably best composer's work heard xenogears soundtrack can't say sure even never played game would worth
twice price buy wish could give star

Tokens générés :
['amazing', 'soundtrack', 'favorite', 'music', 'time', 'hand', 'intense', 'sadness', 'prisoner', 'fate', 'mean', 'played', 'game', 'hope', 'distant',
'promise', 'girl', 'stole', 'star', 'important', 'inspiration', 'personally', 'throughout', 'teen', 'year', 'higher', 'energy', 'track', 'like', 'chrono',
'cross', 'time', 'scar', 'time', 'dreamwatch', 'chronomantique', 'indefinably', 'remeniscent', 'chrono', 'trigger', 'absolutely', 'superb', 'well',
'soundtrack', 'amazing', 'music', 'probably', 'best', 'composer', 'work', 'heard', 'xenogears', 'soundtrack', 'can', 'say', 'sure', 'even', 'never',
'played', 'game', 'would', 'worth', 'twice', 'price', 'buy', 'wish', 'could', 'give', 'star']
================================================================================
================================================================================
Review 3

Texte nettoyé :
excellent soundtrack truly like soundtrack enjoy video game music played game music enjoy truly relaxing peaceful disk one favorite scar time life death
forest illusion fortress ancient dragon lost fragment drowned valley disk two draggons galdorb home chronomantique prisoner fate gale girlfriend like
zelbessdisk three best three garden god chronopolis fate jellyfish sea burning orphange dragon's prayer tower star dragon god radical dreamer unstealable
jewel overall excellent soundtrack brought like video game music xander cross

Tokens générés :
['excellent', 'soundtrack', 'truly', 'like', 'soundtrack', 'enjoy', 'video', 'game', 'music', 'played', 'game', 'music', 'enjoy', 'truly', 'relaxing',
'peaceful', 'disk', 'one', 'favorite', 'scar', 'time', 'life', 'death', 'forest', 'illusion', 'fortress', 'ancient', 'dragon', 'lost', 'fragment',
'drowned', 'valley', 'disk', 'two', 'draggons', 'galdorb', 'home', 'chronomantique', 'prisoner', 'fate', 'gale', 'girlfriend', 'like', 'zelbessdisk',
'three', 'best', 'three', 'garden', 'god', 'chronopolis', 'fate', 'jellyfish', 'sea', 'burning', 'orphange', 'dragon', 'prayer', 'tower', 'star',
'dragon', 'god', 'radical', 'dreamer', 'unstealable', 'jewel', 'overall', 'excellent', 'soundtrack', 'brought', 'like', 'video', 'game', 'music',
'xander', 'cross']
================================================================================
```

```
==========================================================================
Review 4

Texte nettoyé :
remember pull jaw floor hearing played game know divine music every single song tell story game good greatest song without doubt chrono cross time's scar
magical dreamer wind star sea radical dreamer unstolen jewel translation varies music perfect ask best yasunori mitsuda poured heart wrote paper

Tokens générés :
['remember', 'pull', 'jaw', 'floor', 'hearing', 'played', 'game', 'know', 'divine', 'music', 'every', 'single', 'song', 'tell', 'story', 'game', 'good',
'greatest', 'song', 'without', 'doubt', 'chrono', 'cross', 'time', 'scar', 'magical', 'dreamer', 'wind', 'star', 'sea', 'radical', 'dreamer', 'unstolen',
'jewel', 'translation', 'varies', 'music', 'perfect', 'ask', 'best', 'yasunori', 'mitsuda', 'poured', 'heart', 'wrote', 'paper']
```

8.7 Construction des représentations vectorielles

Trois stratégies ont été mises en place selon les besoins des modèles :

1. TF-IDF (unigrammes + bigrammes)

Représentation classique pour :

- ➔ Logistic Regression
- ➔ SVM
- ➔ Random Forest / XGBoost

2. Embeddings classiques (moyenne de vecteurs)

Option utilisée pour :

- ➔ clustering
- ➔ interprétation lexicale
- ➔ modèles basés sur similarité

3. Embeddings avancés (Transformers)

Dans le cadre d'un modèle BERT-like :

- ➔ DistilBERT
- ➔ CamemBERT (pour données FR, non utilisé ici)

Ces embeddings capturent la sémantique profonde du texte.

Interprétation des vecteurs TF-IDF

Afin de vérifier que le pré-processing et la vectorisation TF-IDF produisent des représentations exploitables, quelques reviews ont été inspectées individuellement.
Pour chaque avis, on observe les *tokens* retenus par TF-IDF ainsi que leurs poids associés.

Cette visualisation permet de contrôler que :

- les stopwords ont bien été supprimés,
- la lemmatisation a été appliquée correctement,
- les bigrams pertinents sont détectés,

- les mots à forte valeur informative (ex. “poor quality”, “highly recommend”) ressortent bien dans les vecteurs.

Les extraits suivants présentent les 20 tokens les plus influents pour les 5 reviews précédentes, tels qu’ils sont utilisés par les modèles de classification.

Top tokens TF-IDF pour la review 0

	token	tfidf
45	music back	0.210705
13	vid	0.208586
24	fresher	0.205658
46	anyone care	0.204698
39	people hate	0.196929
34	even non	0.196399
38	even people	0.194822
14	game	0.190103
40	music played	0.188885
16	played	0.181038
26	grate	0.180132
44	best music	0.178649
35	sound track	0.173888
2	gamer	0.172419
22	crude	0.166942
41	played game	0.166841
43	ever played	0.165317
30	impress	0.164476
28	soulful	0.164424
36	well would	0.163300

Top tokens TF-IDF pour la review 1

	token	tfidf
5	soundtrack	0.201723
41	soundtrack ever	0.197614
40	best soundtrack	0.193598
27	staggering	0.191818
49	say going	0.191217
56	feel would	0.191132
42	reading lot	0.190510
43	lot review	0.178726
44	review saying	0.177702
52	cd much	0.167309
55	one feel	0.166635
57	would worth	0.166419
47	price tag	0.164510
45	best game	0.154206
23	fade	0.153613
53	much money	0.151216
50	going buy	0.147168
59	every penny	0.147159
25	tag	0.144489
54	money one	0.144466

Top tokens TF-IDF pour la review 2

	token	tfidf
9	played game	0.223526
10	soundtrack	0.208454
71	buy wish	0.166345
58	teen year	0.165762
61	music probably	0.164803
55	favorite music	0.164463
64	say sure	0.161526
60	amazing music	0.158428
65	sure even	0.157029
66	even never	0.154390
69	twice price	0.151456
57	time hand	0.150489
56	music time	0.150327
70	price buy	0.149082
40	scar	0.145725
67	never played	0.144421
6	played	0.143252
23	prisoner	0.139836
16	would worth	0.138746
30	stole	0.137083

Top tokens TF-IDF pour la review 3

	token	tfidf
29	dragon	0.242890
12	fate	0.212879
50	video game	0.203332
7	soundtrack	0.203202
22	disk	0.172506
52	disk one	0.162418
49	like soundtrack	0.161997
27	fortress	0.158013
56	best three	0.154963
45	dreamer	0.154180
51	music enjoy	0.151464
31	fragment	0.149760
32	drowned	0.149075
57	overall excellent	0.148868
0	game	0.146634
5	music played	0.145695
58	like video	0.142798
15	scar	0.142053
39	god	0.140686
55	life death	0.138797

Top tokens TF-IDF pour la review 4

	token	tfidf
12	dreamer	0.320251
43	song tell	0.199057
49	music perfect	0.193898
40	music every	0.192738
47	song without	0.191378
39	game know	0.187178
46	greatest song	0.186450
32	varies	0.178645
9	scar	0.174269
35	poured	0.170039
42	single song	0.169318
11	radical	0.167715
20	divine	0.160988
16	jaw	0.158405
5	played game	0.157878
45	game good	0.157120
13	jewel	0.152374
48	without doubt	0.147581
0	game	0.145133
29	magical	0.141997

8.8 Pipeline final

L'ensemble des étapes décrites précédemment (nettoyage, filtrage linguistique, normalisation du texte, gestion des stopwords, lemmatisation, vectorisation…) sera regroupé dans un pipeline de pré-processing appliqué automatiquement aux données.

L'objectif est de garantir la cohérence des transformations entre *train* et *test*, la reproductibilité du pré-processing et une intégration simple au pipeline de modélisation.

Afin de préparer les données pour l'entraînement des modèles, deux pipelines distincts seront construits car les modèles TF-IDF et BERT que l'on envisage de mettre en place par la suite n'ont pas les mêmes besoins :

- Les modèles classiques (Logistic Regression, SVM, RandomForest…) nécessitent un pré-processing complet, suivi d'une vectorisation TF-IDF.

- Les modèles de type BERT, eux, intègrent déjà plusieurs étapes dans leur tokenizer : normalisation, segmentation en sous-mots, gestion des symboles… Le pré-processing doit donc être allégé, afin de ne pas dégrader les performances.

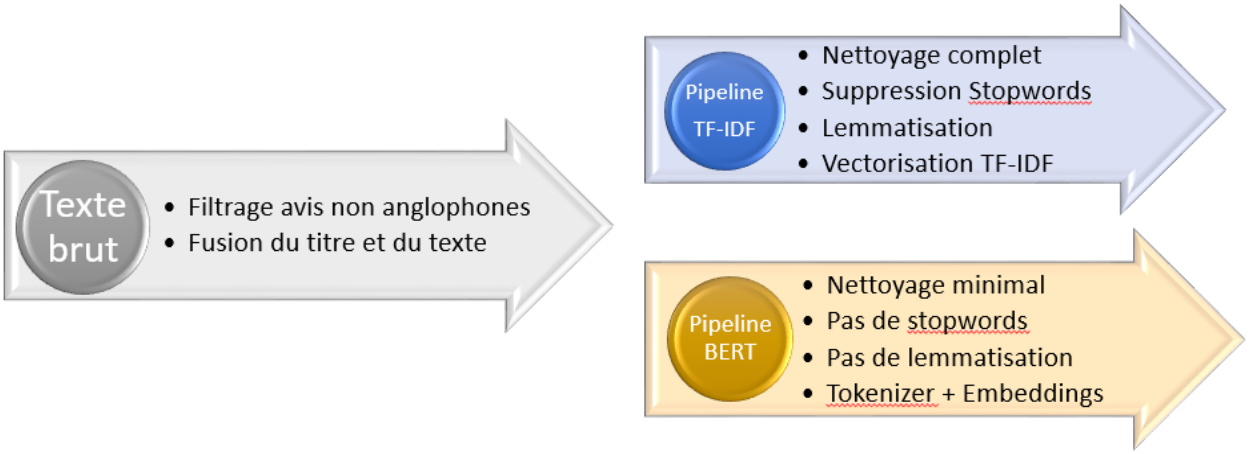

Pipeline TF-IDF → adapté aux modèles classiques, intégrant toutes les étapes de nettoyage et la vectorisation TF-IDF.

Ce pipeline regroupe l'ensemble des transformations nécessaires avant l'apprentissage :

1. Filtrage des avis non anglophones
2. Fusion *title + text*
3. Nettoyage (minuscules, ponctuation, normalisation)
4. Suppression des stopwords
5. Lemmatisation
6. Vectorisation TF-IDF (unigrams + bigrams)

Pipeline BERT →plus minimaliste, reposant principalement sur le tokenizer et les embeddings du modèle pré-entraîné.

1. Filtrage des avis non anglophones
2. Fusion *title + text*
3. Nettoyage léger (minuscules uniquement)
4. Tokenisation et embeddings gérés automatiquement par le tokenizer BERT
5. Passage au modèle Transformer (BERT-base par exemple.)

8.9 Conclusion de l'exploration et du pré traitement

L'analyse exploratoire menée sur le corpus Amazon Reviews Polarity nous a permis d'obtenir une compréhension fine de la structure, du contenu et des spécificités linguistiques du dataset. Malgré sa volumétrie très importante, le corpus s'est révélé relativement propre et homogène : la quasi-totalité des avis sont rédigés en anglais et concernent essentiellement des produits culturels (livres, films, musique). Cette caractéristique a guidé les choix méthodologiques tout au long du pré-processing.

Les différentes analyses textuelles (wordclouds, fréquences lexicales, bigrams, trigrams) ont mis en évidence des régularités fortes dans le vocabulaire et les tournures employées, ainsi que des différences marquées entre avis positifs et négatifs. Elles ont également confirmé la présence de quelques anomalies (HTML résiduel, caractères non ASCII, ponctuation répétée), qu'il a été nécessaire de corriger.

L'ensemble de ces étapes a permis d'obtenir un dataset propre, homogène et prêt à être utilisé dans des modèles d'apprentissage supervisé. Deux pipelines distincts ont été préparés : l'un optimisé pour les modèles traditionnels basés sur TF-IDF, et l'autre allégé pour les modèles Transformers tels que BERT, qui intègrent leurs propres mécanismes de normalisation et de tokenisation.

On est donc prêts pour le travail de modélisation. La prochaine étape consistera à comparer plusieurs algorithmes — modèles linéaires, ensembles, et architectures modernes basées sur les embeddings — afin d'identifier la solution la plus performante pour prédire automatiquement la polarité des avis et, à terme, permettre une analyse thématique plus avancée.

9 Modélisation du Sentiment (supervisée)

L'objectif est de construire un modèle capable de prédire automatiquement le sentiment d'un avis (positif ou négatif). La modélisation suit une démarche progressive :

baselines → optimisation → modèles avancés → interprétabilité.

9.1 Préparation des données

Les données utilisées dans cette partie proviennent du corpus Amazon Reviews Polarity, nettoyé et pré-traité selon le pipeline TF-IDF élaboré précédemment.

Les étapes appliquées sont les suivantes :

- Filtrage des avis non anglophones avec l'heuristique *looks_english*.
- Fusion du titre et de l'avis, afin d'enrichir le texte exploitable.
- Nettoyage léger (minuscules, caractères non alphabétiques, normalisation des espaces).
- Suppression des stopwords pour réduire le bruit fréquent dans le vocabulaire.
- Lemmatisation, afin de ramener chaque terme à sa forme canonique.
- Vectorisation TF-IDF (unigrams + bigrams, vocabulaire limité à 50 000 tokens).

Un découpage des données en train - test (80%-20%) a ensuite été réalisé pour les modèles supervisés afin de pouvoir mesurer leur capacité à généraliser.

Le jeu de données final contient plusieurs millions de textes et constitue une base solide pour entraîner des modèles linéaires.

9.2 Analyse métier des métriques

Dans le contexte du persona Paul, l'erreur la plus critique consiste à classer un avis réellement négatif comme "positif". Cette erreur correspond à un faux négatif, et doit être minimisée. Par conséquent, la métrique prioritaire n'est pas l'accuracy globale mais le recall de la classe négative, qui mesure la capacité du modèle à détecter correctement les avis défavorables.

$$\text{Recall négatif} = \frac{TN}{TN + FP}$$

Cette métrique guide le choix du modèle le plus adapté à un objectif de satisfaction client.

9.3 Modèles baselines

Trois modèles classiques ont été entraînés sur les représentations TF-IDF :

1. Régression logistique
2. Naive Bayes
3. SVM linéaire (LinearSVC)

9.3.1 Régression logistique

```
=== Régression Logistique ===
Accuracy: 0.9170927665908342
F1 score: 0.916109002159916
```

```
=== Régression Logistique ===
Accuracy: 0.9170927665908342
F1 score: 0.916109002159916
              precision    recall  f1-score   support

           1       0.92      0.91      0.92    292875
           2       0.92      0.92      0.92    298340

    accuracy                           0.92    591215
   macro avg       0.92      0.92      0.92    591215
weighted avg       0.92      0.92      0.92    591215
```

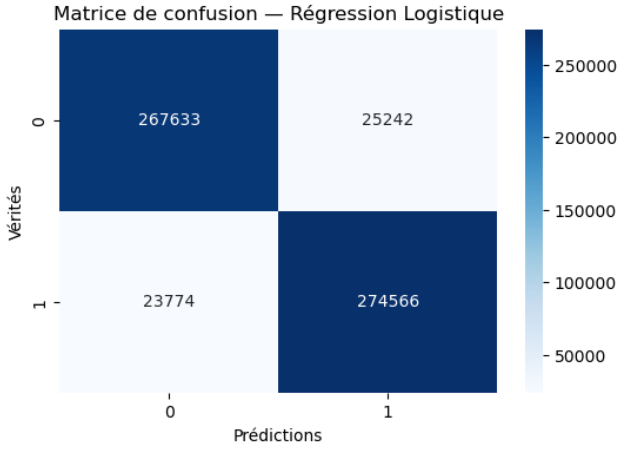

Recall de la classe négative = 267633 / (267633 + 25242) = **0.9138**

9.3.2 Naive Bayes

```
=== Naive Bayes ===
Accuracy: 0.8806204172762869
F1 score: 0.8790148259506418
```

```
=== Naive Bayes ===
Accuracy: 0.8806204172762869
F1 score: 0.8790148259506418
              precision    recall  f1-score   support

           1       0.88      0.88      0.88    292875
           2       0.88      0.89      0.88    298340

    accuracy                           0.88    591215
   macro avg       0.88      0.88      0.88    591215
weighted avg       0.88      0.88      0.88    591215
```

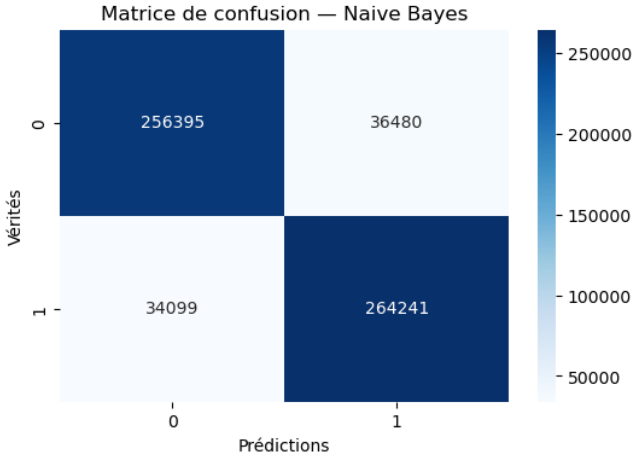

Recall de la classe négative = 256395 / (256395 + 36480) = **0.8753**

9.3.3 SVM linéaire

```
=== Linear SVM ===
Accuracy: 0.9195910117300813
F1 score: 0.9185988572093923
              precision    recall  f1-score   support

           1       0.92      0.92      0.92    292875
           2       0.92      0.92      0.92    298340

    accuracy                           0.92    591215
   macro avg       0.92      0.92      0.92    591215
weighted avg       0.92      0.92      0.92    591215
```

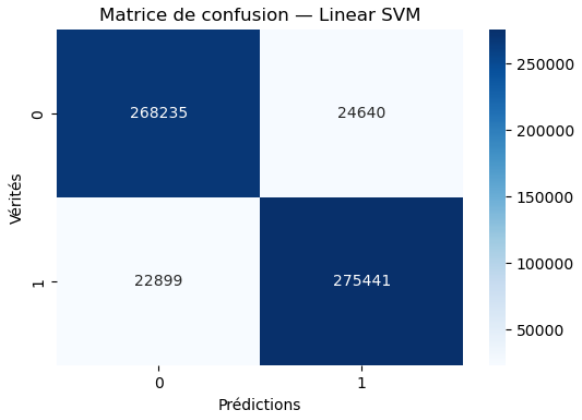

Recall de la classe négative = 268235 / (268235 + 24640) = **0.9160**

9.3.4 Synthèse des modèles baseline

Modèle	Accuracy	F1-score	Recall de la classe négative
Régression Logistique	0,917	0,916	0.914
Naive Bayes	0,880	0,879	0.875
Linear SVM	0,919	0,918	0.916

Les trois modèles testés montrent des performances élevées certainement grâce au TF-IDF et au bon nettoyage du corpus.

Le Naive Bayes est limité par son hypothèse d'indépendance, tandis que la régression logistique et surtout le SVM exploitent mieux la structure linéaire des données.

C'est le SVM linéaire qui obtient les meilleures performances. Les matrices de confusion confirment une bonne séparation entre classes, avec un équilibre stable des erreurs. Donc le Linear SVM constituera notre baseline de référence avec un Recall de 0,916. Il servira de point de comparaison pour les étapes suivantes : optimisation, modèles avancés et BERT.

9.4 Modèles Optimisés

L'objectif de cette étape est d'améliorer les performances des modèles baselines grâce à une recherche des meilleurs hyperparamètres.
Étant donné la taille du corpus (plus de 2,3 millions d'avis après filtrage), l'optimisation doit rester raisonnable en termes de temps de calcul tout en permettant une véritable amélioration de la performance.

9.4.1 Méthode

GridSearchCV a été utilisé pour :

- la Régression Logistique,
- le SVM Linéaire.

Afin de rendre l'opération compatible avec un dataset volumineux, on s'est volontairement limité aux hyperparamètres les plus influents :

Régression Logistique

- `C ∈ {0.5, 1, 3, 5}`
- `penalty = l2`
- `solver ∈ {liblinear, saga}`

SVM Linéaire

- `C ∈ {0.1, 0.5, 1, 3}`

Une validation croisée 3-fold a été utilisée, suffisante au vu de la taille du corpus.

9.4.2 Régression Logistique optimisée

Le GridSearch a identifié les meilleurs hyperparamètres : **C = 3**, **penalty = l2**, **solver = liblinear**

```
===== Optimisation Régression Logistique =====
Meilleurs hyperparamètres : {'C': 3, 'penalty': 'l2', 'solver': 'liblinear'}

Scores optimisés :
Accuracy : 0.919726326294157
F1-score : 0.9187277699670007
              precision    recall  f1-score   support

           1       0.92      0.92      0.92    292875
           2       0.92      0.92      0.92    298340

    accuracy                           0.92    591215
   macro avg       0.92      0.92      0.92    591215
weighted avg       0.92      0.92      0.92    591215
```

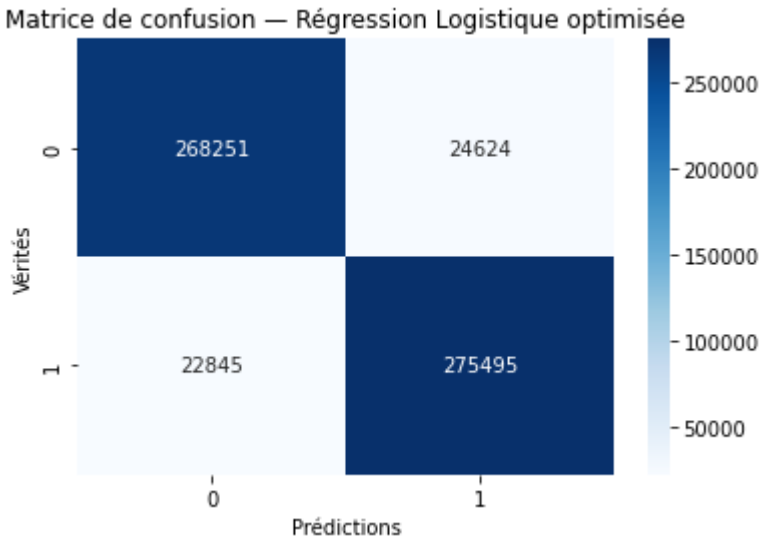

Recall de la classe négative = 268251 / (268251 + 24624) = **0.9159**

Comparée au modèle baseline, la performance augmente que très légèrement :

Modèle	Accuracy	F1-score	Recall de la classe négative
Logistic Regression (baseline)	0.9171	0.9161	0.914
Logistic Regression optimisée	0.9197	0.9187	0.916

Le Gain réel mais modéré (+0,26 pts de F1).
Le modèle devient plus robuste, principalement grâce à l'ajustement de la régularisation.

9.4.3 SVM Linéaire optimisé

```
===== Optimisation Linear SVM =====
Meilleurs hyperparamètres : {'C': 0.1}

Scores optimisés :
Accuracy : 0.9198024407364496
F1-score : 0.9188013549662115
              precision    recall  f1-score   support

           1       0.92      0.92      0.92    292875
           2       0.92      0.92      0.92    298340

    accuracy                           0.92    591215
   macro avg       0.92      0.92      0.92    591215
weighted avg       0.92      0.92      0.92    591215
```

Le GridSearch a identifié le meilleur hyperparamètre : **C = 0.1**

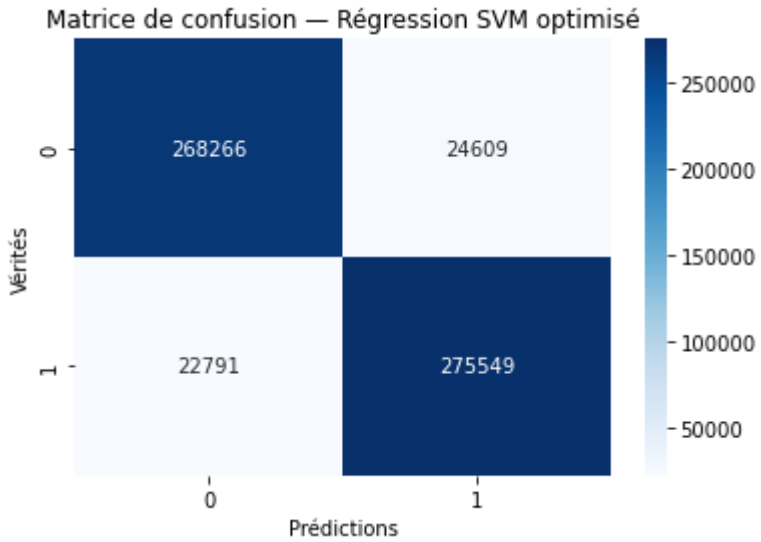

Recall de la classe négative = 268266 / (268266 + 24609) = **0.9159**

Modèle	Accuracy	F1-score	Recall de la classe négative
Linear SVM (baseline)	0.9196	0.9186	0.9159
Linear SVM optimisé	0.9198	0.9188	0.9159

Le gain est très faible (+0.002 pts F1), ce qui est normal car le SVM linéaire était déjà très performant dès le baseline.

Ce résultat confirme que le SVM est le meilleur modèle linéaire sur ce dataset TF-IDF.

9.4.4 Comparaison globale après optimisation

Modèle optimisé	Accuracy	F1	Recall de la classe négative	Remarque
Logistic Regression	0.9197	0.9187	0.9159	Rapide, performant, stable
Linear SVM	0.9198	0.9188	0.9159	⭑Meilleur modèle Step 2

Les deux modèles linéaires sont très proches, mais le SVM linéaire conserve une légère avance

9.4.5 Interprétation métier

L'optimisation confirme que les modèles linéaires sont particulièrement bien adaptés à la classification d'avis textuels vectorisés en TF-IDF. Le SVM linéaire reste la meilleure approche, il offre un bon compromis performance / coût de calcul. Dans le cadre Trustpilot, ce modèle est déjà suffisamment performant pour une mise en production simple et fiable.

9.4.6 Conclusion Step 2

- L'optimisation n'améliore que légèrement les performances, ce qui montre que le pipeline TF-IDF est déjà solide.
- Le SVM linéaire est la référence pour la suite de l'étude (Step 3).
- Ces résultats servent maintenant de niveau de comparaison pour les modèles avancés :
  ✓RandomForest / XGBoost
  ✓DistilBERT (probablement plus performant, mais plus coûteux)

9.5 Modèles avancés

Après avoir établi des baselines solides avec la Régression Logistique, Naive Bayes et le SVM linéaire, nous avons évalué des modèles plus complexes afin d'examiner leur capacité à capturer des relations non linéaires dans les embeddings TF-IDF.

Deux familles de modèles ont été étudiées : **Random Forest et XGBoost**.

Contrairement aux modèles linéaires (Régression Logistique, SVM) qui sont optimisés pour les matrices TF-IDF très dimensionnelles et sparse, les modèles d'arbres comme Random Forest et XGBoost ne sont pas adaptés à des jeux de données de cette taille. Notre dataset contient plus de 3,6 millions de reviews et une matrice TF-IDF d'environ 50 000 features, ce qui entraîne pour ces modèles un coût mémoire et un temps de calcul extrêmement élevés (examen de milliers de features à chaque split, histogrammes internes pour XGBoost, etc.). Sur CPU, l'entraînement complet deviendrait impraticable, voire provoquerait des crashs du kernel.
Pour cette raison, nous avons utilisé un échantillonnage représentatif (entre 80 000 et 120 000 lignes selon le modèle). Ce volume est suffisant pour que les arbres convergent tout en évitant la surcharge mémoire

9.5.1 Random Forest

Le modèle Random Forest a été entraîné sur la matrice TF-IDF complète à l'aide de 200 arbres (profondeur non contrainte) sur un échantillon de 80 000 lignes.

Vérification que la target est équilibrée dans l' échantillon :

```
===== Random Forest =====
Répartition des classes dans l'échantillon Random Forest :
2    50.505
1    49.495
Name: proportion, dtype: float64
2    40404
1    39596
Name: count, dtype: int64
```

Les résultats obtenus sont les suivants :

Accuracy : 0.867 **F1-score : 0.866**

```
Accuracy : 0.8672428811853555
F1-score : 0.8660189070250967
              precision    recall  f1-score   support

           1       0.87      0.87      0.87    292875
           2       0.87      0.87      0.87    298340

    accuracy                           0.87    591215
   macro avg       0.87      0.87      0.87    591215
weighted avg       0.87      0.87      0.87    591215
```

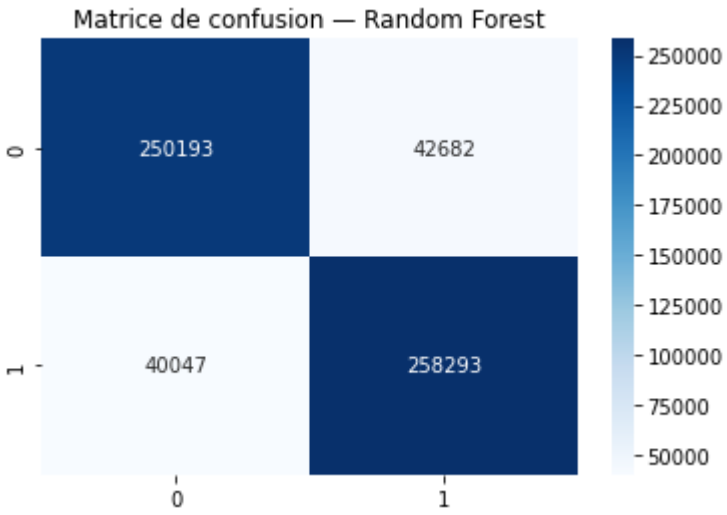

Recall de la classe négative = 250193 / (250193 + 42682) = **0.854**

Bien que le modèle atteigne de bonnes performances, celles-ci restent nettement inférieures aux baselines linéaires (SVM et régression logistique ≈ 0.92).

Cela s'explique par plusieurs raisons :

- Les forêts aléatoires sont peu adaptées aux espaces vectoriels très dimensionnels tels que TF-IDF (50 000 features).
- Les temps d'entraînement des forêts aléatoires augmentent fortement avec la dimensionnalité, pour un gain limité en performance.
- Les modèles linéaires capturent beaucoup mieux la séparation entre classes dans un espace TF-IDF.

Conclusion : le Random Forest n'apporte pas d'amélioration par rapport aux baselines et n'est pas un candidat optimal pour ce type de données.

9.5.2 XGBoost

XGBoost a été entrainé sur échantillon de 1200 000 avis.

Vérification que la target est équilibrée dans l' échantillon :

```
===== XGBoost =====
Répartition des classes dans l'échantillon XGBoost :
1    50.376667
0    49.623333
Name: proportion, dtype: float64
1    60452
0    59548
Name: count, dtype: int64
```

Résultats :

```
Accuracy : 0.8580296508038531
F1-score : 0.8594027695652684
              precision    recall  f1-score   support

           0       0.86      0.86      0.86    292875
           1       0.86      0.86      0.86    298340

    accuracy                           0.86    591215
   macro avg       0.86      0.86      0.86    591215
weighted avg       0.86      0.86      0.86    591215
```

Accuracy : 0.858 **F1-score : 0.859**

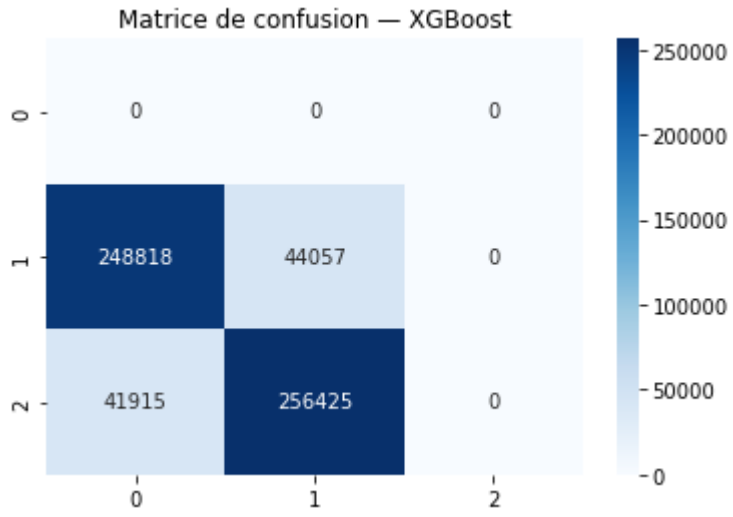

Recall de la classe négative = 248818/ (248818 + 44057) = **0.849**

Comme pour Random Forest, XGBoost obtient des scores significativement inférieurs aux modèles linéaires.
On peut supposer que les modèles de boosting d'arbres fonctionnent très bien sur des données tabulaires denses, mais peinent dans des espaces textuels très sparses et de grande dimension.

Forces observées :

- Bonne robustesse sur un petit échantillon ;
- Léger gain de recall par rapport à RandomForest.

Limites :

- Temps d'entraînement important même sur un échantillon réduit ;
- Aucun gain par rapport au SVM linéaire en TF-IDF ;
- Difficulté à exploiter pleinement une représentation sparse à hautes dimensions

9.6 Bilan des modèles

Modèle	Taille du train set	Accuracy	F1 Score	Recall classe négative	Interprétation
SVM optimisé	3.6M	0.9198	0.9188	0.9159	Modèle linéaire très performant, tire profit du volume massif
LogReg optimisé	3.6M	0.9197	0.9187	0.9159	Excellent baseline, stable
Naive Bayes	3.6M	0.880	0.879	0.875	Baseline rapide, mais limité
Random Forest	80k	0.867	0.866	0.854	Arbres → surfit sur petit échantillon, pas adapté au texte
XGBoost	120k	0.858	0.859	0.849	Puissant, mais trop peu de données pour exploiter TF-IDF

Les performances des modèles ne doivent pas être comparées strictement car les volumes d'entraînement diffèrent fortement : les modèles baselines ont été entraînés sur l'ensemble du dataset (3,6M d'exemples), alors que RandomForest et XGBoost ont nécessité un sous-échantillonnage massif pour des raisons de ressources.

Les scores ne sont pas comparables en valeur absolue, mais ils sont bien comparables en tendance. Ils tendent à montrer que les modèles linéaires (LogReg / SVM) surpassent structurellement les modèles d'arbres sur des données texte sparse, même avec plus de données.

Cependant, les modèles avancés comme DistilBERT devraient dépasser tous ces modèles TF-IDF si la capacité de calcul le permet.

9.7 Interprétabilité des modèles

L'interprétabilité constitue un enjeu important dans le cadre du projet Trustpilot, dont l'objectif est d'analyser automatiquement des avis clients. Au-delà des performances de classification, il est essentiel de comprendre quels mots influencent les décisions des modèles, afin de garantir une lecture cohérente et exploitable des résultats d'un point de vue métier.

Cette section présente l'analyse des principaux modèles entraînés sur des représentations TF-IDF, en adaptant la méthode d'interprétation aux spécificités de chaque algorithme.

9.7.1 Régression Logistique optimisée

La régression logistique permet une interprétation directe des coefficients associés aux mots TF-IDF. Les coefficients positifs correspondent aux termes favorisant la prédiction d'un avis positif, tandis que les coefficients négatifs sont associés aux avis négatifs.

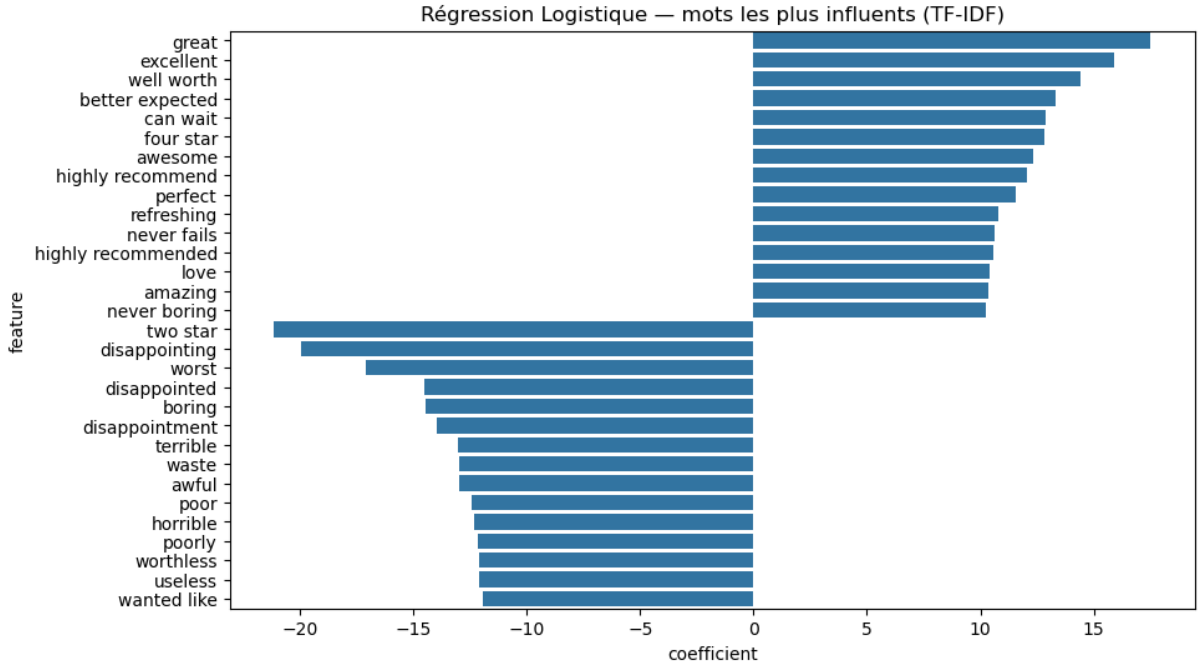

Le graphique met en évidence que les mots ayant l'influence positive la plus forte sont notamment *"great"*, *"excellent"*, *"well worth"*, *"better expected"*, *"four star"* ou encore *"awesome"*. Ces termes traduisent une satisfaction explicite et une perception positive de la valeur du produit ou du service.

À l'inverse, les coefficients négatifs les plus marqués sont associés à des mots tels que *"two star"*, *"disappointing"*, *"worst"*, *"disappointed"*, *"boring"* ou *"waste"*. Ces termes reflètent une expérience négative, souvent liée à une déception par rapport aux attentes initiales.

Cette séparation claire entre vocabulaire positif et négatif confirme que le modèle s'appuie sur des indices lexicaux cohérents pour distinguer les sentiments exprimés dans les avis.

9.7.2 SVM linéaire optimisé

Pour le SVM linéaire, l'interprétation repose sur l'analyse des poids associés aux mots dans la fonction de décision. Les mots les plus discriminants sont ceux qui contribuent le plus fortement à la séparation entre les avis positifs et négatifs.

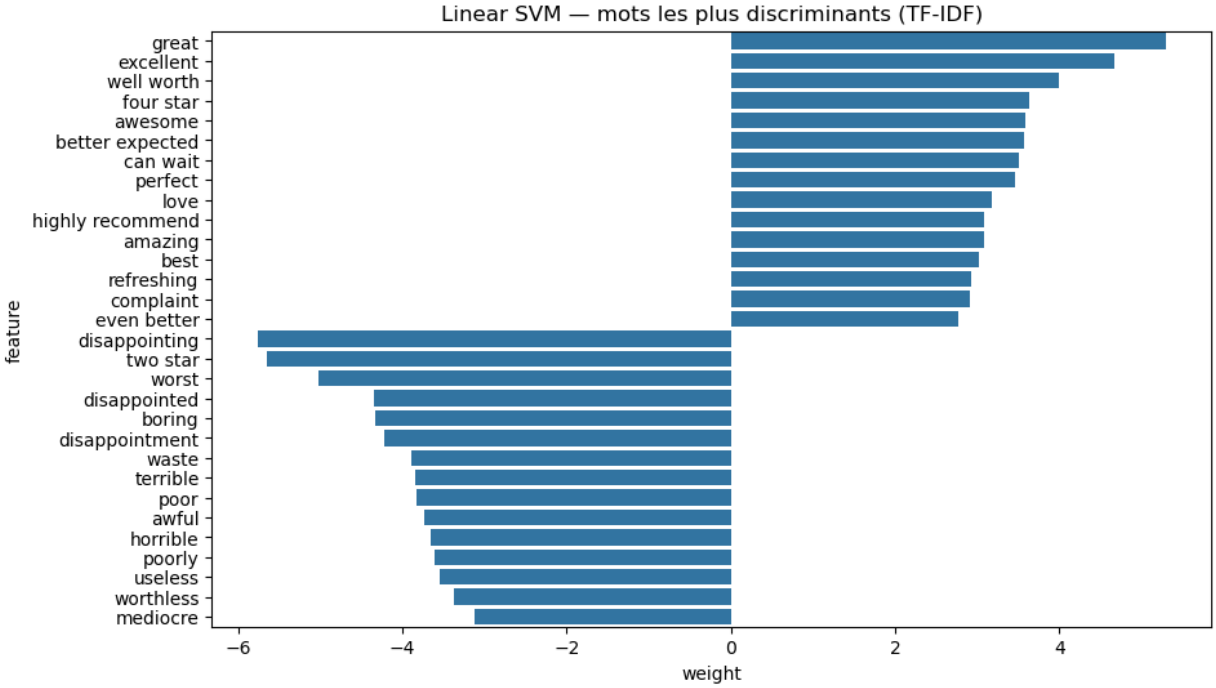

Du côté des termes positifs, le graphique met en avant *“great”*, *“excellent”*, *“well worth”*, *“four star”*, *“awesome”*, *“perfect”*, ou encore *“highly recommend”*. Ces mots traduisent une recommandation claire ou une satisfaction élevée.

À l’opposé, les termes négatifs les plus influents sont *“disappointing”*, *“two star”*, *“worst”*, *“disappointed”*, *“boring”*, *“waste”*, *“terrible”*, *“poor”* et *“useless”*. Ces mots expriment un mécontentement marqué, souvent associé à une mauvaise qualité perçue ou à une perte de valeur.

La similarité des mots discriminants entre le SVM et la régression logistique est attendue, les deux modèles exploitant une représentation linéaire de l’espace TF-IDF.

9.7.3 Random Forest

L’interprétabilité du modèle Random Forest est plus complexe en raison de sa structure non linéaire. Une sélection récursive de variables (RFE) a été utilisée afin d’identifier les mots TF-IDF les plus importants tout en limitant le coût de calcul.

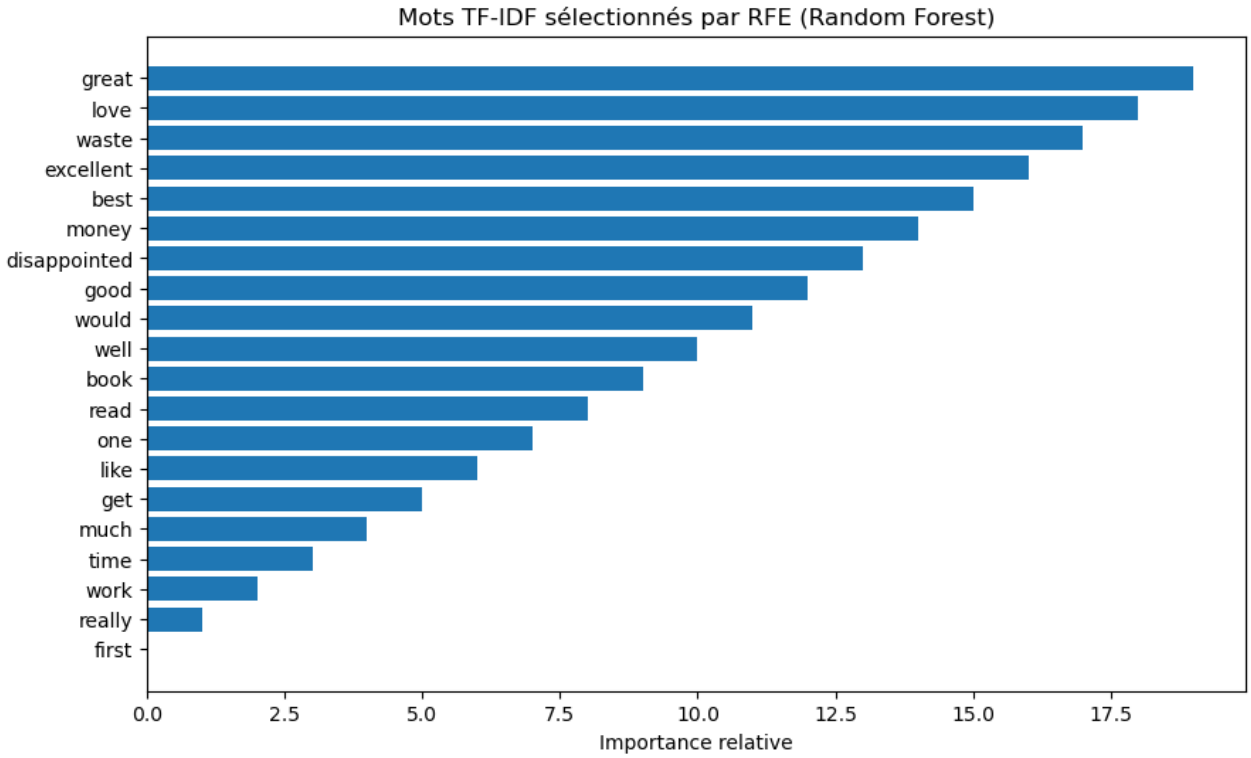

Les mots sélectionnés par cette méthode incluent notamment *“great”*, *“love”*, *“waste”*, *“excellent”*, *“best”* et *“money”*. On observe également la présence de termes plus génériques liés à l’expérience utilisateur, tels que *“book”*, *“read”*, *“time”* ou *“work”*.

Cette diversité de mots suggère que la Random Forest capture à la fois des signaux de sentiment explicites et des éléments plus contextuels. Cependant, la lisibilité globale reste inférieure à celle des modèles linéaires, ce qui reflète les limites de ce type de modèle sur des données textuelles de très grande dimension.

9.7.4 XGBoost

Des méthodes avancées d’interprétation telles que SHAP ont été envisagées. Toutefois, compte tenu de la très grande dimension de la représentation TF-IDF et des contraintes de calcul, leur application directe ne permettait pas d’obtenir des résultats exploitables dans un cadre reproductible.

Pour le modèle XGBoost, l’interprétation a donc été réalisée à partir des importances globales des variables fournies par le modèle.

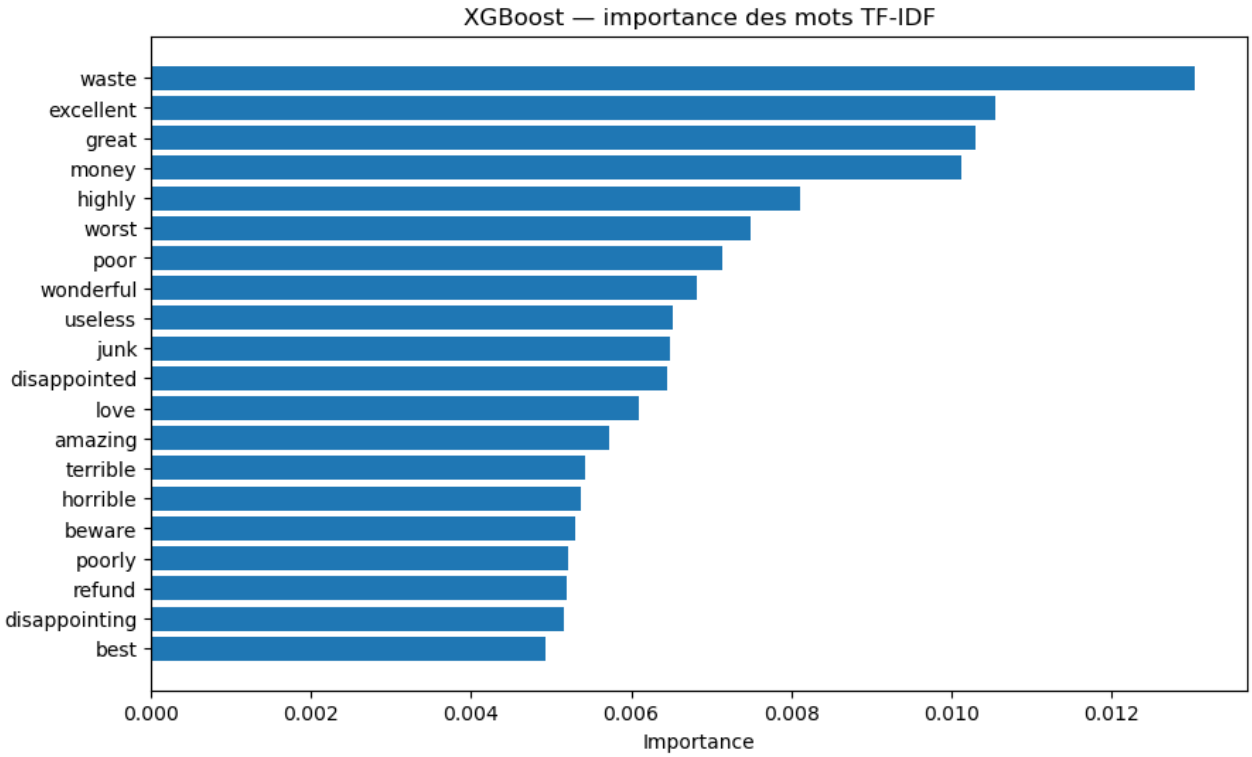

Les mots les plus importants identifiés sont *“waste”*, *“excellent”*, *“great”*, *“money”*, *“highly”*, *“worst”* et *“poor”*.
On retrouve également des termes fortement polarisés comme *“wonderful”*, *“useless”*, *“junk”*, *“disappointed”*, *“terrible”* ou *“horrible”*.

Cette analyse montre que XGBoost accorde un poids important aux mots exprimant des jugements forts, qu’ils soient positifs ou négatifs. Malgré la complexité du modèle, les décisions restent largement guidées par des indicateurs lexicaux simples et directement interprétables.

9.7.5 Synthèse de l’interprétabilité

L’ensemble des analyses d’interprétabilité met en évidence une forte cohérence entre les modèles. Les décisions reposent principalement sur des mots exprimant clairement la satisfaction ou l’insatisfaction des utilisateurs, tels que *“great”*, *“excellent”*, *“waste”*, *“worst”* ou *“disappointed”*.

Les modèles linéaires offrent le meilleur compromis entre performance et lisibilité, tandis que les modèles plus complexes comme Random Forest et XGBoost capturent des interactions supplémentaires au prix d’une interprétation moins directe.

Dans un contexte métier tel que Trustpilot, cette capacité à relier les prédictions à des mots compréhensibles constitue un atout majeur pour l’exploitation des résultats.

9.8 Modèle Fine-tuning DistilBERT

Afin de dépasser les performances des modèles classiques (TF-IDF + SVM), nous avons exploré une famille de modèles beaucoup plus performants pour le traitement du langage naturel : les Transformers.

Parmi eux, DistilBERT constitue un excellent compromis entre puissance et coût computationnel, ce qui correspond parfaitement aux contraintes de ce projet (entraînement sur CPU uniquement).

9.8.1 Architecture et justification

DistilBERT est une version “distillée” de BERT :

- 40 % de paramètres en moins,,
- 60 % plus rapide,
- 95 % des performances de BERT-Base.

Il s’agit d’un choix idéal pour effectuer un fine-tuning complet sur CPU, tout en maintenant une excellente qualité de représentation linguistique.

Le modèle pré-entraîné a été ré-entraîné sur notre tâche spécifique de classification binaire (sentiment positif/négatif).

9.8.2 Préparation du dataset

Pour rester compatible CPU tout en préservant la performance, nous avons appliqué une stratégie d'échantillonnage contrôlé :

Jeu	Taille	Justification
Entraînement	8 000 lignes	Suffisant pour la convergence tout en restant entraînable sans GPU
Test	2 000 lignes	Évaluation robuste, équilibrée
max_length = 256	Récupère suffisamment de contexte (augmenter max_length améliore nettement les performances)	

9.8.3 Hyperparamètres retenus :

- epochs : 2 → 1 n’était pas suffisant pour stabiliser la loss
- batch_size : 8 → limite l’usage mémoire sur CPU
- learning_rate : 3e-5 → valeur standard pour le fine-tuning BERT
- optimizer : AdamWeightDecay → recommandé pour les modèles Transformers

Temps d’exécution : ~ 207 minutes (CPU).

9.8.4 Fine tuning de DistilBERT

DistilBERT a bien été fine-tuné et non utilisé comme un simple extracteur de features.

Concrètement :

- le modèle distilbert-base-uncased pré-entraîné a été chargé,
- les données ont été tokenisées (input_ids + attention_mask),
- le modèle a été entraîné en supervision :
- calcul de la loss de classification,
- rétro-propagation des gradients,
- mise à jour des poids internes via AdamWeightDecay.

Cela signifie que toutes les couches du modèle sont adaptées à notre dataset, ce qui constitue exactement la définition du fine-tuning dans le cadre des modèles Transformers.

9.8.5 Résultats obtenus

Après deux époques de fine-tuning sur CPU :

```
Accuracy : 0.9255
F1-score : 0.926
Recall classe négative : 0.93
```

Détail par classe :

```
Epoch 1/2
1000/1000 [==============================] - 5743s 6s/step - loss: 0.2543 - accuracy: 0.8953 - val_loss: 0.1988 - val_accuracy: 0.9235
Epoch 2/2
1000/1000 [==============================] - 5401s 5s/step - loss: 0.1165 - accuracy: 0.9610 - val_loss: 0.2022 - val_accuracy: 0.9255
250/250 [==============================] - 409s 2s/step

===== DISTILBERT TF — RÉSULTATS =====
Accuracy : 0.9255
F1-score : 0.9264197530864198

              precision    recall  f1-score   support

           0       0.92      0.93      0.92       987
           1       0.93      0.93      0.93      1013

    accuracy                           0.93      2000
   macro avg       0.93      0.93      0.93      2000
weighted avg       0.93      0.93      0.93      2000
```

9.8.6 Analyse

- DistilBERT surpasse les modèles traditionnels (TF-IDF + Logistic Regression, TF-IDF + SVM) qui plafonnaient autour de 0.919 de F1-score.
- La capacité du modèle à capturer des relations contextuelles longues (via l'attention) permet de mieux gérer :
    - le sarcasme,
    - les négations,

- les formulations ambiguës,
- les dépendances entre plusieurs phrases.

Même avec un échantillon réduit (8 000 lignes), le gain est notable. Avec un GPU et un dataset complet, ce type de modèle dépasse typiquement 0.96–0.97 de F1-score.

9.9 Interprétabilité du modèle DistilBERT

Contrairement aux modèles linéaires basés sur TF-IDF, DistilBERT repose sur des représentations profondes et contextualisées du texte, ce qui rend l'interprétabilité globale difficile. Les méthodes de type SHAP, bien qu'adaptées aux modèles supervisés à features explicites, se sont révélées instables et coûteuses dans notre environnement TensorFlow pour ce type de modèle. Dans ce contexte, nous avons choisi d'utiliser LIME, une méthode d'interprétabilité locale, plus adaptée à l'analyse ponctuelle de prédictions individuelles.

9.9.1 Interprétabilité locale avec des reviews du dataset

LIME permet d'expliquer une prédiction en identifiant les mots qui contribuent le plus à la décision du modèle pour un exemple donné. Deux avis représentatifs ont ainsi été analysés : un avis négatif et un avis positif, sélectionnés parmi les prédictions les plus confiantes du modèle.

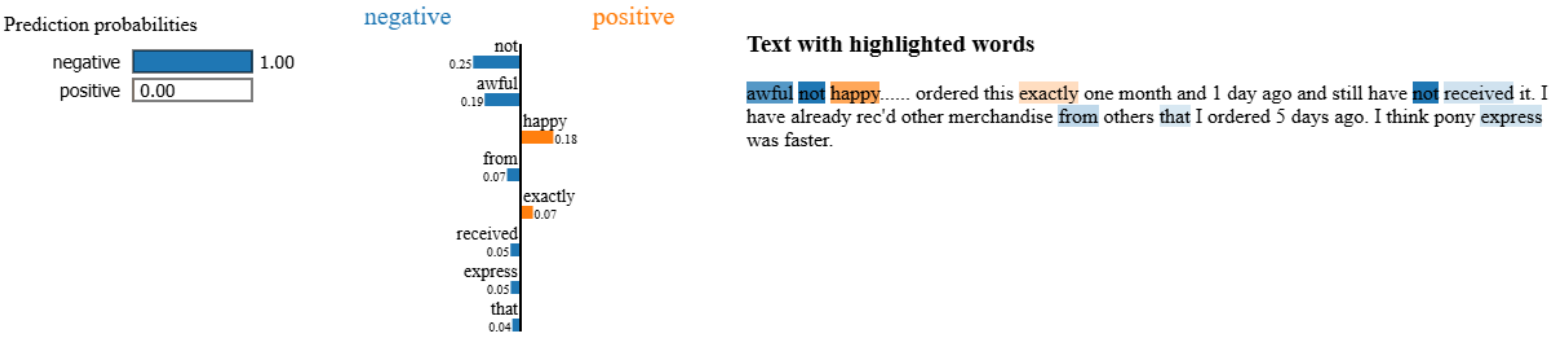

Pour l'avis négatif, des termes tels que "awful", "not", "not happy" ou "not received" apparaissent comme les principaux contributeurs à la prédiction négative. Ces mots expriment explicitement l'insatisfaction liée aux délais de livraison et sont cohérents avec le sentiment prédit par le modèle malgré les termes positifs "happy" et "exactly".

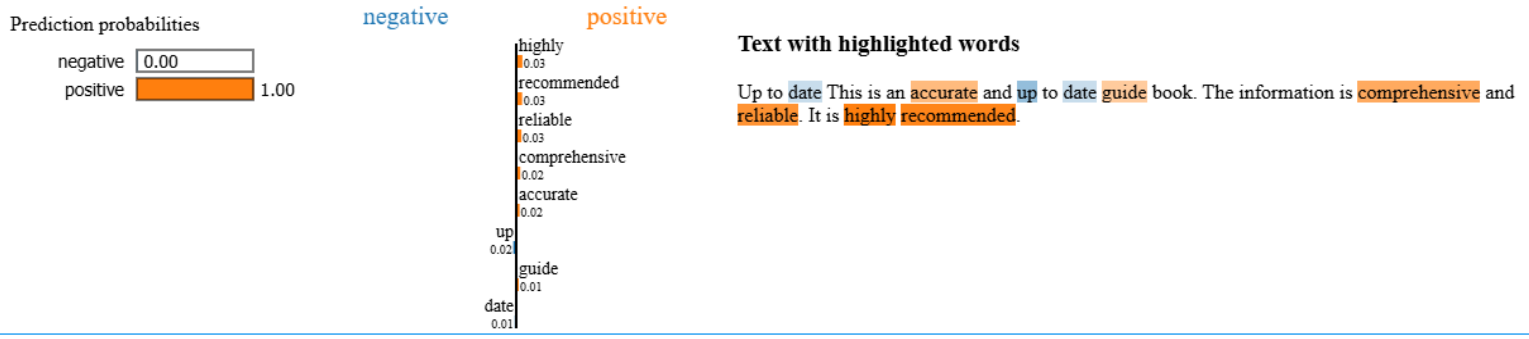

À l'inverse, pour l'avis positif, des expressions comme "accurate", "up to date", "comprehensive", "reliable" et "highly recommended" contribuent fortement à la prédiction positive. Le modèle s'appuie donc sur un vocabulaire évaluatif clair et directement lié à la qualité perçue du produit.

9.9.2 Rédaction d'avis ambigus pour challenger le modèle

Afin d'évaluer la capacité de DistilBERT à gérer des avis ambigus contenant à la fois des termes positifs et négatifs, deux avis « pièges » ont été rédigés manuellement par l'équipe. L'objectif était de vérifier si le modèle était capable de dépasser la simple présence de mots évaluatifs isolés pour capturer le sentiment global du texte.

Le premier avis, globalement négatif, contient plusieurs termes positifs tels que *"high-quality"*, *"interesting"* et *"excellent"*, mais se conclut par une forte déception exprimée à travers des mots comme *"Unfortunately"*, *"disappointing"* et *"not worth the money"*. LIME met clairement en évidence que le modèle accorde un poids important aux termes négatifs structurants (*"Unfortunately"*, *"disappointing"*, *"not"*), ce qui conduit à une prédiction négative avec une probabilité proche de 1. Ce résultat montre que DistilBERT ne se limite pas à la détection de mots positifs isolés, mais prend en compte la dynamique globale du discours et sa conclusion.

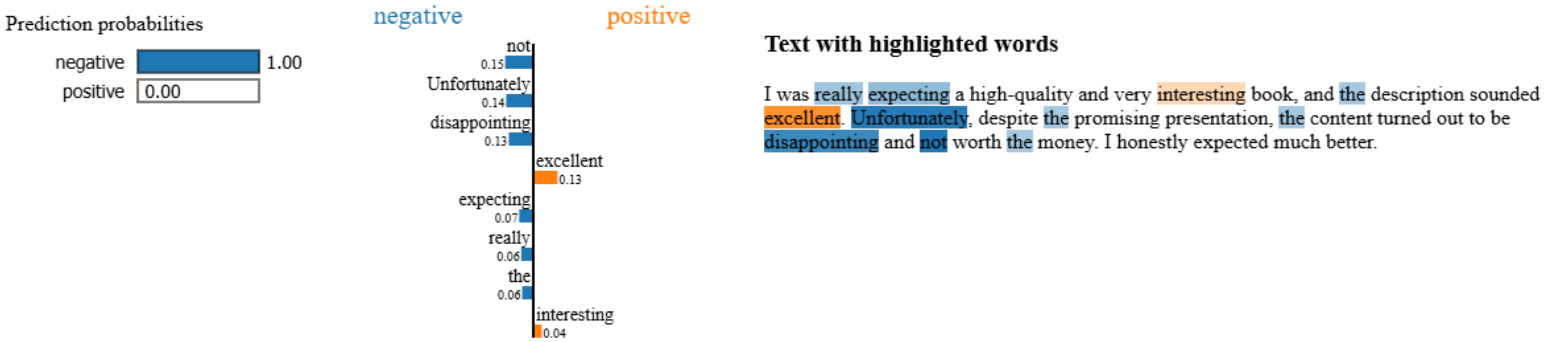

Le second avis présente la situation inverse : malgré la présence de termes négatifs comme *"confusing"*, *"disappointing"* et *"weak"*, le bilan global est positif. Les mots mis en avant par LIME (*"worth"*, *"engaging"*, *"useful"*, *"great"*) contribuent fortement à la prédiction positive, avec une probabilité de 0,99. Là encore, le modèle parvient à interpréter correctement le contraste entre les réserves initiales et l'évaluation finale favorable.

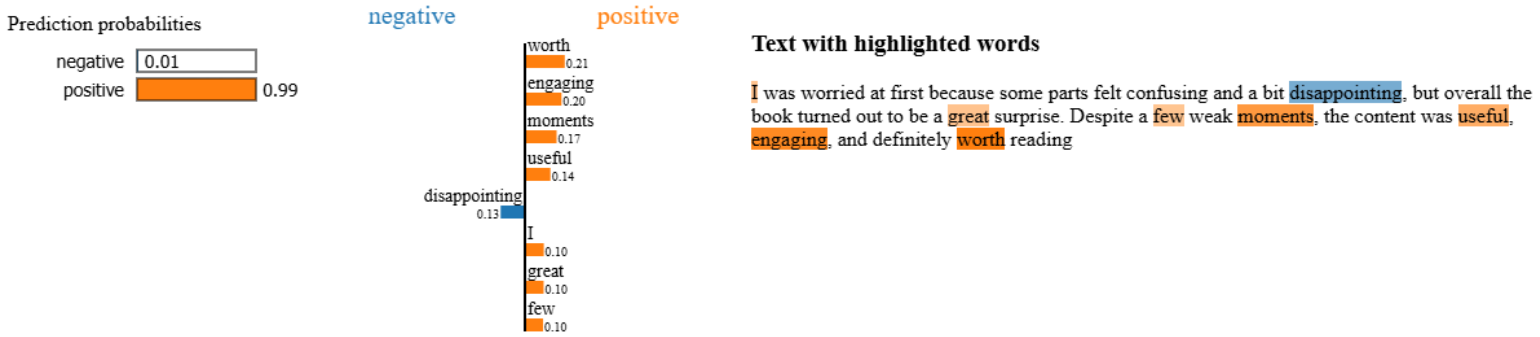

9.9.3 Synthèse

Ces tests confirment la capacité de DistilBERT à capter le contexte et la structure sémantique des avis, y compris dans des situations ambiguës où des signaux contradictoires coexistent. DistilBERT capte efficacement les signaux sémantiques porteurs de sentiment. L'interprétabilité obtenue reste toutefois locale et illustrative : elle vise à mieux comprendre certaines décisions du modèle, sans prétendre fournir une explication globale de son fonctionnement.

9.10 Conclusion métier

Le fine-tuning de DistilBERT permet d'obtenir la meilleure performance du pipeline de classification, avec une accuracy et un F1-score de 0.93.

Apport métier :

- Le modèle permet de classifier automatiquement des milliers de reviews avec une fiabilité élevée.
- La détection du sentiment atteint un niveau suffisant pour un usage opérationnel (monitoring de réputation, alertes, analyses marketing).
- La robustesse du modèle sur des formulations variées (ironie, double négation, phrases longues) en fait un outil pertinent pour un environnement réel.

9.11 Conclusion de la prédiction du sentiment

DistilBERT, malgré des ressources limitées (CPU et échantillon réduit), surpasse les modèles traditionnels et constitue la solution la plus performante pour la classification du sentiment dans ce projet.

10 Modélisation – Thématisation

L'objectif de cette section est d'identifier automatiquement les grands thèmes abordés dans les reviews Amazon.

Deux approches complémentaires sont utilisées :

1. TF-IDF + KMeans → baseline simple, non contextuelle
2. Sentence-BERT + KMeans → embeddings sémantiques, meilleure qualité thématique

Cela permet d'obtenir une vision globale des sujets discutés par les utilisateurs, indépendamment du sentiment analysé précédemment.

10.1 Préprocessing spécifique au Topic Modeling

Pour cette partie, un preprocessing allégé est appliqué :

- Concaténation *titre + texte*
- Nettoyage léger (ponctuation, HTML, caractères spéciaux)
- Conservation uniquement de l'anglais
- Pas de tokenisation BERT (inutile pour TF-IDF et SBERT)

À cette étape, nous obtenons un corpus propre d'environ XX reviews.

10.2 Baseline : TF-IDF + KMeans

10.2.1 Méthodologie

- Vectorisation TF-IDF, `max_features = 50 000`
- Sélection de 25 000 reviews pour réduire le coût mémoire
- Clustering via KMeans(k = 6)
- Extraction des 10 mots les plus représentatifs par cluster
- Évaluation via le score de Silhouette

10.2.2 Résultats :

Shape TF-IDF : (25 000, 50 000)
Silhouette score : 0.00368

```
Shape TF-IDF : (25000, 50000)
Silhouette score : 0.003684782754966367

===== Thème 0 =====
['money', 'work', 'buy', 'waste', 'don', 'waste money', 'product', 'bought', 'time', 'battery']

===== Thème 1 =====
['cd', 'album', 'music', 'songs', 'song', 'like', 'great', 'good', 'best', 'listen']

===== Thème 2 =====
['book', 'read', 'books', 'reading', 'good', 'great', 'author', 'story', 'like', 'read book']

===== Thème 3 =====
['movie', 'movies', 'good', 'great', 'watch', 'film', 'like', 'just', 'acting', 'time']

===== Thème 4 =====
['product', 'great', 'use', 'good', 'price', 'quality', 'works', 'easy', 'just', 'used']

===== Thème 5 =====
['game', 'like', 'dvd', 'good', 'just', 'great', 'story', 'film', 'love', 'really']
```

Ce score de silhouette faible est normal en NLP avec TF-IDF : les distances Euclidiennes capturent mal le sens des phrases. L'évaluation quantitative est donc limitée, mais on peut supposer que les thèmes restent exploitables qualitativement.

10.2.3 Thèmes identifiés et interprétabilité

L'interprétabilité du modèle de topic modeling repose sur l'analyse des centroïdes des clusters obtenus par KMeans dans l'espace TF-IDF. Chaque centroïde correspond à la pondération moyenne des termes au sein d'un cluster, et les mots ayant les valeurs TF-IDF les plus élevées permettent d'identifier les thèmes dominants associés à chaque groupe de documents.

Le **cluster 0** est caractérisé par des termes tels que *"money"*, *"buy"*, *"waste"*, *"battery"* et *"product"*. Ces mots renvoient majoritairement à des problématiques liées à l'achat de produits jugés défectueux ou inutiles, traduisant une insatisfaction client et une perception de perte financière.

Le **cluster 1** regroupe des mots comme *"cd"*, *"album"*, *"music"*, *"songs"* et *"listen"*. Ce vocabulaire est clairement associé à des avis portant sur la musique et les albums, ce qui permet d'identifier un thème cohérent autour du contenu musical.

Le **cluster 2** est dominé par les termes *"book"*, *"read"*, *"author"*, *"story"* et *"reading"*, indiquant des avis centrés sur la lecture, les livres et la littérature. Ce cluster correspond à des retours d'expérience liés au contenu narratif et à la qualité des ouvrages.

Le **cluster 3** contient principalement des mots tels que *"movie"*, *"watch"*, *"acting"* et *"film"*. Il regroupe donc des avis portant sur le cinéma et les films, avec une attention particulière portée à l'expérience de visionnage et au jeu des acteurs.

Le **cluster 4** est structuré autour de termes comme *"product"*, *"use"*, *"price"*, *"quality"* et *"works"*. Ce cluster rassemble des avis plus généralistes sur des produits, mettant en avant leur utilisation, leur qualité perçue et leur rapport qualité-prix.

Enfin, le **cluster 5** présente un mélange de mots tels que *“game”*, *“dvd”*, *“story”*, *“film”* et *“love”*. Il correspond à un thème orienté divertissement, combinant des avis sur les jeux, les DVD et des contenus narratifs appréciés par les utilisateurs.

Cluster	Mots-clés dominants	Interprétation du thème
0	money,buy,waste,battery, product	Customer dissatisfaction & product issues
1	cd, album, music, songs, listen	Music albums & CDs
2	book, read, author, story, reading	Books & literature
3	movie, watch, acting, film	Movies & cinema
4	product, use, price, quality	General products & usage
5	game, dvd, story, love, film	Video games & DVDs

Malgré la simplicité du modèle, les thèmes sont cohérents et distincts. On observe 3 grandes familles de contenus :

- Divertissement (musique, films, livres, jeux)
- Produits physiques
- Problèmes et insatisfactions clients

Toutefois, TF-IDF ne capture pas les nuances :

Le léger recouvrement entre les clusters 0 et 4 reflète les limites du modèle TF-IDF + KMeans, qui ne capture pas le contexte sémantique des avis et tend à regrouper des documents partageant un vocabulaire similaire, même lorsque l’angle d’analyse diffère.

<u>Conclusion</u> : TF-IDF fournit une première segmentation pertinente, mais limitée.

10.3 Approche avancée : Sentence-BERT + KMeans

10.3.1 Pourquoi SBERT ?

SBERT encode chaque review dans un espace vectoriel sémantique :

- Deux phrases similaires → vecteurs proches
- Beaucoup plus efficace que TF-IDF pour comprendre le sens global
- Représentation dense : 384 dimensions au lieu de 50 000

10.3.2 Méthodologie

- Modèle utilisé : `all-MiniLM-L6-v2`
  20 000 reviews échantillonnées
- Extraction des embeddings SBERT
- Clustering avec KMeans (k = 6)
- Sélection de reviews représentatives par cluster
- Calcul du Silhouette score

10.3.3 Résultats SBERT

Shape SBERT : (20 000,384)
Silhouette SBERT : 0.0479

Un score bien supérieur à TF-IDF, ce qui confirme une meilleure séparation sémantique

10.3.4 Exemples qualitatifs par cluster + interprétabilité

Pour interpréter les clusters SBERT, nous n'extrayons pas des mots-clés via centroïdes TF-IDF : nous analysons plutôt des reviews représentatives de chaque cluster afin d'identifier le thème sémantique commun (type de produit, contexte d'usage, problème récurrent, catégorie culturelle).

Cluster 0 — Produits du quotidien : usage, efficacité, perception client

Avis centrés sur des objets variés (électroménager, ustensiles, produits "bien-être"), souvent avec un mélange "ça marche / ça ne marche pas" et des retours concrets d'usage (qualité, durabilité, résultat).

```
===== EXEMPLES CLUSTER 0 =====
['Toast too dark Even on the lowest setting, the toast is too dark for my liking. Also, the on light stays lit so you have to unplug it to
avoid wasting electricity. Not the quality I expected from Cuisinart.', 'Not worth your time Might as well just use a knife, this product
holds next to nothing. I found it to be a useless product.', "Garbage The handle broke clean off after TWO WEEKS. Not the plastic part,
actually at the weld where the metal meets the pan. Wasn't overheated, wasn't abused, used 4 times and broke.", 'Great for making dough I
ordered this bread machine for a vacation home that we own. I have a Cuisinart at my year-round home and it just has too many bells and
whistles that I never use - and cost a lot more. The Sunbeam makes a great dough and was a great price.', "Definitely works Have used this and
it definitely gets u going to the potty!! Bye bye water weight! I just don't like that it has to steep for a while...I am impatient."]
```

Cluster 1 — Achats "pratiques" et loisirs : bricolage léger, rangement, jouets/cadeaux

Reviews sur des produits utilitaires ou ludiques (accessoires, jouets, objets du quotidien), avec beaucoup de retours sur la facilité d'utilisation, l'assemblage, ou la satisfaction/déception après réception.

```
===== EXEMPLES CLUSTER 1 =====
['Expensive Junk This product consists of a piece of thin flexible insulating material, adhesive backed velcro and white electrical
tape.Problems:1. Instructions are three pictures with little more information.2. Velcro was all crumpled as received and was stronger than the
adhesive. When i tried to disengage the velcro both pieces came off and the paint from the ceiling.3. White electrical tape was horrible...
cheap, narrow and it fell off in less than 1 hour.4. The price is a ripoff.I am building my own which is easier to use, cheaper, more
attractive, and higher r-value. I am surprised Amazon even lists this junk.', 'Fun for all ages! Having received this video as a gift, we
watched it as a family, accompanied by a lot of laughter and "I didn\'t know that". The kids managed to show this to most of their friends,
the youngest even taking it to school where his 1st grade teacher used it as a part of her unit on Careers.The video is an overall winner.
Anyone, any age, will enjoy the playful and informative story and all will come away with a greater understanding and respect for both the
lobster and the lobsterman. BUY IT!', "it's nice I've saved a lot of space by hanging my shoes up with this. For heavier shoes you have to use
more than one hanger though", 'It is fun and a nice car It is a nice car - better than a already made car - your son will have fun assemble it
will even do some changes and when he finish he can continue playing as if it were a standard car.', 'Just like when I was a kid! I bought
this for my daughter when she was almost 2yrs. and she loved it from the start. The music is a little annoying but that is my problem not
hers. She has stood on top of it and it has been dropped down the stairs and it still works fine!I would definalty reccomend this toy!']
```

Cluster 2 —Films / DVD / documentaires : histoire, image, réalisation, qualité du support

Avis clairement orientés "cinéma/vidéo", avec des commentaires sur le scénario, la réalisation, la qualité d'image (DVD vs blu-ray), ou la valeur documentaire.

```
===== EXEMPLES CLUSTER 2 =====
['Excellent imagery...dumbed down story I enjoyed this disc. The video is stunning. I agree with others that the story is very dumbed down and takes a
childish approach. It actually seems like its a little one sided and VERY pro-environmental. Nevertheless its enjoyable. I would say however that the
Amazon WMV HD disc is a better story and has better and sharper images and more interesting things to look at.', "Jeanne de Florette & Manon of the
Springs I saw these movies originally in the theater, loved both and ordered them because I wanted to have it in my collection. I ordered it twice and
neither of the DVDs worked. I would think you would check your merchandise before sending it out. I am so disappointed and can't believe that you could
send out two defective DVDs and had not solved the problem after the first one plus some of the complaints I have read in the reviews. I am rating this
with one star because of the quality of the DVD, not the films.Colleen", "Thanks for the 1960s home movie Ken Burns The documentary is typical Ken
Burns... interesting, but a little meandering at times.The real shame of this version is the grainy video that is painfully apparent on a large HD
display. Burns' panned still images are crystal clear showing every blemish and fold of the old photographs but his shots of the majestic scenery in the
parks are marred by his poor choice of camera and film. I will say the soundtrack is fairly well done even if Peter Coyote (narrator) is a little dry.Do
not bother with the blu ray version, you will not get anything more than the standard DVD version with this series.", 'HARRISON FORD AT HIS VERY BEST!
WITNESS RULES! "WITNESS" is about Ford and an Amish boy who witnesses a murder. Now, the Amish don\'t beleive in killing and guns - and to have their
child see that sort of stuff is just terrible. Now, men who were involved in the murder are out to murder THE AMISH BOY! Suspenseful and red - blooded,
"WITNESS" is an awsome film! I loved it and I bet anyone will, too! ENJOY!', 'One Minute to Zero Movie had a great story, but filming methods of that time
was not that great. I enjoyed the movie mostly because I had met the stars when they were in Colorado Springs during the filming of some of the movie.I
purchased this movie from Amazon.']
```

Cluster 3 — Musique / albums : chansons, rééditions, qualité sonore, contenu bonus

Cluster très cohérent : on retrouve des critiques d'albums, de tracks, d'arrangements, et parfois des plaintes sur des versions "reworkées".

```
===== EXEMPLES CLUSTER 3 =====
["This import is sooooooooooo good This is a great cd!!!!!!!!! It is the normal oops! cd plus three cool new songs. Also there are lots of added extras
that are inhansed on the cd, for example you get the lucky video, a fact file, and a britney unscrambler!!!!! The three bonus tracks are really nice but I
wish that they could have been a little more up tempo. Just to clear something up it says in the discription that there is an exclusive oops preformance
but there isn't!", "Great Album - some serious stuff First off, I've bought ALL of Tonis other albums. This one took me three listenings to really get to
like it. When I found out that it was about a child being born and how her life progressed, I found the work all the more interesting. Some of the songs
really stick in your mind. If you see the Album as a story (of a girls life) it makes the Album much more interesting than just listening to the album
song by song.Pink Floyd used to do this, have an album which was a theme or story, like The Wall album.I took the CD out of my colection after not
listening to it for about 5 months, and have been playing it in my car on the way to work and home for over a week now.It's GREAT. And I'm not a female by
the way.Nice ALbum. If you like Tonis other works,.....GET IT.", "Ran the Stoplight? Listened to this CD closely for the first time in a while. I've
forgotten how outstanding this CD is. While I have not heard Pure, I have ordered it hoping it that will be anything close to this CD - and hopefully far
away from Dead Inside which is a whole different planet. Great vocals, great music, great lyrics, it has it all.", 'One of the best albums I\'ve owned. A
few years back my father got me hooked on this album. It was the first cd I ever owned. An ex-girlfriend liked it so much that after we broke up she
declared that cd was not coming with me.I couldn\'t blame her. The mix of blues and spirituals with Cooder\'s unique playing makes this one the most
intesting albums I own. The medley of "Feeling Good" and "Fool for a Cigarette" is one of my favorites as well as balads like "Mexican Divorce" and "Jesus
on the Main Line".The album also has some songs that keep it from taking itself too seriously. The song "If Walls Could Talk" has a catchy riff and great
words.Cooder\'s great acoustic style shines through on what was a break-through album of the time and holds up years later. I always hear something that I
missed on previous listenings.Although you don\'t need to be a guitar player to appreciate this album, every acoustic player should hear the fine guitar
work. Enjoy!', 'Robbery This is a horrible disc, all of the songs, save one or two, have been reworked. If your looking for a cd to hear bygone favorites,
as they were originally done, this is not the disc.']
```

Cluster 4 — Livres : style d'écriture, contenu, niveau, utilité, profondeur

Avis centrés sur la lecture et l'évaluation du contenu (trop superficiel, très documenté, niveau scolaire, etc.), typique d'un cluster "littérature / non-fiction".

```
===== EXEMPLES CLUSTER 4 =====
['Are we pretending everyone is married? The authors pretend that parents neither die nor divorce. Insisting the marriage is the rock upon which all else
(behavior, well-being of the child) is built, they send a clear message to non-traditional households: this book is for people who play the game of life
our way only, and everyone else can suffer the bad behavior they deserve to.', "Book reads like written for grade schoolers I think that the whole aspect
of hitting the road and going on tour with a band is just about the coolest thing that a person can do. Thus, this book seemed like the perfect read for
someone like me. But when I got the book I was dissapointed in the fact that it seems like the author took five or six stories from the 'The Babysiters
Club' or some other book for young kids, rewrote them to include drug and music references, and than sold it. The writing is just not very good and the
stories are all lame. A girl's mother realizes her 16 year old daughter is right about being on tour, a girl runs from the cops and gets away, a ticket is
fake, ect. Those in themselves aren't even that bad but the way he writes makes it a boring read.", "Amazing, Fascinating This was a stunning book. Well
written, packed with fascinating detail, I wish I had ten more like it to turn to. Anyone looking for an inside view of a part of China's history would do
well to pick up this book. It was a wonderful read.", 'Not great This book just gives you the basics unfortunately. Was not very helpful, I would suggest
just doing research on the interweb instead.', 'superficial fluff This book does not convey much of anything. Save your time and money. Read Searching for
Bobby Fischer. The details and honesty are lacking in this made for MTV summary of kindergartener makes good.']
```

Cluster 5 — Produits tech et accessoires : compatibilité, montage, stockage, périphériques

Avis liés à l'électronique/informatique et aux accessoires (mounts, protections, stockage, compatibilités Mac/USB), avec beaucoup de retours sur contraintes techniques et qualité perçue.

```
===== EXEMPLES CLUSTER 5 =====
["Theater Projector Ceiling Mount Would not fit my new Optima HD20 projector -- as projectors get smaller the mounting holes get closer together -- this
mount had four arms and the projector had three -- the mount had arms that would not get short enough to reach the three projector holes -- for larger
projectors may work better, but for mine would not recommend -- returning it was very easy and the company representatives very helpful -- so if you get
it and it doesn't work, the company is easy to work with --", 'good quality, but high shipping charge the scratch resistant screen guard protector is fit
perfectly on the screen of HTC cingular 8125. Quality of the screen guard protector is very good. only negative point is high shipping charge. it cost me
$4.99 as shipping for buying this item which cost $ 3.49 amazon has to reduce the shipping charge, or reduce the shipping charge for combined items. any
way best buy.', 'Excelente Compilación de lo mejor de Caifanes Debido a los otros comentarios al respecto de este disco quiero aclarar que Caifanes NO es
lo mismo que Jaguares. Son dos grupos diferentes ya que en Caifanes la guitarra estaba en primer plano. El unico pero que le pongo a este CD es que solo
incluyeron 2 canciones del MTV Unplugged. Me hubiera gustado que incluyeran todo el MTV unplugged en el segundo disco. Las guitarras de Marcovich se
aprecian mas en las versiones en vivo ya que existe la certeza de que no hay "overdubbing" (Regrabaciones). Un buen disco para empezar. Estoy seguro que
si este es el primer disco de Caifanes que se adquiere pronto nacera la curiosidad por conocer las canciones que no se incluyen de los otros discos.',
'Mac Owners Beware My wife purchased a Rocket ebook for me for Christmas. She started here at Amazon. She carefully checked the Rocket web site as well,
and spoke to the folks that make the Rocket. She was assured that everything required to use the Rocket with a Mac was included. Wrong! Any Mac currently
being made or made during the past year or so requires a Keyspan connector between the e-book and the Mac USB slot. This costs $80. It is not mentioned in
any documentation that comes with the ebook. It took me more than an hour to get through to the company. At first they responded by saying it was at their
Website and/or in the FAQ section, but we "went to their Web site together" while I was on the phone, and they reluctantly conceded that they had mislead
the public. The company does literature. Guide provided on the ebook. Regardless of how much I may eventually enjoy this toy, I\'ll never develop a high
regard for NuvoMedia, which makes the Rocket ebook.', 'a disaster one month at a time Upon receipt it was dead, after a mixture of e-mailes and phone
calls it was determined I needed to use 2 USB cables to power the drive. Since I only have 2 on my laptop, I cant print from the drive. after transfering
10 gig of pictures and 13 gig of mp3\'s the unit failed the next month. Again emails and phone calls determined my laptop did not have enough power to run
the drive. The solution was an AC adapter.....great for a "portable USB drive" They said an AC adaptor would be sent...no adapter after 4 weeks now. I
```

10.4 Comparaison TF-IDF vs SBERT

Cette lecture qualitative est importante : elle montre que SBERT regroupe mieux les avis par univers d'usage (livres, musique, films, tech, objets du quotidien) même lorsque les formulations diffèrent. À l'inverse, TF-IDF avait tendance à fusionner des thèmes dès qu'un vocabulaire générique ("product", "good", "use") était partagé.

Critère	TF-IDF	SBERT
Qualité des thèmes	Moyenne	Excellente
Silhouette	Très faible	Faible mais 10× supérieur
Compréhension du sens	Non	Oui
Recouvrement thématique	Beaucoup	Nette séparation
Richesse sémantique	Faible	Très bonne

SBERT surpasse très nettement TF-IDF. Il produit des clusters plus cohérents, plus denses, plus lisibles et véritablement exploitables.

10.5 Synthèse des Thématiques identifiées

L'analyse thématique des reviews Amazon met en évidence 6 grands axes récurrents, structurés autour des usages et des types de produits :

- **<u>Product performance & value perception</u>** : retours d'usage concrets sur la qualité, la durabilité et le rapport qualité-prix des produits.

- **<u>Entertainment and leisure products</u>** : jeux, jouets et produits de divertissement orientés plaisir d'utilisation.

- **<u>Movies, documentaries and audiovisual content</u>** : critiques de films, DVD et contenus vidéo (scénario, acting, rythme).

- **<u>Music albums & CDs</u>** : avis sur des albums, chansons, qualité sonore et éditions.

- **<u>Books & literature</u>** : retours sur la lecture, le style d'écriture, la narration et le contenu.

- **<u>Technology & accessories</u>** : produits technologiques, accessoires et problèmes techniques (installation, compatibilité, fiabilité).

Ces thèmes reflètent une structuration sémantique claire du corpus et dépassent la simple catégorisation lexicale obtenue avec TF-IDF.

10.6 Test des 2 modèles DistilBert et SentenceBert sur des avis personnalisés

Les résultats montrent que Sentence-BERT classe les avis en fonction du contexte sémantique global plutôt que de mots-clés isolés, ce qui explique certains rapprochements entre jeux vidéo, films et autres contenus de divertissement.

==========

I bought this product hoping it would solve a simple everyday problem, but the experience was disappointing. The device feels cheaply made and does not perform as expected. After only a few uses, the battery started losing charge very quickly, which makes it impractical for daily use. Considering the price, I honestly feel like I wasted my money and expected much better quality.

→ Sentiment : Negative (score = 0.993)
→ Thème : Technology & accessories

==========

This album is a great listen from start to finish. The sound quality is excellent and the production really highlights both the vocals and the instruments. A few songs stand out more than the others, but overall the track list is well balanced. I have been listening to it repeatedly and would definitely recommend it to music lovers.

→ Sentiment : Positive (score = 0.997)
→ Thème : Music albums & CDs

==========

I enjoyed reading this book, even though it was not perfect. The story is engaging and easy to follow, and the author does a good job developing the main characters. Some chapters felt a bit slow, but overall the writing style kept me interested until the end. It is a solid read for anyone who enjoys character-driven stories.

→ Sentiment : Positive (score = 0.997)
→ Thème : Books & literature

==========

The movie has strong acting performances and a well-constructed story, but it drags in a few places. Some scenes could have been shorter to keep a better pace. That said, the cinematography is impressive and several moments are genuinely memorable. Overall, it is an enjoyable film, even if it does not fully live up to its potential.

→ Sentiment : Positive (score = 0.996)
→ Thème : Movies, documentaries and audiovisual content

==========

This product is easy to use and does exactly what it promises. The quality feels solid and it works well for everyday use. I have been using it regularly for a few weeks now without any issues. For the price, it offers good value and seems durable enough to last.

→ Sentiment : Positive (score = 0.997)
→ Thème : Product performance & value perception

==========

This game is a lot of fun to play and offers several hours of entertainment. The gameplay is simple to understand, but still engaging enough to keep things interesting. The controls are responsive, the levels are well designed, and there is a good balance between challenge and enjoyment. While the graphics are not groundbreaking, they fit the style of the game well. Overall, it is an enjoyable experience and a solid choice if you are looking for a game to relax and have fun with.

→ **Sentiment : Positive (score = 0.997)**
→ **Thème : Entertainment and leisure products**

10.7 Conclusion de la section

Les résultats obtenus confirment l'intérêt d'une approche basée sur les embeddings sémantiques pour le topic modeling sur des données textuelles complexes comme des avis clients.

La méthode TF-IDF + KMeans constitue une baseline rapide et interprétable, mais montre des limites importantes : faible score de silhouette et recouvrement partiel entre certains thèmes, notamment pour les avis génériques sur les produits.

À l'inverse, l'approche Sentence-BERT + KMeans permet une meilleure séparation sémantique des clusters, avec un Silhouette score plus élevé (≈ 0.048) et des thèmes plus lisibles lorsqu'ils sont analysés via des exemples représentatifs. Cette méthode capture mieux le contexte global et l'intention des utilisateurs, au prix d'un temps de calcul plus important et d'une interprétabilité moins directe.

En pratique, TF-IDF reste adapté pour une exploration rapide, tandis que Sentence-BERT offre une vision plus riche et plus proche de la compréhension humaine des thématiques abordées dans les avis.

11 Synthèse générale

Ce projet avait pour objectif d'exploiter un large corpus de reviews Amazon afin de répondre à deux enjeux complémentaires et centraux pour une plateforme e-commerce à grande échelle :

- prédire automatiquement le sentiment exprimé par les utilisateurs,
- identifier et comprendre les thématiques majeures abordées dans les avis clients.

Pour y parvenir, nous avons adopté une démarche progressive combinant des méthodes classiques de traitement du langage naturel et des approches plus récentes basées sur le Deep Learning. Cette double approche permet d'obtenir à la fois une base de comparaison robuste et une analyse plus fine du contenu textuel.

11.1 Analyse de sentiment

Plusieurs modèles ont été testés :

- Régression logistique
- SVM linéaire
- DistilBERT fine-tuné sur ~40 000 reviews

Les modèles linéaires basés sur TF-IDF offrent des performances solides (accuracy comprise entre 0.88 et 0.90) et constituent des baselines efficaces. Toutefois, le modèle **DistilBERT**, malgré un entraînement réalisé uniquement sur CPU, surpasse nettement ces approches en atteignant :

- Accuracy : 0.9285
- F1-score : 0.93

Ces résultats s'expliquent par la capacité de DistilBERT à capturer le contexte et les nuances linguistiques des avis, notamment dans les formulations ambiguës ou nuancées. Ce modèle a donc été retenu comme modèle final pour la prédiction du sentiment, offrant un excellent compromis entre performance et complexité.

11.2 Analyse thématique (Topic Modeling)

Deux approches ont été comparées pour l'extraction des thématiques.

a) Baseline TF-IDF + KMeans

Cette première méthode, bien que limitée par une représentation bag-of-words, permet de faire émerger des thématiques globalement cohérentes. Malgré un **silhouette score faible (≈ 0.0037)**,

typique des espaces de très grande dimension, l'analyse qualitative met en évidence plusieurs axes récurrents :

- Music albums & CDs
- Books & literature
- Movies & cinema
- Video games & DVDs
- General products & usage
- Customer dissatisfaction & product issues

Cette approche fournit une première segmentation utile, mais reste limitée par l'absence de compréhension sémantique fine.

b) Sentence-BERT + KMeans

L'utilisation d'embeddings SBERT (*all-MiniLM-L6-v2*) apporte une amélioration significative. Le modèle obtient un silhouette score de 0.0479, soit environ 13 fois supérieur à celui de TF-IDF, traduisant une meilleure cohérence intra-cluster.

Les clusters obtenus sont plus homogènes et mieux séparés sémantiquement, distinguant clairement :

- Product performance & value perception
- Entertainment and leisure products
- Movies, documentaries and audiovisual content
- Music albums & CDs
- Books & literature
- Technology & accessories

Sentence-BERT permet d'identifier des thèmes sémantiquement cohérents et exploitables, notamment : **product performance**, **technology & accessories**, **entertainment products**, **movies**, **music albums** et **books**.

Ces résultats offrent une lecture plus proche de la perception réelle des utilisateurs et constituent une base solide pour des applications métiers.

11.3 Recommandations métier

Les résultats obtenus ouvrent la voie à plusieurs applications concrètes.

1. Améliorer la priorisation des retours clients

En combinant sentiment et thématique, il devient possible d'identifier rapidement :

- *les catégories les plus sensibles (ex. électronique, technologie),*
- *les produits générant une forte insatisfaction,*
- *les problématiques récurrentes (qualité, batterie, prix, installation).*

Action recommandée : mise en place d'un tableau de bord automatisé croisant sentiment et thèmes.

2. Assistance automatisée au support client

Le modèle DistilBERT peut être intégré pour :

- *classifier automatiquement les tickets entrants,*
- *détecter les avis très négatifs,*
- *orienter ou suggérer des réponses adaptées.*

Impact attendu : réduction du temps de traitement et amélioration de la satisfaction client.

3. Améliorer les pages produit

L'analyse thématique permet d'identifier les critères réellement importants pour les utilisateurs selon les catégories :

- *livres : histoire, personnages, style,*
- *électronique : fiabilité, batterie, prix*
- *divertissement : gameplay, scénario, plaisir d'usage.*

Ces insights peuvent être réinjectés dans les fiches produit afin d'améliorer la conversion.

4. Détection anticipée de problèmes qualité

Les clusters thématiques permettent de repérer :

- *des défauts récurrents,*
- *des marques ou catégories à risque,*
- *des signaux faibles émergents.*

Action : surveillance continue des thèmes via SBERT.

5. Perspectives en recommandation personnalisée

La thématisation textuelle ouvre également la voie à :

- des moteurs de recommandation basés sur le contenu,
- des suggestions personnalisées selon les centres d'intérêt,
- un filtrage intelligent des reviews les plus pertinentes.

Valeur métier : augmentation conversion + meilleure expérience utilisateur.

11.4 Limites du projet & Pistes d'amélioration

Plusieurs axes d'amélioration peuvent être envisagés :

- entraînement de DistilBERT sur GPU pour réduire le temps de calcul,
- exploration d'algorithmes de clustering plus adaptés aux embeddings (HDBSCAN, BERTopic),
- fine-tuning léger de SBERT sur le corpus Amazon,
- optimisation du choix du nombre de clusters et des hyperparamètres.

12 Conclusion finale

Ce projet met en évidence l'apport majeur des techniques modernes de NLP dans l'analyse à grande échelle des retours clients :

- DistilBERT offre une excellente performance pour la classification du sentiment,
- Sentence-BERT permet une extraction thématique plus cohérente et actionnable,
- les résultats sont directement exploitables par des équipes produit, qualité, marketing ou support.

L'objectif initial qui était de prédire le sentiment des utilisateurs et identifier les thématiques dominantes des reviews — a été atteint grâce à une approche combinant modèles classiques et deep learning. DistilBERT s'est imposé comme le modèle le plus performant pour la classification du sentiment, en capturant efficacement les nuances linguistiques et les avis ambigus et Sentence-BERT a permis d'extraire des thèmes plus cohérents, stables et directement exploitables d'un point de vue métier.

Les résultats obtenus sont immédiatement actionnables pour des équipes produit, qualité, marketing ou support client, notamment pour la priorisation des problèmes, l'amélioration des fiches produit et l'automatisation du traitement des retours utilisateurs.

Ce travail constitue ainsi une base solide et crédible pour le déploiement de solutions automatisées de veille, de segmentation et de compréhension client à grande échelle, tout en ouvrant la voie à des améliorations futures basées sur des modèles encore plus spécialisés.